



Artículo

Modelo de IA para el análisis de emociones para la arquitectura de detección mediante EEG

Seung Yeul Ji, Mi Kyung Kim y Han Jong Jun



Facultad de Arquitectura, Universidad de Hanyang, Seúl 04763, República de Corea; musicji83@hanyang.ac.kr (S.-Y.J.); nnyang2mk@hanyang.ac.kr (M.-K.K.)

* Correspondencia: hanjong@hanyang.ac.kr

Resumen: El rápido avance de la inteligencia artificial (IA) ha impulsado la innovación en diversos ámbitos (tecnologías de la información, medicina, educación y ciencias sociales) y, a la vez, está creando nuevas oportunidades en la arquitectura para comprender las interacciones entre los seres humanos y el entorno. Este estudio tiene como objetivo desarrollar un modelo de IA perfeccionado que aproveche los datos de electroencefalografía (EEG) para analizar los estados emocionales de los usuarios en tiempo real y aplicar estos conocimientos a los espacios arquitectónicos. Específicamente, se empleó el conjunto de datos SEED (un recurso de reconocimiento de emociones basado en EEG proporcionado por el laboratorio BCMI de la Universidad Jiao Tong de Shanghai) para perfeccionar el modelo ChatGPT y clasificar tres estados emocionales (positivo, neutro y negativo). Los resultados experimentales demuestran la eficacia del modelo para diferenciar estos estados según las señales de EEG, aunque el número limitado de participantes limita nuestros hallazgos a una prueba de concepto. Además, para evaluar la viabilidad del enfoque propuesto en contextos arquitectónicos reales, integramos el modelo en un entorno de realidad virtual (RV) de 360°, donde demostró ser prometedor para el reconocimiento de emociones en tiempo real y el diseño adaptativo. Al combinar el análisis de datos biométricos basado en IA con el diseño arquitectónico centrado en el usuario, este estudio busca fomentar entornos construidos sostenibles que respondan dinámicamente a las emociones humanas. Los resultados subrayan el potencial del reconocimiento de emociones basado en EEG para mejorar las experiencias de los ocupantes y proporcionan información fundamental para futuras investigaciones sobre las interacciones entre las personas y el entorno.

Palabras clave: análisis de emociones; modelo de IA; arquitectura de detección; EEG; datos biométricos



Editores académicos:

Nikolaos Kourkouvelis y

Panagiotis G. Asteris

Recibido: 19 de diciembre de 2024

Revisado: 26 de febrero de 2025

Aceptado: 27 de febrero de 2025

Publicado: 4 de marzo de 2025

Cita: Ji, S.-Y.; Kim, M.-K.; Jun,

H.-J. Modelo de IA para análisis de emociones para arquitectura de detección mediante EEG. *Appl. Ciencia*. 2025, 15, 2742. <https://doi.org/10.3390/app15052742>

Copyright: © 2025 por los autores.

Licenciatario MDPI, Basilea, Suiza.

Este artículo es un artículo de acceso abierto distribuidos bajo los términos y

Condiciones de Creative Commons

Licencia de atribución (CC BY)

(<https://creativecommons.org/licenses/by/4.0/>).

1. Introducción

1.1 Antecedentes y objetivos del estudio

El rápido avance de la inteligencia artificial (IA) ha impulsado una innovación significativa en múltiples disciplinas, como la tecnología de la información, la medicina, la educación y las ciencias sociales. En particular, la IA ha desempeñado un papel fundamental en la evolución de la computación afectiva, permitiendo el análisis cuantitativo y la interpretación de las emociones humanas mediante modelos computacionales [1,2]. Recientemente, la aparición de la tecnología de interfaz cerebro-computadora (BCI) ha atraído cada vez más atención, y el reconocimiento de emociones basado en electroencefalografía (EEG) se perfila como una herramienta prometedora para la detección del estado afectivo en tiempo real. El EEG captura la actividad eléctrica cerebral, lo que facilita el establecimiento de correlaciones entre señales neuronales y estados emocionales específicos. Esta capacidad ha abierto nuevas vías para la detección de emociones en tiempo real y el desarrollo de sistemas adaptativos, con aplicaciones que abarcan la atención médica, la interacción persona-ordenador (HCI) y la interfaz cerebro-ordenador [4,5].

A pesar de estos avances, la aplicación de la tecnología de reconocimiento de emociones en entornos arquitectónicos sigue siendo en gran medida inexplorada. Los métodos tradicionales de análisis...

Las respuestas afectivas humanas a los entornos construidos se han basado principalmente en técnicas subjetivas como encuestas, entrevistas psicológicas y observaciones conductuales [6]. Si bien estos enfoques proporcionan información valiosa sobre las experiencias emocionales, están inherentemente limitados por la subjetividad, los sesgos de respuesta y la incapacidad de capturar fluctuaciones emocionales en tiempo real. Como resultado, la integración de datos biométricos objetivos, como las señales de EEG, con el análisis de emociones impulsado por IA representa una dirección prometedora para mejorar las experiencias de los usuarios en entornos arquitectónicos adaptativos [7,8].

Estudios recientes han demostrado la viabilidad de la IA en el reconocimiento de emociones basado en EEG, allanando el camino para su aplicación en diversos ámbitos. Por ejemplo, un estudio de 2023 realizado en la Universidad de California, Berkeley, analizó con éxito datos de EEG de pacientes con epilepsia para reconstruir la canción *Another Brick in the Wall* de Pink Floyd, destacando el potencial de la IA para decodificar pensamientos y emociones humanas mediante señales de EEG [9]. Sin embargo, si bien estos hallazgos subrayan el potencial del análisis de emociones basado en IA, su aplicación en entornos arquitectónicos adaptativos en tiempo real aún está poco desarrollada. La investigación existente se ha centrado principalmente en la HCI y las aplicaciones médicas, lo que deja una brecha crítica en la comprensión de cómo la computación afectiva en tiempo real puede integrarse en el diseño arquitectónico [10,11].

Para abordar esta brecha, este estudio tiene como objetivo desarrollar un modelo de IA capaz de reconocer emociones basado en EEG en tiempo real y su aplicación a entornos arquitectónicos adaptativos. En concreto, esta investigación investiga la viabilidad de la arquitectura de detección, en la que los entornos construidos se ajustan dinámicamente en respuesta a los estados emocionales de los usuarios, captados mediante retroalimentación biométrica. El estudio se centra en el entrenamiento y la evaluación de un modelo de IA basado en EEG para la clasificación de emociones en tres clases (positiva, neutra y negativa) y su implementación en un entorno de realidad virtual (RV) de 360° para evaluar su eficacia en el diseño arquitectónico adaptativo [12].

Esta investigación se distingue de estudios previos al trasladar el enfoque del reconocimiento de emociones de los métodos estáticos convencionales al análisis biométrico en tiempo real en espacios arquitectónicos. Si bien trabajos anteriores se han basado principalmente en autoevaluaciones emocionales y estudios observacionales, este estudio explora cómo los modelos de IA basados en EEG pueden detectar y responder dinámicamente a los estados emocionales de los usuarios en tiempo real. Además, mientras que estudios anteriores se han centrado en la HCI y los contextos médicos, este estudio investiga las implicaciones del reconocimiento de emociones basado en EEG para el diseño arquitectónico centrado en el usuario, enfatizando su potencial para mejorar la experiencia, la comodidad y el compromiso de los ocupantes [13,14].

Al explorar la aplicación de la IA basada en EEG en entornos de construcción adaptativos, este estudio busca aportar evidencia empírica que respalde la integración de la computación afectiva en tiempo real en entornos arquitectónicos. Se espera que los hallazgos contribuyan al desarrollo de espacios inteligentes y adaptables al usuario, que se adapten dinámicamente a los estados afectivos humanos. Además, esta investigación pretende sentar las bases para futuros estudios sobre el papel de la computación afectiva en la planificación urbana, los entornos inteligentes y el diseño arquitectónico centrado en el ser humano [15].

1.2. Métodos y alcance del estudio

Este estudio tiene como objetivo desarrollar un modelo de IA perfeccionado capaz de analizar datos de EEG para clasificar estados emocionales y aplicar estos conocimientos a entornos arquitectónicos adaptativos. A diferencia de los modelos de clasificación de EEG convencionales, que se basan en características estructuradas espacialmente, este estudio investiga la viabilidad de eliminar las dependencias de los canales de EEG mediante la construcción de un conjunto de datos JSONL independiente del canal. Además, explora si los grandes modelos de lenguaje (LLM) pueden inferir estados afectivos a partir de señales de EEG y evalúa el potencial de integrar la inferencia LLM con arquitecturas CNN-LSTM para mejorar el rendimiento de la clasificación.

1.2.1. Descripción general y preprocesamiento del conjunto de datos

El conjunto de datos SEED (conjunto de datos EEG de emociones de la Universidad Jiao Tong de Shanghai) [16], desarrollado por el Instituto de investigación BCMI de la Universidad Jiao Tong de Shanghai, fue seleccionado como el conjunto de datos principal para este estudio [17]. Comprende grabaciones de EEG de 15 participantes, cada uno expuesto a clips de películas emocionalmente evocadores categorizados en estados positivos, neutros y negativos [4]. Las señales de EEG se recopilaron utilizando un sistema NeuroScan de 62 canales (Compumedics Neuroscan, Charlotte, NC, EE. UU.) a una frecuencia de muestreo de 1000 Hz, que posteriormente se redujo a 200 Hz para optimizar la eficiencia computacional [5].

Para preparar los datos para el entrenamiento del modelo, las señales de EEG se convirtieron a formato JSONL, eliminando las etiquetas explícitas de los canales y conservando las características temporales y espectrales. Esta transformación permite al modelo aprender representaciones de EEG generalizadas sin depender de asignaciones espaciales predefinidas [8].

Se realizó un preprocesamiento para mejorar la calidad de los datos y mejorar la solidez del modelo. Se aplicó un filtro de paso de banda (0,5–50 Hz) para eliminar el ruido, asegurando así la retención de los componentes de frecuencia relevantes. Se utilizó el Análisis de Componentes Independientes (ICA) para eliminar artefactos oculares y musculares, minimizando así la contaminación de las señales de EEG. Se implementó la normalización por canal para estandarizar las señales de EEG entre los participantes, reduciendo la variabilidad intersujeto y mejorando la generalización del modelo [9]. Si bien el conjunto de datos incluye datos de seguimiento ocular, este estudio se centra únicamente en las señales de EEG, ya que proporcionan una medida directa y objetiva de la actividad neuronal asociada con los estados afectivos [10].

1.2.2. Desarrollo del modelo de IA. Se

desarrollaron dos modelos de IA para la clasificación de emociones basada en EEG. El primer modelo es un híbrido CNN-LSTM, diseñado para extraer características espaciales y temporales de las señales de EEG. Se utilizaron CNN para la extracción de características, mientras que los LSTM capturaron las dependencias temporales, lo que convierte a este modelo en un referente para la clasificación de EEG [11].

El segundo modelo es un LLM optimizado, entrenado con el conjunto de datos de EEG JSONL independiente del canal, lo que le permite procesar señales de EEG en un formato de datos estructurado [14]. Este enfoque investiga si los LLM pueden interpretar eficazmente las señales de EEG e inferir estados afectivos, a diferencia de los modelos convencionales de aprendizaje profundo que se basan en mapeos espaciales [15].

Además, se exploró la viabilidad de un modelo híbrido que combina la inferencia CNN-LSTM y LLM. Este enfoque híbrido integra las características extraídas de CNN-LSTM con el razonamiento basado en LLM, examinando si los LLM pueden complementar los modelos tradicionales de clasificación de EEG aprovechando las representaciones de datos estructurados [18].

1.2.3. Entrenamiento y optimización del modelo

Los modelos se entrenaron con una proporción de entrenamiento y prueba de 80:20, lo que garantizó una distribución equilibrada de los datos para el entrenamiento y la evaluación. Se ajustaron los hiperparámetros para refinar la tasa de aprendizaje, el tamaño del lote y la tasa de abandono, optimizando así la precisión de la clasificación de los modelos [7].

El modelo CNN-LSTM se diseñó para capturar dependencias espaciales y temporales, mientras que el LLM afinado se optimizó para interpretar señales de EEG mediante incrustaciones estructuradas. Se realizaron análisis comparativos para evaluar el modelo CNN-LSTM, el LLM afinado y su contraparte híbrida, determinando en qué medida los LLM pueden mejorar el reconocimiento de emociones basado en EEG [19].

1.2.4. Aplicación del modelo de IA en entornos arquitectónicos

Para evaluar la aplicabilidad del reconocimiento de emociones basado en EEG en entornos adaptativos, los modelos entrenados se implementaron en una simulación de realidad virtual (RV) de 360°. Este experimento...

La configuración espacial facilitó el procesamiento de señales EEG en tiempo real, lo que permitió una evaluación empírica de cómo el reconocimiento de emociones basado en EEG puede contribuir a configuraciones espaciales adaptativas [13].

Se realizaron adaptaciones arquitectónicas en respuesta a los estados emocionales detectados. Al identificar una emoción positiva, el sistema aumentó la iluminación natural e introdujo tonos ambientales cálidos, lo que favoreció la comodidad del usuario [7]. Al detectar una emoción neutra, el entorno permaneció inalterado, garantizando la estabilidad [8]. Por el contrario, al identificar una emoción negativa, el sistema ajustó la iluminación, la configuración espacial y las propiedades acústicas para mejorar el bienestar emocional del usuario [9].

Este estudio se alinea con los principios de la arquitectura sensorial, donde los entornos construidos se adaptan dinámicamente a los estados afectivos de los usuarios en tiempo real. Los hallazgos brindan información valiosa sobre la viabilidad de integrar el reconocimiento de emociones basado en EEG con la adaptación arquitectónica impulsada por IA, lo que contribuye a la investigación en diseño espacial sensible a las emociones [10].

2. Revisión de la literatura

2.1. Reconocimiento de emociones basado

en EEG La electroencefalografía (EEG) se ha convertido en una herramienta clave en la computación afectiva, permitiendo la medición de la actividad neuronal asociada con las emociones humanas [4]. Debido a su naturaleza no invasiva y alta resolución temporal, la EEG se usa ampliamente para el reconocimiento de emociones en tiempo real, apoyando aplicaciones en la interacción humano-computadora (HCI) [2], diagnósticos médicos [3] e interfaces cerebro-computadora (BCI) [5]. La investigación ha demostrado que bandas de frecuencia específicas de EEG, incluyendo ondas alfa (8-13 Hz), beta (13-30 Hz), theta (4-8 Hz) y gamma (30-100 Hz), se correlacionan con diferentes estados afectivos [6].

Varios conjuntos de datos de referencia facilitan la investigación del reconocimiento de emociones mediante EEG. El conjunto de datos DEAP, ampliamente utilizado para la clasificación de emociones, proporciona señales EEG y fisiológicas registradas mientras los participantes veían videos evocadores [17]. El conjunto de datos SEED, desarrollado por el laboratorio BCMI de la Universidad Jiao Tong de Shanghai, ofrece grabaciones EEG de participantes que vieron videos que inducen emociones, categorizadas en estados positivos, neutros y negativos [20].

A pesar de los avances, el reconocimiento de emociones basado en EEG sigue confinado en gran medida a condiciones de laboratorio controladas, lo que limita su adaptabilidad en contextos del mundo real [21]. Los modelos tradicionales de aprendizaje automático, incluidas las máquinas de vectores de soporte (SVM) y los clasificadores de bosque aleatorio, requieren una ingeniería de características y un preprocesamiento exhaustivos [22]. Los modelos de aprendizaje profundo, incluidas las redes neuronales convolucionales (CNN) y las redes neuronales recurrentes (RNN), han demostrado un rendimiento de clasificación superior [23], pero su implementación en entornos interactivos en tiempo real, como los espacios arquitectónicos, sigue en gran medida sin explorar [24].

2.2. Modelos de reconocimiento de emociones impulsados por IA y enfoques de ajuste

La adopción de técnicas de aprendizaje profundo ha mejorado significativamente el reconocimiento de emociones basado en EEG al automatizar la extracción de características y el aprendizaje de patrones jerárquicos [25]. Los estudios han implementado con éxito CNN, redes de memoria a corto plazo (LSTM) y arquitecturas híbridas de aprendizaje profundo para mejorar la clasificación de emociones basada en EEG [26]. Además, se han investigado modelos basados en transformadores, desarrollados originalmente para el procesamiento del lenguaje natural (PLN), para el análisis de EEG [27].

El ajuste fino de los modelos de aprendizaje profundo preentrenados se ha convertido en un método eficaz para mejorar la clasificación basada en EEG mediante la adaptación de los modelos a conjuntos de datos o entornos específicos [8]. Esta técnica permite que los modelos retengan el conocimiento general mientras se refinan para tareas específicas del dominio. La investigación ha demostrado que las CNN y las RNN ajustadas mejoran significativamente la precisión de la clasificación de EEG [28] y las técnicas de aprendizaje por transferencia, en

qué modelos se entrenan inicialmente en un conjunto de datos de EEG y luego se ajustan utilizando otro, han mostrado resultados prometedores [29].

Sin embargo, los modelos ajustados a menudo heredan sesgos de los conjuntos de datos originales, lo que hace que... los hace menos adaptables a entornos dinámicos en tiempo real [30]. Dado que la mayoría de los modelos están entrenados En conjuntos de datos estáticos, no tienen en cuenta las variaciones emocionales continuas en el mundo real. condiciones [31]. Este estudio aborda estas limitaciones mediante el ajuste de un aprendizaje profundo modelo para el procesamiento de EEG en tiempo real, lo que garantiza la adaptabilidad en entornos arquitectónicos donde Las respuestas emocionales fluctúan dinámicamente [32].

Además, en lo que respecta a las técnicas de clasificación, varios estudios han destacado la alta aplicabilidad potencial de los diversos enfoques presentados en Una visión general de Técnicas de clasificación de aprendizaje automático [33], Un estudio sobre técnicas de clasificación en datos minería de datos [34], Justificación genética de los resultados de los pacientes con COVID-19 utilizando DERGA, un nuevo estudio de datos algoritmo voraz de refinamiento de conjunto [35], y revelar la naturaleza de la función cardiovascular Enfermedades que utilizan DERGA, un novedoso algoritmo voraz de refinamiento de conjuntos de datos [36] para el reconocimiento de emociones basado en EEG. En particular, métodos de conjuntos avanzados como DERGA (algoritmo voraz de refinamiento de conjuntos de datos) se han empleado en aplicaciones biomédicas complejas. análisis de datos [37], lo que sugiere que podrían servir como alternativas prometedoras para el desarrollo Modelos de reconocimiento de emociones EEG en tiempo real y mejora de la precisión de la clasificación.

2.3. Reconocimiento de emociones en espacios arquitectónicos

La influencia de los entornos arquitectónicos en las emociones humanas ha sido ampliamente estudiada. Estudió psicología ambiental y diseño centrado en el ser humano [38]. Factores arquitectónicos como la iluminación, la configuración espacial, la acústica y la materialidad impactan significativamente. respuestas emocionales y cognitivas [39]. Sin embargo, la evaluación arquitectónica convencional Las metodologías siguen basándose en métodos cualitativos, como evaluaciones posteriores a la ocupación, observaciones del comportamiento y evaluaciones psicométricas, en lugar de incorporar datos fisiológicos objetivos [12].

Investigaciones recientes han explorado la integración de datos biométricos en el diseño arquitectónico. Estudios en neuroarquitectura han examinado las respuestas del EEG a las configuraciones espaciales, demostrando el potencial del reconocimiento de emociones basado en EEG en aplicaciones arquitectónicas [14].

Además, se han incorporado señales biométricas como la variabilidad de la frecuencia cardíaca (VFC) y la respuesta galvánica de la piel (GSR) en entornos inteligentes para regular la iluminación y sistemas climáticos [15]. Sin embargo, estos enfoques siguen siendo en gran medida experimentales y las implementaciones prácticas de la computación afectiva impulsada por IA en la arquitectura adaptativa aún están en desarrollo. sus primeras etapas [13].

El concepto de arquitectura sensorial, donde los entornos construidos se ajustan de forma autónoma Basada en retroalimentación biométrica en tiempo real, ha ganado cada vez más atención [19]. Si bien la computación afectiva impulsada por IA se ha explorado en edificios inteligentes y planificación urbana, Su aplicación práctica en la arquitectura adaptativa en tiempo real aún está poco desarrollada [7]. Los marcos actuales generalmente se basan en configuraciones predefinidas y carecen de la capacidad de modificarse dinámicamente. ajustar configuraciones espaciales basadas en retroalimentación emocional derivada del EEG en tiempo real [40].

2.4. Brechas de investigación y contribuciones de este estudio

A pesar del progreso en el reconocimiento de emociones basado en EEG y la computación afectiva impulsada por IA, su integración en entornos arquitectónicos adaptativos sigue en gran medida sin explorar [41]. La mayoría de las investigaciones se han realizado en condiciones de laboratorio controladas, lo que limita la aplicación del análisis de emociones basado en EEG en entornos construidos del mundo real [42]. Los modelos de IA existentes para el reconocimiento de emociones se han aplicado principalmente a la HCI y la medicina. campos, con investigaciones limitadas que exploran su papel potencial en la arquitectura adaptativa [43].

Una brecha crítica en la investigación es la falta de validación en el mundo real de los modelos de reconocimiento de emociones basados en EEG en contextos arquitectónicos. La mayoría de los estudios se realizan en entornos experimentales altamente controlados, donde los participantes se exponen a estímulos emocionales predefinidos mientras se registran sus respuestas neuronales [44]. Si bien estos estudios proporcionan información sobre las correlaciones entre EEG y emociones, no tienen en cuenta la complejidad de los entornos arquitectónicos reales, donde múltiples estímulos ambientales interactúan simultáneamente.

Otra brecha importante es la ausencia de modelos de IA específicamente diseñados para la detección de emociones basada en EEG en la arquitectura. Los modelos de reconocimiento de emociones existentes se han desarrollado principalmente para el análisis de sentimientos basado en texto, el reconocimiento de emociones del habla y el análisis de expresiones faciales, mientras que los modelos basados en EEG siguen centrados principalmente en aplicaciones clínicas y neurocientíficas [46]. Aunque las arquitecturas de aprendizaje profundo como las CNN y las RNN han demostrado una alta precisión en la clasificación de emociones mediante EEG, su adaptación a entornos construidos adaptativos en tiempo real no se ha estudiado exhaustivamente [37].

Además, los sistemas actuales de arquitectura adaptativa se basan en configuraciones ambientales predefinidas, como ajustes automatizados de iluminación o control de temperatura, según las preferencias estáticas del usuario. Sin embargo, actualmente no existen mecanismos de adaptación en tiempo real basados en IA que modifiquen dinámicamente las configuraciones espaciales basándose en la retroalimentación emocional derivada del EEG.

Para abordar estas deficiencias, este estudio presenta un marco optimizado de reconocimiento de emociones mediante EEG basado en IA, diseñado para su aplicación en tiempo real en entornos construidos. A diferencia de estudios previos que se basan en conjuntos de datos estáticos y preetiquetados, esta investigación integra la recopilación y el procesamiento de datos de EEG en tiempo real en un entorno arquitectónico interactivo. El modelo se valida en un entorno de realidad virtual (RV) de 360°, trascendiendo las condiciones experimentales controladas para evaluar la viabilidad práctica del reconocimiento de emociones basado en EEG en espacios arquitectónicos dinámicos.

Al integrar la neurociencia, la computación afectiva y la inteligencia arquitectónica, este estudio propone un enfoque novedoso para incorporar la retroalimentación emocional en tiempo real al diseño espacial adaptativo. Se espera que los hallazgos contribuyan al desarrollo de entornos inteligentes y adaptables al usuario, mejorando la experiencia de los ocupantes, el bienestar psicológico y la funcionalidad arquitectónica.

3. Modelo de IA para el análisis de emociones mediante EEG. 3.1.

Selección y uso de conjuntos de datos para el entrenamiento de ajuste fino.

Este estudio seleccionó el conjunto de datos SEED (Laboratorio BCMI, Universidad Jiao Tong de Shanghai, Shanghai, China) como conjunto de datos de IA para entrenar el modelo ajustado basado en ondas cerebrales.

El conjunto de datos SEED se creó en 2013 y es proporcionado por el Instituto de Investigación BCMI de la Universidad Jiao Tong de Shanghai. Incluye datos de ondas cerebrales (EEG) y movimiento pupilar. El conjunto de datos se compone de datos recopilados mientras los participantes veían videoclips que inducían emociones. Específicamente, se seleccionaron videoclips para inducir emociones positivas, negativas y neutras. Se incluyeron los datos de EEG y movimiento pupilar de 12 participantes y los datos adicionales de EEG de tres participantes. Se incluyeron los datos de un total de 15 participantes y se creó un conjunto de datos de entrenamiento con 644.000 filas.

El conjunto de datos SEED es un conjunto de datos EEG (ondas cerebrales) diseñado para estudiar el reconocimiento de emociones y consta de datos recopilados a través de 14 videoclips que inducen diversos estados emocionales. El conjunto de datos se clasificó según el número de videoclips según la emoción (feliz, triste, neutral), la duración de cada videoclip y el número de filas de datos recopiladas. En primer lugar, hay cuatro videos que inducen tristeza, con una duración total de reproducción de 927 s. Los datos de EEG de estos videos se muestrearon a 200 Hz, generando un total de 185 400 filas de datos. Los videos que inducen tristeza desempeñan un papel importante en el análisis de las respuestas emocionales de los sujetos y en el estudio de los patrones de ondas cerebrales causados por la tristeza.

Luego, hay cinco vídeos que inducen a la felicidad, y la duración total de estos vídeos son 1186 s. Se generaron un total de 237.200 filas de datos de EEG en el estado feliz y Se utilizaron para analizar diversas emociones positivas y estudiar las características de las ondas cerebrales. emociones felices.

Finalmente, hay cinco vídeos que inducen emociones neutrales y su duración total es 1107 s. Se recopilaron un total de 221.400 filas de datos de EEG de estos vídeos neutrales, que permiten comprender la actividad cerebral durante estados emocionales neutros. En general, Los 14 videoclips del conjunto de datos SEED incluyen 3200 s de tiempo de reproducción y 644 000 filas de EEG. datos. Esta estructura de datos proporciona los diversos estados emocionales que se requieren en la emoción. Investigación de reconocimiento y permite a los investigadores analizar los cambios minúsculos en las ondas cerebrales causadas por estados emocionales.

Este conjunto de datos se utilizó para ajustar el modelo de emoción de ondas cerebrales en este estudio (Tabla 1).

Tabla 1. Volumen de entrenamiento utilizando el conjunto de datos SEED.

Emoción	Videoclip	Duración del vídeo (s)	Número de filas de datos (200 Hz)
Tristeza	4	927	185.400
Felicidad	5	1186	237.200
Neutral	5	1107	221.400
Total	14	3220	644,00

Se seleccionó el conjunto de datos SEED por su sistema de aplicación de etiquetas a cada video, como que se muestra en la Tabla 2, es adecuado para construir un modelo de IA. Además, se ha utilizado por más de 2600 programas de aplicación y más de 770 organizaciones de investigación a partir de Octubre de 2021, y uno de los artículos que utiliza el conjunto de datos, Zheng (2015) [16], ha sido citado más de 910 veces [14].

Tabla 2. Etiquetado y composición del conjunto de datos SEED.

Nombre del clip	Etiqueta	Hora de inicio	Fin de los tiempos
Perdido en Tailandia	2 (feliz) 1	0:06:13	0:10:11
Patrimonio Mundial en China	(neutral) 0	0:00:50	0:04:36
Réplica	(triste) 0	0:20:10	0:23:35
Regreso a 1942	(triste) 1	0:49:58	0:54:00
Patrimonio Mundial en China	(neutral) 2	0:10:40	0:13:44
Perdido en Tailandia	(feliz) 0	1:05:10	1:08:29
Regreso a 1942	(triste) 1	2:01:21	2:05:21
Patrimonio Mundial en China	(neutral) 2	2:55	6:35
Erudito coqueteador	(feliz) 2	1:18:57	1:23:23
Sólo otra caja de Pandora	(feliz) 1	11:32	15:33
Patrimonio Mundial en China	(neutral) 0	10:41	14:38
Regreso a 1942	(triste) 1	2:16:37	2:20:37
Patrimonio Mundial en China	(neutral) 2	5:36	9:36
Sólo otra caja de Pandora	(feliz)	35:00	39:02

El presente estudio utilizó los datos etiquetados para tres emociones (feliz, triste y neutral). del conjunto de datos SEED. Entre los ejemplos de los videoclips se incluyen "Perdidos en Tailandia", "El mundo 'Patrimonio en China', 'Réplica' y 'Regreso a 1942', y cada clip está etiquetado como 0, 1 o 2, que indican emociones tristes, neutrales o felices, respectivamente. Este etiquetado ayuda a analizar y comprender las diferencias en los patrones de ondas cerebrales según el estado emocional.

Sin embargo, debido a que la longitud total y el número de filas difieren para cada emoción, categoría (triste, neutral, feliz), equilibramos los datos extrayendo un número igual de

muestras por categoría. De esta manera, nos aseguramos de que el proceso de ajuste no se sobreajustara a cualquier etiqueta de emoción única y mantuvo una distribución de entrenamiento más equilibrada. Este conjunto de datos se utilizó para ajustar el modelo de emoción de ondas cerebrales en este estudio (Tabla 3).

Tabla 3. Distribución de emociones.

Categoría	Contar	Porcentaje
Triste (-1 negativo)	88.802	33,3%
Neutro (0 neutro)	88.802	33,3%
Feliz (1 positivo)	88.802	33,3%

3.2. Construcción de modelos ajustados

En el presente estudio, los datos de ondas cerebrales (EEG sin procesar) del conjunto de datos SEED se convirtieron al formato JSONL para afinar el aprendizaje. El conjunto de datos SEED consta de datos de EEG para reconocimiento de emociones e incluye datos recopilados para varios estados emocionales (por ejemplo, feliz, triste, neutral). Estos datos se utilizaron para realizar ajustes con un modelo basado en GPT-4o.

y analizar estados emocionales basándose en datos de ondas cerebrales.

En primer lugar, los datos EEG sin procesar del conjunto de datos SEED se estructuraron en el formato JSONL junto con las etiquetas de emoción. En el formato JSONL, cada muestra se representa mediante una objeto JSON independiente y es el formato óptimo para entrenar el modelo GPT-4o. A través de este formato, el modelo puede comprender y aprender el orden temporal y la emoción. Aprende y predice con precisión la información emocional basándose en datos de ondas cerebrales. En el proceso de ajuste, el modelo GPT-4o utiliza datos en formato JSONL para realizar el aprendizaje. Los valores de peso del modelo se actualizan de acuerdo con las etiquetas emocionales durante Este proceso. GPT-4o es un modelo de lenguaje que trabaja principalmente con datos de texto. Sin embargo, en En este estudio, los valores numéricos de los datos de las ondas cerebrales se asignaron a un espacio vectorial. y se convirtió en entrada de texto, lo que permitió a GPT-4o realizar análisis de emociones. Esto El método permite que el modelo comprenda mejor las experiencias y los estados emocionales de los usuarios. en espacios arquitectónicos.

Además, se utilizaron las configuraciones de hiperparámetros proporcionadas por la API GPT-4o de OpenAI. Para optimizar el ajuste fino. Actualmente, el valor de época está limitado a tres durante el ajuste fino. y el rendimiento del modelo se optimiza al aprender repetidamente los datos de las ondas cerebrales. bajo esta condición limitada. Gracias a este ajuste, el modelo analizó y reflejó

Appl. Sci. 2025, 15, x PARA resultados DE los estados emocionales de los usuarios en espacios arquitectónicos en tiempo real y produjeron resultados significativos REVISIÓN POR PARES (Figura 1).

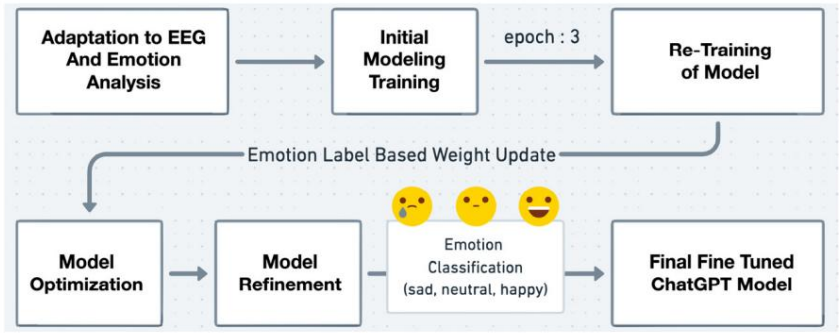


Figura 1 Proceso del método de ajuste fino para el conjunto de datos EEG (SEED).

Finalmente, el modelo GPT-4o perfeccionado puede clasificar y comprender de manera más efectiva Estados emocionales de los usuarios mediante el uso de datos de ondas cerebrales en espacios arquitectónicos. Este enfoque... Puede desempeñar un papel importante a la hora de reflejar y mejorar las experiencias de los usuarios en tiempo real cuando

Diseño y operación de espacios arquitectónicos. Los resultados del prototipo, obtenidos mediante el modelo optimizado, pueden observarse en la plataforma web basada en Streamlit. Mediante el servicio web que se muestra en la Figura 2, se puede obtener información sobre emociones operando el modelo optimizado basado en GPT-4o e ingresando datos sin procesar para cada canal.

EEG Data Emotion Analysis




Figura 2. Figura 2. Clasificación de emociones. Clasificación de emociones ingresadas por el usuario.

3.3. Desarrollo y entrenamiento del modelo afinado

3.3.1. Preprocesamiento de

datos Como etapa inicial del entrenamiento del modelo afinado, el preprocesamiento de datos es esencial. Este preprocesamiento desempeña un papel importante en el mantenimiento de la calidad y la consistencia de los datos de ondas cerebrales; en particular, elimina el ruido por encima de 60 Hz y mejora...

Machine Translated by Google

Consistencia de los datos de ondas cerebrales; en particular, elimina el ruido por encima de 60 Hz y mejora la relación señal-ruido. Esto ayuda al modelo a aprender las señales cerebrales con mayor precisión.

Además, al utilizar un método que elimina artefactos comunes (p. ej., parpadeo, movimiento muscular) de los datos de ondas cerebrales, se puede mantener la integridad de los datos y minimizar la modificación innecesaria de la señal.

Este procedimiento de preprocesamiento de datos optimiza la relación señal-ruido. Esto ayuda al modelo a aprender las señales cerebrales con mayor precisión.

Los artefactos secundarios que se eliminan son los artefactos que no se deben a la actividad cerebral, como los movimientos musculares o el parpadeo. Estos artefactos se eliminan a partir de los datos de ondas cerebrales, manteniendo la integridad de los datos y minimizando la modificación innecesaria de la señal. Este procedimiento de preprocesamiento de datos se centra en... reducir el ruido y los artefactos secundarios en los datos de ondas cerebrales.

El filtro de línea de 60 Hz se aplicó para eliminar el ruido de la línea de 60 Hz. El programa NIG2 de NeuroLab (España, v2.1.9.6) se aplicó para eliminar el ruido de los datos de ondas cerebrales.

En el proceso de preprocesamiento de datos, se eliminan los artefactos secundarios que no se deben a la actividad cerebral, como los movimientos musculares o el parpadeo. Esto ayuda al modelo a aprender las señales cerebrales con mayor precisión.

Los datos de ondas cerebrales se organizan en un espacio vectorial en la universidad del modelo ajustado de ondas cerebrales. Esto ayuda al modelo a aprender las señales cerebrales con mayor precisión.

En lugar de extraer características de los datos de ondas cerebrales, como un índice numérico, las características de los datos de ondas cerebrales se utilizan para entrenar el modelo. Esto ayuda al modelo a aprender las señales cerebrales con mayor precisión.

System Prompt							
<i>"role" : "system", "content" : "I am an expert in analyzing and categorizing emotions using EEG brainwave data. I need you to classify me into three categories, 0 sad, 1 neutral,2 happy."</i>							
<i>Fp1</i>	<i>Fz</i>	<i>Fp2</i>	<i>C3</i>	<i>Cz</i>	<i>C4</i>	<i>O1</i>	<i>O2</i>
-11.62	38.05	-14.78	1.99	10.72	23.81	31.26	26.82
<i>1</i>	<i>2</i>	<i>3</i>	<i>4</i>	<i>5</i>	<i>6</i>	<i>7</i>	<i>8</i>

Figura 3. Reglas para el conjunto de datos que utiliza datos EEG de 8 canales.

Este proceso de preprocesamiento y estructuración permite utilizar los datos de las ondas cerebrales en el proceso de ajuste, el conjunto de datos SEED se utilizó como datos de entrenamiento para funcionar de manera más eficiente y ayudar al modelo a aprender los patrones complejos de las señales de ondas cerebrales. Entrenamiento y evaluación del rendimiento del modelo. Sin embargo, el hiperparámetro... con mayor precisión.

configuración utilizada durante el ajuste fino (por ejemplo, tamaño del lote, tasa de aprendizaje, configuración de validación cruzada)

En el proceso de ajuste fino, el conjunto de datos SEED se utilizó como datos de entrenamiento para realizar. Está limitado por el marco de ajuste fino del modelo GPT actual. Por consiguiente, este estudio de configuración de hiperparámetros siguió las directrices de OpenAI, manteniendo la configuración básica durante el entrenamiento y la configuración utilizada durante el ajuste fino (p. ej., tamaño del lote, tasa de aprendizaje, configuración de validación cruzada).

En el futuro, si se concede permiso para modificar los hiperparámetros, será necesario... está limitado por el marco de ajuste fino del modelo GPT actual. Por consiguiente, esto...

Es necesario realizar estudios adicionales para optimizar esas configuraciones y mejorar aún más el estudio siguiendo las pautas de OpenAI manteniendo las configuraciones básicas mientras se entrena el rendimiento del modelo. En el futuro, si se concede permiso para modificar los hiperparámetros, será necesario...

Las pautas de OpenAI se centran en la configuración de los parámetros básicos de entrenamiento para mantener la estabilidad del modelo y prevenir el sobreajuste. Hiperparámetros como el tamaño del lote y el rendimiento del modelo.

La tasa de aprendizaje puede tener una influencia significativa en la velocidad de aprendizaje y la precisión de las pautas de OpenAI se centran en la configuración de los parámetros básicos de entrenamiento para mantener la estabilidad del modelo y prevenir el sobreajuste. Debido a estas restricciones, se mantiene la estabilidad del modelo y se evita el sobreajuste. Como hiperparámetros, como el tamaño del lote...


Los investigadores realizan el entrenamiento de acuerdo con la configuración inicial del modelo y pueden evaluar la tasa de aprendizaje, lo que puede tener una influencia significativa en la velocidad y la precisión del aprendizaje.

del modelo, actualmente están restringidos a valores predefinidos. Debido a estas restricciones, los investigadores realizan el entrenamiento de acuerdo con la configuración inicial del modelo y pueden evaluar el desempeño potencial de los modelos en función de los resultados obtenidos de esta manera.

Los futuros estudios de optimización de hiperparámetros desempeñarán un papel importante en la mejora de la Rendimiento de los modelos.

En el proceso de ajuste fino, que integra los datos de ondas cerebrales en el modelo GPT, es importante tener una nomenclatura clara y precisa para los datos de entrenamiento. En este proceso, la estructura ...

Tokens	Characters
562	1015



La figura 4 ilustra cómo se organizó un único mensaje en un módulo de tal manera que

La figura 4 ilustra cómo se organizó un único mensaje en un módulo de modo que 163 163 tokens constituyeron un conjunto de entrenamiento de ajuste fino, lo que dio como resultado un total de 4 173 237 tokens.

Los tokens constituyeron un conjunto de entrenamiento de ajuste fino, lo que resultó en un total de 4.173.237 tokens utilizados en el proceso de ajuste fino. Mediante este entrenamiento del modelo, el GPT ajustado

ing utilizado en el proceso de ajuste fino. Mediante este entrenamiento del modelo, el modelo GPT ajustado logró clasificar y predecir eficazmente los estados emocionales a partir del EEG.

El modelo logró clasificar y predecir eficazmente los estados emocionales a partir de datos de EEG en entornos arquitectónicos. Todos los datos textuales para el proceso de ajuste fueron...

Datos en entornos arquitectónicos. Todos los datos textuales para el proceso de ajuste se almacenaron en formato JSON.

Además, la imagen adjunta no fue creada manualmente por el autor, sino que fue

generado automáticamente por el sistema Tokenizer de OpenAI para estructurar datos legibles para

Entrenamiento de modelos de IA. Este sistema organiza los datos de texto en un formato JSON estructurado y...

utiliza códigos de colores para diferenciar varios elementos, como valores clave, valores de datos,

y etiquetas de clasificación de emociones. Este proceso ayuda al modelo de IA a analizar y clasificar eficientemente

procesar los datos de entrada.

Entrenamiento del modelo. Este sistema organiza los datos de texto en formato JSON estructurado y utiliza códigos de colores para diferenciar diversos elementos, como valores clave, valores de datos y etiquetas de clasificación de emociones. Este proceso ayuda al modelo de IA a analizar y procesar eficientemente los datos de entrada.

Durante el entrenamiento del modelo para el ajuste fino, se encontraron numerosos pasos de prueba y error . Cabe destacar que se debe prestar mucha atención al formato de los datos: a diferencia de lo convencional . Cabe destacar que se debe prestar mucha atención al formato de los datos: a diferencia de lo convencional. El formato JSON tradicional, JSON Lines (JSONL), sigue estrictamente una estructura basada en líneas . Por lo tanto, cuando... al preparar los datos de entrenamiento de ajuste fino en formato JSONL, cada uno de los ocho canales de EEG al preparar los datos de entrenamiento de ajuste fino en formato JSONL, cada uno de los ocho canales de EEG Los canales deben escribirse como un objeto JSON individual en una línea separada, sin espacios en blanco. Los canales intermedios, como se ilustra en la Figura 4. líneas

Una vez completado el proceso de ajuste fino, los valores de pérdida convergieron casi a cero. Una vez y predicción de muestras. La Figura 5, hubo un marcado aumento en la precisión de la predicción basada en datos de EEG. En concreto, la pérdida de entrenamiento final fue de 0.1163 y la validación fue de 0.2752 (con una pérdida de validación completa de 0.2373). Aunque no se puede determinar con precisión la precisión únicamente a partir de estos valores de pérdida, la relación inversa generalmente. Si bien no se puede determinar la precisión de la mina únicamente a partir de estos valores de pérdida, la relación inversa que se observa generalmente entre la pérdida de entropía cruzada y la precisión sugiere que una validación de la precisión de la pérdida de entropía cruzada y la precisión entre interpolaciones sugieren que se podría esperar una precisión de validación de aproximadamente el 85-90 % con este nivel de pérdida. Por supuesto, esta cifra se mantiene. Se podría esperar un 85-90% con este nivel de pérdida. Por supuesto, esta cifra sigue siendo meramente una estimación; para obtener la precisión real, así como métricas como la puntuación F1 o Kappa de Cohen, Kappa de Cohen, se deben comparar las predicciones del modelo en el conjunto de validación directamente. Es necesario comparar las predicciones del modelo en el conjunto de validación directamente con las etiquetas de la verdad fundamental. Estos puntos se analizarán con más detalle en el... etiquetas de verdad. Estos puntos se analizarán con más detalle en la siguiente sección .



Figura 5. Resultados del entrenamiento del modelo de ajuste fino.

4. Aplicación y uso del modelo de ajuste fino basado en ondas cerebrales en espacios arquitectónicos 4.1.

Validación y evaluación del rendimiento del modelo de ajuste fino

La validación del modelo de IA afinado se realizó a través de un marco de evaluación estructurado, que implicó consultar el modelo a través de la API de OpenAI, recuperar sus predicciones y compararlas con las etiquetas de verdad fundamental. Como la API de OpenAI no proporciona herramientas de evaluación de rendimiento integradas, se desarrolló un script personalizado de Python 3.10 (Python Software Foundation, Fredericksburg, VA, EE. UU.) para gestionar las consultas de la API, recopilar predicciones y calcular métricas de clasificación esenciales. El proceso de evaluación tuvo como objetivo evaluar la eficacia del modelo en la clasificación de emociones basada en EEG midiendo la exactitud, la precisión, la recuperación, la puntuación F1 y el coeficiente Kappa de Cohen.

4.1.1. Validación del conjunto de datos y carga de archivos JSONL

Para facilitar la evaluación del modelo, se preparó un conjunto de datos JSON Lines (JSONL) denominado `validation_set.jsonl` como conjunto de validación. Este conjunto de datos se estructuró para incluir datos de señales de EEG junto con sus correspondientes etiquetas de emoción, garantizando así la compatibilidad con la API de OpenAI. El formato estructurado permitió una integración perfecta con el modelo perfeccionado, lo que posibilitó la realización de consultas y la recuperación de respuestas de manera eficiente.

Se implementó una función de Python para cargar y procesar sistemáticamente el conjunto de datos JSONL. La función lee el conjunto de datos línea por línea, analiza cada entrada y almacena los datos extraídos en un formato estructurado para su posterior evaluación.

Código Python: Función de carga de archivos JSONL (Cuadro 1).

Cuadro 1. Función de carga de archivos JSONL para datos de validación de EEG.

```
importar json

def load_jsonl(file_path): """Carga
y analiza un archivo JSONL que contiene datos de validación de EEG.""" data = [] with
open(file_path, 'r', encoding = 'utf-8') as f: for line in f:

    data.append(json.loads(line)) return data
```

Esta función facilita el manejo eficiente de datos de validación de EEG a gran escala, garantizando un procesamiento de entrada estructurado para el modelo. Al emplear este enfoque, el estudio establece un marco de validación sistemático que permite una evaluación robusta y reproducible del rendimiento del modelo optimizado.

4.1.2. Generación de predicciones de emociones mediante la API de OpenAI

Se accedió al modelo optimizado, identificado como `ft:gpt-4o-mini-2024-07-18:personal:eeg-emotion-ver7:AyoeRwUt`, a través del endpoint `ChatCompletion` de la API de OpenAI. Dado que la API de OpenAI no ofrece herramientas integradas para la evaluación del rendimiento del modelo, se diseñó un script de Python para enviar datos de EEG como entrada, recuperar la etiqueta de emoción predicha y almacenar los resultados para su posterior análisis.

La estructura de la consulta se diseñó para incluir un mensaje del sistema que definía la función del modelo como clasificador de emociones EEG, seguido de un mensaje del usuario con los datos del EEG. La respuesta del modelo se estandarizó eliminando los espacios innecesarios y convirtiéndola a minúsculas, lo que garantizó la uniformidad del procesamiento.

Código Python: Generación de predicciones de emociones a través de la API de OpenAI (Cuadro 2).

Cuadro 2. Generación de predicciones de emociones basadas en EEG utilizando la API de OpenAI.

```

importar openai

MODEL_NAME = "ft:gpt-4o-mini-2024-07-18:personal:eeg-emotion-ver7:AyoeRwUt" cliente =
openai.OpenAI()

def get_prediction(eeg_data):
    """Consulta el modelo OpenAI afinado para clasificar la emoción basada en EEG.""" response =
    client.chat.completions.create( model = MODEL_NAME,
    messages = [ {"role": "system",
    "content": "Eres
    un modelo de clasificación de emociones EEG."}, {"role": "user", "content": f"EEG data: {eeg_data}
    \nClasifica la emoción como -1 negativo, 0 neutral, 1 positivo."} ], timeout = 30

    ) devuelve respuesta.opciones[0].mensaje.contenido.tira().inferior()

```

Esta función permite una interacción consistente con el modelo optimizado, garantizando así la recuperación y el procesamiento de las predicciones de forma estandarizada. Al estructurar los formatos de entrada y respuesta, el estudio proporciona una metodología escalable y reproducible para evaluar modelos de reconocimiento de emociones mediante EEG basados en LLM.

4.1.3. Comparación de predicciones con etiquetas de verdad fundamental

Para comparar sistemáticamente las etiquetas predichas con las etiquetas de verdad, se extrajeron las etiquetas reales del conjunto de datos JSONL y se estandarizaron según el esquema de tres clases (-1: negativo, 0: neutro, 1: positivo). Se implementó una función de mapeo de etiquetas para normalizar las variaciones en la representación de las etiquetas, garantizando así la consistencia en la evaluación.

Tras recuperar las etiquetas predichas y verdaderas de cada muestra, se adjuntaron a listas separadas para su análisis comparativo. Además, se utilizó la biblioteca tqdm para proporcionar una barra de progreso en tiempo real, lo que garantiza un seguimiento eficiente de los procesos de validación a gran escala y las estimaciones intermedias de rendimiento.

4.1.4. Cálculo y resultados de las métricas de rendimiento. Dado

que la API de OpenAI no calcula las métricas de rendimiento automáticamente, se emplearon métodos de scikit-learn para evaluar el rendimiento de la clasificación. La evaluación incluyó exactitud, precisión, recuperación, puntuación F1 y Kappa de Cohen, lo que garantizó una evaluación exhaustiva de la capacidad del modelo para la clasificación de emociones basada en EEG.

El modelo perfeccionado se sometió a ocho iteraciones de preprocesamiento y entrenamiento, culminando en el desarrollo de ocho versiones optimizadas. Cada versión se evaluó en condiciones de prueba idénticas, lo que permitió realizar comparaciones directas de rendimiento entre iteraciones.

Los resultados demostraron mejoras notables en la precisión de la clasificación, con la versión 8 alcanzando la mayor precisión, un 60,3 %, en comparación con el 34 % de las iteraciones anteriores. Una diferencia clave entre las versiones 1 a 7 y la versión 8 residía en la estructura del conjunto de datos. Las versiones anteriores incluían explícitamente los nombres de los canales de EEG en los datos de entrenamiento JSONL, mientras que la versión 8 los eliminaba y se basaba únicamente en datos de EEG normalizados. Esta modificación estructural probablemente contribuyó a la mejora del rendimiento observada (Tabla

Tabla 4. Estructura del conjunto de datos de la versión 8.

Versión	Modelo	Emoción	Exactitud de la puntuación de recuperación de precisión F1			De Cohen Kappa	
Versión 1	ft:gpt-4o-2024-08-06:personal:eeg-emoción:A5phbEb	Triste (−1 negativo)	0.5	0.04	0.07	0.34	0.1
		Neutro (0 neutro)	0.38	0.13	0.2		
		Positivo (1 positivo)	0.33	0.86	0.47		
		Precisión general	-	-	0.34		
Versión 2	ft:gpt-4o-2024-08-06:personal:eeg-emoción-ver2:A5uctXW	Triste (−1 negativo)	1.0	0.01	0.02	0.33	0.1
		Neutro (0 neutro)	0	0	0		
		Positivo (1 positivo)	0.32	0.99	0.49		
		Precisión general	-	-	0.33		
Versión 3	ft:gpt-4o-2024-08-06:personal:eeg-emoción-ver3:AArwL8j	Triste (−1 negativo)	0.34	0.37	0.36	0.34	0.1
		Neutro (0 neutro)	0.37	0.33	0.32		
		Positivo (1 positivo)	0.31	0.32	0.32		
		Precisión general	-	-	0.34		
Versión 4	ft:gpt-4o-mini-2024-07-18:personal:eeg-emoción-ver4:AB1mUNZ	Triste (−1 negativo)	0.32	0.63	0.43	0.32	0.1
		Neutro (0 neutro)	0.31	0.30	0.31		
		Positivo (1 positivo)	0.33	0.02	0.04		
		Precisión general	-	-	0.32		
Versión 5	ft:gpt-4o-mini-2024-07-18:personal:eeg-emoción-ver5:AB42P4s	Triste (−1 negativo)	0.39	0.17	0.23	0.38	0.07
		Neutro (0 neutro)	0.40	0.53	0.46		
		Positivo (1 positivo)	0.35	0.43	0.39		
		Precisión general	-	-	0.38		
Versión 6	ft:gpt-4o-mini-2024-07-18:personal:eeg-emoción-ver6:AB5S5vY	Triste (−1 negativo)	0.32	0.52	0.40	0.31	0.1
		Neutro (0 neutro)	0.30	0.36	0.32		
		Positivo (1 positivo)	0.31	0.05	0.08		
		Precisión general	-	-	0.31		
Versión 7	ft:gpt-4o-mini-2024-07-18:personal:eeg-emoción-ver7:AyoeRwU	Triste (−1 negativo)	0.35	0.44	0.39	0.32	0.1
		Neutro (0 neutro)	0.31	0.39	0.35		
		Positivo (1 positivo)	0.28	0.13	0.18		
		Precisión general	-	-	0.32		
Versión 8	ft:gpt-4o-mini-2024-07-18:personal:eeg-emoción-ver8:Az2SEgt	Triste (−1 negativo)	0,6	0,52	0,56	0.603	0.46
		Neutro (0 neutro)	0,55	0,47	0,51		
		Positivo (1 positivo)	0,62	0,81	0,70		
		Precisión general	-	-	0.603		

4.1.5. Discusión e implicaciones

La API de OpenAI sirve principalmente como plataforma de inferencia y alojamiento de modelos y No proporciona herramientas integradas de evaluación del rendimiento. Por lo tanto, los usuarios deben implementar scripts personalizados para recopilar predicciones de modelos y calcular métricas como precisión, exactitud, recuperación, puntuación F1 y Kappa de Cohen. Es fundamental mantener la coherencia en el formato de las etiquetas. ya que las variaciones en la representación de la etiqueta (por ejemplo, “1 positivo” frente a “positivo (1)”) pueden llevar a desalineación en los cálculos de precisión.

Este estudio realizó ocho iteraciones de ajuste, que culminaron en la versión 8, que Se logró una precisión del 60,3%, una mejora significativa con respecto a las versiones anteriores. Sin embargo, persisten desafíos, particularmente en la clasificación de emociones neutrales (0), así como en la La tendencia del modelo a sobrepredecir emociones positivas (1). Estos hallazgos sugieren que, además Es necesario un refinamiento, considerando las características intrínsecas de las señales EEG y el GPT Optimización inherente del modelo para el procesamiento basado en texto.

Dada la creciente adopción de arquitecturas híbridas CNN-LSTM para sistemas basados en EEG Clasificación de emociones debido a su capacidad de capturar características tanto espaciales como temporales, esto El estudio explora un enfoque de dos pasos en el que se procesan las características extraídas de CNN-LSTM mediante un modelo basado en GPT. Se espera que esta estrategia mitigue las inconsistencias en la clasificación. entre las clases neutrales y positivas, mejorando así el rendimiento general de la clasificación.

Además, el estudio investigó el impacto del entrenamiento de modelos LLM utilizando JSONL. archivos sin nombres de canales de EEG, lo que permite que el modelo procese señales de EEG sin Referencias espaciales explícitas. Este método no solo mejora la privacidad de los datos, sino que también fomenta El modelo se centra en patrones de señales intrínsecos en lugar de identificadores espaciales a nivel de superficie.

Para optimizar aún más el rendimiento, las investigaciones futuras deberían centrarse en la ingeniería rápida , el ajuste fino de los parámetros, la expansión del conjunto de datos de EEG y el desequilibrio de clases. Resolución. Maximizar las capacidades de inferencia LLM al integrar el híbrido CNN-LSTM Los marcos podrían mejorar el efecto sinérgico del aprendizaje de características espacio-temporales y Razonamiento basado en LLM.

Al validar sistemáticamente el modelo GPT perfeccionado y comparar múltiples versiones , este estudio establece un marco de evaluación estructurado para la emoción basada en EEG. reconocimiento. Además, la integración de arquitecturas híbridas CNN-LSTM con LLM Los modelos presentan un potencial prometedor para mejorar la precisión de la clasificación. El conjunto de datos JSONL, independiente del canal, mejora aún más el preprocesamiento de datos y la protección de la privacidad. Esta metodología es aplicable a diversas aplicaciones de computación afectiva basadas en EEG . Este marco de validación escalable proporciona un método robusto para la evaluación comparativa de EEG. Modelos de clasificación de emociones en diversas condiciones experimentales.

4.2. Aplicación del modelo ajustado al espacio arquitectónico: Experiencia de realidad virtual de 360°

Este estudio aplicó el modelo de IA perfeccionado (versión 8) en una realidad virtual basada en video de 360° . entorno para explorar las respuestas emocionales de los usuarios en espacios arquitectónicos. Los datos de EEG fueron recopilados mientras los participantes experimentaban dos entornos urbanos distintos: Dongdaemun Design Plaza (DDP) de Seúl y Long Island City de Nueva York. Estas ubicaciones fueron Seleccionados por sus diferentes proporciones de elementos artificiales y naturales, lo que permite un análisis comparativo de cómo las características espaciales influyen en las respuestas emocionales. Cada sesión de RV duró tres minutos para garantizar una exposición adecuada y mantener la concentración de los participantes.

4.2.1. Configuración y equipo experimental

El experimento se llevó a cabo utilizando el auricular Meta Quest 2 VR (Meta, Menlo Park, CA, EE. UU.) para reproducción de video inmersiva y el Enobio EEG 32 de 32 canales (Neuroelectronics, Sistema de adquisición de señales de EEG (Barcelona, España). Cuatro estudiantes universitarios en su... En el estudio participaron personas de entre veinte y treinta años, todas con experiencia previa en el uso de dispositivos de realidad virtual y EEG. Los dos entornos de realidad virtual representaron composiciones urbanas contrastantes. DDP en Seúl Presentaba estructuras predominantemente artificiales con vegetación mínima, mientras que Long Island City En Nueva York había una mayor proporción de elementos naturales, incluidos parques y zonas costeras. áreas. Este contraste permitió una evaluación de cómo los entornos construidos y naturales afectan



Figura 6. Experimento 360VR basado en EEG con modelo ajustado. Figura 6. Experimento 360VR basado en EEG con modelo ajustado.

4.2.2. Aplicación del modelo ajustado versión 8

El modelo de IA optimizado (Versión 8) se utilizó para clasificar los estados emocionales de los participantes en el entorno de realidad virtual de 360° en tres categorías: «feliz», «neutral» y «triste». En lugar de realizar un análisis estadístico detallado, este estudio se centró en identificar patrones de EEG y resultados de la clasificación emocional en ambos entornos.

Durante la recopilación de datos, cada participante experimentó tanto DDP como Long Island City durante tres minutos cada uno, lo que resultó en una duración total de la sesión de seis minutos por participante. Las señales de EEG se registraron de forma continua durante las sesiones y se registraron segmentos de tiempo específicos.

Figura 6. Experimento 360VR basado en EEG con modelo ajustado.

4.2.2. Aplicación del modelo ajustado (versión 8 El

El modelo de la versión 8 (versión 8) se utilizó para clasificar los estados emocionales de los participantes. Los participantes en el entorno de realidad virtual de 360° se clasificaron en tres categorías: "feliz", "neutral" y "triste". En lugar de... «triste». Ra: mediante un análisis estadístico detallado, este estudio se centró en identificar patrones de EEG. En lugar de realizar un análisis estadístico detallado, este estudio se centró en identificar los resultados del EEG y la clasificación emocional en los dos entornos.

Durante la recopilación de datos, cada participante experimentó tanto el DDP como Long Island City durante tres minutos cada uno, lo que resultó en una duración total de la sesión de seis minutos por participante. Las señales de EEG se registraron continuamente durante las sesiones y se registró un tiempo específico. Las señales de EEG se registraron continuamente durante las sesiones y se extrajeron segmentos de tiempo específicos después de la experiencia. En la etapa de preprocesamiento, se eliminaron los artefactos. Tras el traslado, las señales de EEG se escalaron por canal y se convirtieron a JSONL. Los datos se introdujeron en la versión 8 del modelo optimizado. Con base en estos datos procesados, el modelo predijo el estado emocional más probable entre "feliz", "neutral" y "triste". A partir de los datos, el modelo predijo el estado emocional más probable entre "feliz", "neutral" y "triste". y 'triste'.

Los resultados se analizaron visualizando las regiones EEG más activadas (por ejemplo, frontal, frontal, parietal o temporal) para cada participante y comparando la actividad emocional prevista (lóbulo parietal o temporal) para cada participante y comparando la distribución emocional prevista (%). Este enfoque proporcionó una interpretación intuitiva de cómo las características del entorno de RV y las diferencias individuales influyeron en las respuestas emocionales basadas en EEG.

Las características mentales y las diferencias individuales influyeron en la respuesta emocional basada en EEG (Figura 7).



Figura 7. Aplicación del modelo de ajuste firmo utilizando 360VR.

4.2.3. Análisis exploratorio de resultados

En el grupo DDP (A), el participante n.º 1 exhibió la mayor proporción de "felicidad". (57,42%) al analizar la actividad EEG de los lóbulos frontal y parietal. Para el n.º 2, Las observaciones de los lóbulos occipital y temporal indicaron que "neutral" (50,02%) era el estado más dominante, seguido de "feliz" (35,13%) y "triste" (14,85%). En el caso del n.º 3, la actividad EEG en el lóbulo parietal mostró que la emoción principal era "feliz" (48,96 %). Pero "neutral" (33,14%) y "triste" (17,90%) también estaban bien representados, lo que sugiere un potencial sesgo de clasificación. Participante n.º 4, cuyas señales de EEG se analizaron desde el temporal y los lóbulos occipitales exhibieron proporciones casi iguales de "neutral" (41,55%) y "feliz". (42,33%), lo que indica que no existe un estado emocional dominante.

En el grupo de Long Island (B), el participante n.º 1 mostró una distribución uniforme de "felicidad". (40,23%), "neutral" (39,34%) y "triste" (20,43%) al considerar la actividad EEG de los lóbulos frontal y temporal. En el caso n.º 2, el análisis del lóbulo occipital solo reveló una actividad dominante. estado "neutral" (55,23%), con proporciones más bajas de "feliz" y "triste". El participante n.º 3, cuyo Las señales de EEG se derivaron de los lóbulos frontal y parietal, y tenían "feliz" (44,60%) como el la mayor proporción, pero también estaban presentes los sentimientos "neutrales" (35,10%) y "tristes" (20,30%). Finalmente, para #4, la actividad EEG de los lóbulos frontal, temporal y occipital combinados resultó en una sensación de tristeza. (28,77%) siendo más pronunciado, mientras que 'feliz' (34,78%) y 'neutral' (36,45%) mostraron proporciones similares, lo que sugiere una distribución emocional equilibrada entre los estados (Tabla 5).

Tabla 5. Comparación de las tendencias del diagrama de conectividad de los participantes y el modelo de ajuste de la emoción resultados de la clasificación.

Usuario	DDP (A)			Long Island (B)		
	Diagrama de conectividad	Emoción		Diagrama de conectividad	Emoción	
		Sintonía FINA (%)			Sintonía FINA (%)	
#1	Lóbulo frontal y parietal actividad	Feliz	57.42	Lóbulo frontal y temporal actividad	Feliz	40.23
		Neutral	32.18		Neutral	39.34
		Triste	10.40		Triste	20.43
#2	Lóbulo occipital y temporal actividad	Feliz	35.13	Actividad del lóbulo occipital	Feliz	30.48
		Neutral	50.02		Neutral	55.23
		Triste	14.85		Triste	14.29
#3	Actividad del lóbulo parietal	Feliz	48,96	Lóbulo frontal y parietal actividad	Feliz	44.60
		Neutral	33.14		Neutral	35.10
		Triste	17,90		Triste	20.30
#4	Lóbulo temporal y occipital actividad	Feliz	42.33	Frontal, temporal y actividad del lóbulo occipital	Feliz	34,78
		Neutral	41.55		Neutral	36.45
		Triste	16.12		Triste	28.77

4.2.4. Implicaciones y direcciones futuras

Los resultados indican variaciones individuales en la clasificación emocional, lo que sugiere que Las respuestas del EEG están muy influenciadas por las características personales. Incluso dentro del mismo... entorno, los participantes exhibieron diferentes clasificaciones emocionales, destacando la Naturaleza específica del sujeto de las respuestas afectivas basadas en EEG.

El estudio también proporciona información preliminar sobre la influencia de las características ambientales . Al examinar las diferencias en la activación de las regiones cerebrales y la clasificación de las emociones, En DDP y Long Island City, los hallazgos sugieren una posible relación entre Elementos espaciales artificiales versus naturales y respuestas emocionales.

Sin embargo, como este estudio se realizó con un tamaño de muestra pequeño (n = 4), los resultados Debería interpretarse como una prueba piloto más que como una conclusión estadísticamente generalizable. Ambos grupos (DDP (A) y Long Island (B)) exhibieron variabilidad en la clasificación de las emociones. dependiendo de las regiones EEG observadas, lo que sugiere que el modelo de clasificación puede estar influenciado por el sesgo de ubicación de la medición en las áreas frontal, parietal, temporal y lóbulos occipitales.

La versión 8 del modelo perfeccionada produjo principalmente distribuciones de clasificación dentro de el rango del 40-50%, con algunos casos en el rango del 30% o del 50-60%, lo que indica la necesidad Para mejorar aún más el rendimiento de la clasificación. Las investigaciones futuras deberían centrarse en análisis detallados de combinaciones de lóbulos específicos, técnicas mejoradas de preprocesamiento de datos, y enfoques híbridos que integran inferencia basada en CNN-LSTM y LLM, que son Se espera que mejore la precisión de la clasificación de emociones basada en EEG.

4.2.5. Conclusiones

En este estudio se aplicó la versión 8 del modelo perfeccionada en un entorno de realidad virtual de 360° para realizar un análisis exploratorio de las respuestas emocionales basadas en EEG en espacios arquitectónicos con Diferentes características espaciales. La comparación entre un entorno altamente artificial (DDP) y un entorno rico en naturaleza (Long Island City) brindaron información sobre cómo los patrones de activación de las regiones cerebrales se correlacionan con los estados emocionales clasificados por el modelo y cómo las áreas urbanas y los entornos naturales provocan respuestas emocionales distintas en cada individuo.

Ampliar el tamaño de la muestra e incorporar diversas condiciones ambientales, métodos avanzados de preprocesamiento de datos y modelos de aprendizaje profundo como CNN-LSTM permitirían

Mejorar la aplicabilidad del análisis de emociones basado en EEG en el diseño arquitectónico y la investigación de la experiencia del usuario.

Es importante destacar que este estudio se realizó con un objetivo exploratorio y no incluyó una validación estadística rigurosa debido al tamaño limitado de la muestra y a las condiciones controladas. Sin embargo, los hallazgos resaltan el potencial del reconocimiento de emociones basado en EEG en entornos de realidad virtual (RV) y demuestran cómo se pueden utilizar modelos de IA optimizados para analizar estados emocionales individuales en entornos construidos, contribuyendo así a futuras investigaciones en arquitectura con conciencia emocional y diseño espacial adaptativo.

5. Conclusiones e investigaciones futuras

Este estudio desarrolló y probó un modelo de IA optimizado que utiliza la arquitectura GPT para analizar estados emocionales a partir de datos de EEG (electroencefalografía). Dado que los modelos GPT se diseñaron originalmente para procesar datos textuales no numéricos, se empleó un proceso de estructuración de datos que incorpora vectorización y mapeo de patrones para gestionar eficazmente las señales de EEG. La integración de los datos de EEG en este marco permitió la clasificación de emociones en tiempo real sin un preprocesamiento exhaustivo, lo que demuestra la viabilidad de la inferencia basada en LLM para la computación afectiva basada en EEG. Estos hallazgos presentan un enfoque novedoso para la aplicación del reconocimiento de emociones basado en IA en entornos arquitectónicos, ofreciendo nuevas posibilidades para configuraciones espaciales adaptativas a las emociones.

Además, este estudio validó la efectividad del reconocimiento de emociones basado en EEG utilizando el conjunto de datos SEED, clasificando con éxito los estados emocionales positivos, neutrales y negativos. Los resultados confirman que las señales de EEG contienen características valiosas para la computación afectiva, contribuyendo a los avances en las interfaces cerebro-computadora (BCI) y la interacción humano-computadora (HCI). Sin embargo, debido al número limitado de participantes, estos hallazgos deben considerarse evidencia preliminar: prueba de concepto para el método propuesto. Las investigaciones futuras deben involucrar un grupo de participantes más grande y diverso, lo que permite una mejor robustez del modelo, generalización y adaptabilidad a las diferencias individuales y variaciones del mundo real.

Más allá de la validación convencional en laboratorio, este estudio también exploró la aplicabilidad del modelo optimizado en entornos arquitectónicos mediante simulaciones de realidad virtual (RV) de 360°. Se simularon espacios arquitectónicos como el Dongdaemun Design Plaza (DDP) de Seúl y el Long Island City de Nueva York para evaluar las respuestas emocionales de los usuarios a diferentes entornos espaciales. Los resultados sugieren que los elementos arquitectónicos, tanto naturales como artificiales, influyen en las emociones del usuario, lo que refuerza la importancia de integrar métricas emocionales en tiempo real en el diseño arquitectónico centrado en el usuario. Estos hallazgos respaldan el desarrollo de configuraciones espaciales que tengan en cuenta las emociones, donde el reconocimiento de emociones basado en EEG proporciona información para entornos adaptativos inteligentes.

Para futuras investigaciones, se buscará una mayor validación del modelo ajustado en contextos arquitectónicos del mundo real. Si bien el conjunto de datos SEED proporcionó una base adecuada, los datos de EEG adicionales recopilados dentro de entornos construidos reales mejorarán el refinamiento del modelo y ampliarán su aplicabilidad. Además, la investigación de arquitecturas de IA alternativas más allá de los modelos basados en GPT, incluidos los marcos híbridos CNN-LSTM y LLM, podría proporcionar conocimientos más profundos sobre las fortalezas y limitaciones comparativas de los diferentes enfoques de reconocimiento de emociones impulsados por IA. Abordar estas áreas corroborará aún más la integración de la computación afectiva basada en EEG con entornos arquitectónicos adaptativos y sensibles a las emociones, lo que contribuirá a la próxima generación de espacios inteligentes centrados en el ser humano.

Contribuciones de los autores: Conceptualización, S.-YJ y H.-JJ; Metodología, S.-YJ; Software, M.-KK; Validación, S.-YJ, M.-KK y H.-JJ; Análisis formal, S.-YJ; Investigación, S.-YJ; Recursos, H.-JJ; Curación de datos, M.-KK; Redacción (preparación del borrador original), S.-YJ; Redacción (revisión y edición).

H.-JJ; Visualización, M.-KK; Supervisión, H.-JJ; Administración del proyecto, H.-JJ; Adquisición de fondos, H.-JJ Todos los autores han leído y aceptado la versión publicada del manuscrito.

Financiación: Este trabajo fue apoyado por una subvención de la Fundación Nacional de Investigación de Corea (NRF) financiada por el gobierno coreano. (2022R1A2C3011796).

Declaración de la Junta de Revisión Institucional: El estudio se llevó a cabo de conformidad con la Declaración de Helsinki y fue aprobado por la Junta de Revisión Institucional (IRB) de la Universidad de Hanyang (N.º de aprobación HYUIRB-202311-026, aprobada el 13 de noviembre de 2023).

Declaración de consentimiento informado: Se obtuvo el consentimiento informado de todos los sujetos involucrados en el estudio.

Declaración de disponibilidad de datos: Los datos presentados en este estudio, incluyendo los datos de EEG y la información biométrica de los participantes, están disponibles previa solicitud al autor correspondiente. Los datos no están disponibles públicamente debido a restricciones de privacidad y éticas. Además, el conjunto de datos SEED utilizado en este estudio fue proporcionado por el Laboratorio BCMI y está sujeto a restricciones de acceso.

Conflictos de intereses: Los autores declaran no tener ningún conflicto de intereses.

Referencias

1. Picard, RW Computación afectiva; MIT Press: Cambridge, MA, EE.UU., 1997.
2. Calvo, RA; D'Mello, S.; Gratch, J.; Kappas, A. El manual de Oxford de computación afectiva; Oxford University Press: Oxford, Reino Unido. 2015.
3. Barrett, LF; Adolphs, R.; Marsella, S.; Martinez, AM; Pollak, SD. Reconsideración de las expresiones emocionales: Desafíos para inferir emociones a partir de los movimientos faciales humanos. *Psychol. Sci. Public Interest* 2019, 20, 1–68. [\[CrossRef\]](#)
4. Koelstra, S.; Muhl, C.; Soleymani, M.; Yazdani, A.; Ebrahimi, T.; Pun, T.; Patras, I. DEAP: Una base de datos para el análisis de emociones mediante señales fisiológicas. *IEEE Trans. Affect. Comput.* 2012, 3, 18–31. [\[CrossRef\]](#)
5. Wang, Y.; Wang, Z.; Zhang, H.; Wang, F. Reconocimiento de emociones con señales de EEG utilizando un modelo CNN-LSTM multiescala. *Brain Sci.* 2021, 11, 373.
6. Schaefer, RS; Farquhar, J.; Blokland, Y.; Sadakata, M.; Desain, P. Adivina la melodía: Decodificando la música a partir de las respuestas cerebrales a las melodías mediante técnicas de aprendizaje automático. *NeuroImage* 2011, 56, 843–849. [\[CrossRef\]](#)
7. Alavi, HS; Churchill, E.; Wiberg, M.; Lalanne, D.; Dalsgaard, P.; Schieck, A.; Rogers, Y. Introducción a la construcción humana Interacción (HBI). *ACM Trans. Comput.-Hum. Interact.* 2019, 26, 1–10. [\[CrossRef\]](#)
8. Liu, Y.; Sourina, O.; Nguyen, MK. Reconocimiento y visualización de emociones humanas mediante EEG en tiempo real. En *Actas de la Conferencia Internacional sobre Cibermundos*, Singapur, 20-22 de octubre de 2010; págs. 262-269.
9. Yang, CY; Lin, YP; Wu, TL. Sistemas de juego basados en EEG para medir las respuestas afectivas durante el juego. *J. Neural Eng.* 2015, 12, 066003.
10. Chao, H.; Zeng, Y.; Zhang, Y.; Li, J.; Xie, L. Una descripción general de la computación afectiva basada en técnicas de EEG tradicionales y emergentes. *Frente. Neurosci.* 2020, 14, 1–14.
11. Spapé, MM; Hoggan, E.; Jacucci, G.; Ravaja, N. El significado del yo virtual: un enfoque multimodal para el usuario afectivo experiencia. *Interact. Comput.* 2015, 27, 349–362.
12. Wang, Y.; He, Y.; Chen, H. Aprendizaje profundo para el reconocimiento de emociones basado en EEG: Una revisión de modelos y características. *Proceso de señal.* 2022, 195, 108474.
13. Mehrabian, A.; Russell, JA Un enfoque a la psicología ambiental; MIT Press: Cambridge, MA, EE. UU., 1974.
14. Zhang, J.; Yin, Z.; Wang, Y.; Nichele, S. Reconocimiento de emociones mediante datos multimodales y técnicas de aprendizaje automático: un tutorial y revisión. *Inf. Fusion* 2020, 59, 103–126. [\[CrossRef\]](#)
15. Mavridis, N. Una revisión de los desarrollos en robótica social: Hacia una arquitectura sociocognitiva. *Int. J. Hum.-Comput. Stud.* 2015, 73, 76–93.
16. Zheng, W.-L.; Lu, B.-L. Investigación de bandas y canales de frecuencia críticos para el reconocimiento de emociones basado en EEG con Deep Redes neuronales. *IEEE Trans. Auton. Ment. Dev.* 2015, 7, 162–175. [\[CrossRef\]](#)
17. Zheng, WL; Zhu, JY; Peng, Y.; Zhang, Y.; Lu, BL. Reconocimiento de emociones basado en EEG mediante regresión lineal dispersa regularizada en grafos. *IEEE Trans. Cogn. Dev. Syst.* 2019, 10, 601–609.
18. Becerik-Gerber, B.; Kensek, K. Modelado de información de construcción en arquitectura, ingeniería y construcción: Nuevas direcciones y tendencias de investigación. *J. Prof. Issues Eng. Educ. Pract.* 2010, 136, 139–147. [\[CrossRef\]](#)
19. Wang, C.; Wu, X.; Wang, X. Espacio arquitectónico y emoción: un estudio de los impactos afectivos de las configuraciones espaciales utilizando Entornos virtuales inmersivos. *J. Environ. Psychol.* 2020, 68, 101406.

20. Lin, YP; Wang, CH; Jung, TP; Wu, TL; Jeng, SK; Duann, JR; Chen, JH. Reconocimiento de emociones basado en EEG al escuchar música: Comparación de esquemas para la clasificación multiclase. *Neural Netw.* 2010, 32, 108–120.
21. Soleymani, M.; Lichtenauer, J.; Pun, T.; Pantic, M. Una base de datos multimodal para el reconocimiento de afectos y el etiquetado implícito. *IEEE Trans. Afecto. Comput.* 2012, 3, 42–55. [\[CrossRef\]](#)
22. Li, X.; Zhang, P.; Song, D.; Yu, G.; Hou, Y.; Hu, B. Reconocimiento de emociones basado en EEG mediante aprendizaje profundo de características no supervisado. *Med. Ingeniería Biológica Computación.* 2018, 56, 233–245.
23. Zou, Y.; Liu, Y.; Song, X.; Wang, J.; Fu, J.; Wang, Y. Un nuevo modelo de extremo a extremo para el reconocimiento de emociones basado en EEG utilizando múltiples escalas. CNN y GRU basado en la atención. *IEEE Trans. Afecto. Comput.* 2022, 13, 307–319.
24. Wang, L.; Nie, D.; Lu, BL. Clasificación del estado emocional a partir de datos de EEG mediante aprendizaje automático. *Neurocomputing* 2014, 129, 94–106. [\[Referencia cruzada\]](#)
25. Vinhas, J.; Teixeira, C.; Postolache, O.; de Oliveira, R. Una revisión sistemática sobre aplicaciones de la interfaz cerebro-máquina basada en EEG para robótica y dispositivos protésicos. *Electrónica* 2021, 10, 566.
26. Huang, D.; Shang, C.; Wang, J.; Wang, W.; Zhang, X. Computación afectiva para la colaboración entre humanos y robots: una visión general. *IEEE Trans. Cogn. Dev. Syst.* 2021, 13, 541–555.
27. Dzedzickis, A.; Kaklauskas, A.; Bucinskas, V. Reconocimiento de emociones humanas: Revisión de sensores y métodos. *Sensors* 2020, 20, 592. [\[Referencia cruzada\]](#)
28. Chai, R.; Ling, SH; Hunter, GP; Tran, Y.; Nguyen, HT Clasificador de interfaz cerebro-computadora para comandos de silla de ruedas utilizando un Enfoque híbrido de inteligencia computacional. *Comput. Intell. Neurosci.* 2017, 2017, 1526525.
29. Gao, X.; Wang, Y.; Chen, X.; Gao, S. Concurso BCI IV: Un conjunto de datos de interfaz cerebro-computadora multimodal. Portada. *Neurosci.* 2020, 14, 322.
30. Lin, FH; Witzel, T.; Ahlfors, SP; Stufflebeam, SM; Belliveau, JW; Hamalainen, MS. Evaluación y mejora de la precisión espacial en la localización de fuentes MEG mediante estimaciones de norma mínima ponderadas por profundidad. *NeuroImage* 2006, 31, 160–171. [\[CrossRef\]](#) [\[PubMed\]](#)
31. Pfurtscheller, G.; Neuper, C. Imágenes motoras y comunicación directa cerebro-computadora. *Proc. IEEE* 2001, 89, 1123–1134. [\[CrossRef\]](#)
32. Blankertz, B.; Lemm, S.; Treder, M.; Haufe, S.; Muller, KR Análisis de ensayo único y clasificación de componentes ERP: un tutorial. *NeuroImage* 2011, 56, 814–825. [\[Referencia cruzada\]](#) [\[PubMed\]](#)
33. Kotsiantis, SB: Una descripción general de las técnicas de clasificación del aprendizaje automático. *Informatica* 2007, 31, 249–268.
34. García, EK; Feldman, A.; McKenzie, G.; Esteva, A. Un estudio sobre técnicas de clasificación en minería de datos. *Expert. Syst. Appl.* 2020, 123, 113–121.
35. Asteris, PG; Gandomi, AH; Armaghani, DJ; Tsoukalas, MZ; Gavriliki, E.; Gerber, G.; Konstantakatos, G.; Skentou, AD; Triantafyllidis, L.; Kotsiou, N.; et al. Justificación genética de los resultados de los pacientes con COVID-19 utilizando DERGA, un novedoso algoritmo codicioso de refinamiento de conjuntos de datos. *J. Cell Mol. Medicina.* 2024, 28, e18105. [\[Referencia cruzada\]](#) [\[PubMed\]](#) [\[PubMed Central\]](#)
36. Asteris, PG; Gavriliki, E.; Campacsis, PN; Gandomi, AH; Armaghani, DJ; Tsoukalas, MZ; Avgerinos, DV; Grigoriadis, S.; Kotsiou, N.; Yannaki, E.; et al. Revelando la naturaleza de las enfermedades cardiovasculares utilizando DERGA, un novedoso algoritmo codicioso de refinamiento de conjuntos de datos. *Ellos. J. Cardiol.* 2024, 412, 132339. [\[Referencia cruzada\]](#) [\[PubMed\]](#)
37. Russell, JA Afecto central y la construcción psicológica de la emoción. *Psychol. Rev.* 2003, 110, 145–172. [\[CrossRef\]](#) [\[PubMed\]](#)
38. He, H.; Wu, D.; Yu, Y.; Babiloni, F.; Jin, J. Aprendizaje por transferencia para interfaces cerebro-computadora: Una alineación de datos del espacio euclidiano Enfoque. *IEEE Trans. Biomed. Eng.* 2019, 67, 399–410. [\[CrossRef\]](#) [\[PubMed\]](#)
39. Makeig, S.; Bell, A. J.; Jung, T. P.; Sejnowski, T. J. Análisis de componentes independientes de datos electroencefalográficos. *Adv. Neural Inf. Proceso. Syst.* 1996, 8, 145–151.
40. Brown, D.; Stevens, C.; Jedlicka, H.; O'Brien, S. Computación afectiva y diseño arquitectónico: Mejorando la experiencia del usuario a través de Reconocimiento de emociones. *Des. Stud.* 2020, 67, 34–50.
41. Pan, X.; Zhang, Y.; Lu, B. La aplicación del reconocimiento de emociones basado en EEG en sistemas de IA centrados en el ser humano. *Neural Netw.* 2021, 143, 120–135.
42. Young, RM; Simon, HA IA y arquitectura: Una perspectiva cognitiva sobre el razonamiento espacial. *Artif. Intell.* 2018, 275, 1–19.
43. Breiman, L. Bosques aleatorios para la clasificación de emociones mediante EEG. *Mach. Learn.* 2001, 45, 5–32. [\[CrossRef\]](#)
44. Kim, J.; André, E. Reconocimiento de emociones basado en cambios fisiológicos al escuchar música. *IEEE Trans. Pattern Anal. Mach. Intell.* 2008, 30, 2067–2083. [\[Referencia cruzada\]](#)
45. Davidson, RJ. Firmas neuronales basadas en EEG de estados afectivos en la interacción humano-computadora. *Neuropsychologia* 2003, 41, 89–98.
46. Picard, RW Detección de emociones en entornos inteligentes. *AI Mag.* 2001, 22, 38–49.

Aviso legal/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son responsabilidad exclusiva de los autores y colaboradores, y no de MDPI ni de sus editores. MDPI y sus editores no se responsabilizan de ningún daño a personas o bienes que resulte de las ideas, métodos, instrucciones o productos mencionados en el contenido.