

## Artículo

# Predicción de preferencias espaciales arquitectónicas mediante EEG Análisis de las emociones: un enfoque CNN-LSTM

Ju Eun Cho , Se Yeon Kang, Yi Yeon Hong y Han Jong Jun 

Facultad de Arquitectura, Universidad de Hanyang, Seúl 04763, República de Corea; kyungy00@hanyang.ac.kr (JEC); seyeon95@hanyang.ac.kr (SYK); su08069@hanyang.ac.kr (YYH)

\* Correspondencia: hanjong@hanyang.ac.kr

**Resumen:** Los elementos arquitectónicos, como las formas, los colores y la iluminación, influyen significativamente en la respuesta emocional de los usuarios a los espacios. Este estudio aborda el reto de **capturar respuestas emocionales** inconscientes y rápidas **mediante un método de electroencefalografía (EEG)** de 32 canales con 40 participantes, quienes **visualizaron múltiples imágenes de espacios arquitectónicos** mientras se registraba su actividad cerebral en tiempo real. El análisis de potenciales relacionados con eventos (ERP), centrado en N100, N200, P300 y el potencial positivo tardío, **confirmó diferencias fiables en las señales neuronales entre los estímulos preferidos y no preferidos**. Se entrenaron **dos modelos de aprendizaje profundo de memoria a corto plazo y largo plazo de redes neuronales convolucionales** con los datos de EEG: uno utilizando todos los segmentos de ERP y el otro centrado en las características de ERP estadísticamente significativas. El primer modelo logró una alta tasa de recuperación, pero una precisión relativamente baja, mientras que el segundo mejoró la exactitud y la precisión a expensas de la recuperación. Estos hallazgos sugieren que las mediciones objetivas en tiempo real de las respuestas emocionales de los usuarios pueden orientar el diseño arquitectónico en las etapas iniciales y reducir la dependencia de evaluaciones subjetivas. Al integrar información basada en EEG en simulaciones de arquitectura inteligente o realidad virtual, los diseñadores pueden optimizar las características de los edificios para alinearlas con las preferencias y el bienestar de los usuarios, contribuyendo así al desarrollo de entornos construidos eficaces y centrados en el usuario.

**Palabras clave:** EEG; potencial relacionado con eventos; memoria a corto y largo plazo de redes neuronales convolucionales; arquitectura afectiva; predicción de preferencias del usuario



Editor académico: Pedro Couto

Recibido: 24 de febrero de 2025

Revisado: 6 de abril de 2025

Aceptado: 7 de abril de 2025

Publicado: 11 de abril de 2025

Cita: Cho, J.E.; Kang, S.Y.; Hong, Y.Y.; Jun, H.J.

Predicción de preferencias espaciales arquitectónicas mediante análisis de emociones basado en EEG: un enfoque CNN-LSTM.

Appl. Sci. 2025, 15, 4217. <https://doi.org/10.3390/app15084217>

Copyright: © 2025 por los autores.

Licenciatario MDPI, Basilea, Suiza.

Este artículo es un artículo de acceso abierto, distribuidos bajo los términos y

Condiciones de Creative Commons

Licencia de atribución (CC BY)

(<https://creativecommons.org/licenses/by/4.0/>).

## 1. Introducción

Pasar períodos prolongados en ambientes interiores puede tener un efecto en la estabilidad emocional, la creatividad y los niveles de estrés de las personas, que dependen en gran medida de los elementos físicos y ambientales de los espacios arquitectónicos [1–4]. Sin embargo, los procesos de diseño tradicionales a menudo se basan en la intuición y los juicios subjetivos para evaluar las posibles experiencias emocionales de los usuarios; por lo tanto, no pueden capturar con precisión los estados emocionales inconscientes e inmediatos [4,5]. Métodos como entrevistas y encuestas comúnmente utilizados en investigaciones anteriores se centran principalmente en las emociones conscientes y expresadas verbalmente, pero no capturan completamente las respuestas afectivas sutiles e instantáneas provocadas por los estímulos espaciales [6,7]. Para superar estos desafíos, se han introducido recientemente enfoques neurocientíficos. En particular, la electroencefalografía (EEG) ofrece alta resolución temporal y capacidades de medición no invasivas, lo que permite la evaluación en tiempo real de los estados afectivos y cognitivos inconscientes de los usuarios [8,9].

Entre las diversas técnicas de análisis de EEG, el análisis de potenciales relacionados con eventos (PRE) es una herramienta precisa y potente para medir las respuestas emocionales inmediatas a estímulos específicos [7,10–12]. Según la investigación neurocientífica, los componentes del PRE N200, P300 y

El potencial positivo tardío (LPP) está estrechamente asociado con la valencia emocional de los estímulos (p. ej., preferencia, positividad o negatividad). Cuando a los usuarios les gusta o les disgusta un estímulo espacial determinado, se pueden observar diferencias mensurables en estos componentes ERP. Además, investigaciones recientes sobre inteligencia artificial muestran que los modelos de memoria a largo plazo (LSTM) de redes neuronales convolucionales (CNN), que capturan tanto las propiedades espaciales como temporales de los datos de EEG, pueden aprender eficazmente patrones neuronales sutiles para mejorar la precisión de la clasificación de emociones [13]. Por lo tanto, nuestra hipótesis es la siguiente: 1. Los patrones de EEG, en particular los componentes ERP (p. ej., N200, P300 y LPP), serán significativos.

No se diferencian significativamente entre estímulos preferidos y no preferidos.

2. Un modelo de aprendizaje profundo entrenado en señales EEG puede detectar eficazmente estas distinciones en los componentes ERP, logrando así una alta precisión en la clasificación de las respuestas afectivas (es decir, preferidas vs. no preferidas) a los espacios arquitectónicos.

Mediante la medición cuantitativa de las experiencias afectivas de los usuarios en entornos arquitectónicos mediante análisis EEG y ERP, e integrando estos hallazgos con técnicas de aprendizaje profundo, proponemos una metodología para el diseño personalizado. Se espera que este enfoque supere las limitaciones de los métodos tradicionales de diseño arquitectónico, a la vez que contribuya a un proceso más científico y objetivo para el diseño arquitectónico afectivo.

Este artículo revisa brevemente la investigación previa sobre las relaciones entre los espacios arquitectónicos, las emociones y las preferencias, y los antecedentes teóricos del análisis de emociones basado en EEG. A continuación, detalla los procedimientos utilizados para preprocesar y analizar los datos de EEG, así como para diseñar y evaluar el modelo. A través de estos pasos, pretendemos establecer un proceso para comprender cuantitativamente las respuestas emocionales de los usuarios a los espacios arquitectónicos y construir un conjunto de datos fundamental para el diseño de espacios personalizados. En última instancia, mostramos el potencial de los enfoques neurofisiológicos en la práctica arquitectónica para incorporar las experiencias de los usuarios de forma más profunda, contribuyendo al desarrollo de la arquitectura afectiva y el diseño de espacios adaptativos en tiempo real.

## 2. Revisión de la literatura

### 2.1. Características físicas de los espacios arquitectónicos y su influencia en las emociones y preferencias

Varios estudios han confirmado que los atributos físicos de un espacio arquitectónico afectan significativamente las respuestas psicológicas y las preferencias espaciales de los usuarios (ver Tabla 1) [14,15].

Con respecto a la forma espacial, las estructuras curvas pueden proporcionar comodidad psicológica y conducir a evaluaciones más positivas, mientras que una sobreabundancia de curvas a veces crea confusión visual o estrés [16-20]. En cuanto a la iluminación, la luz natural tiende a reducir el estrés y fomentar estados emocionales positivos, mejorando así la preferencia, mientras que la iluminación artificial puede provocar una sensación de distancia emocional en ciertos casos [21]. Los techos altos pueden aumentar la apertura y la creatividad, mientras que los techos más bajos pueden mejorar la concentración pero corren el riesgo de inducir una sensación de confinamiento [22]. Otros elementos de diseño, como el color, los materiales y la acústica, también brindan diversas experiencias psicológicas a los usuarios y sirven como factores clave en la configuración de la preferencia espacial general [14]. Por ejemplo, los colores cálidos y los materiales naturales a menudo fomentan la comodidad psicológica y aumentan la preferencia, mientras que los tonos más fríos o los materiales sintéticos pueden crear una sensación de desapego.

Estas respuestas emocionales desencadenadas por diversos elementos físicos tienen un impacto directo en la evaluación de los edificios y actúan, en términos más generales, como un indicador crucial de qué tan bien se puede utilizar o tener éxito un espacio.

Tabla 1. Elementos arquitectónicos clave y sus efectos emocionales y de preferencia.

Elemento arquitectónico	Característica	Efecto emocional	Efecto de preferencia
Forma espacial [15–20]	Curvo	Proporciona estabilidad psicológica	Aumenta la evaluación positiva
	Curvas excesivas	Puede causar estrés	Reduce la preferencia
	Líneas rectas	Transmite una impresión eficiente y organizada.	Preferido en ciertos contextos
Iluminación [21]	Iluminación natural	Alivia el estrés y fomenta emociones positivas.	Aumenta la preferencia
	Iluminación artificial	Puede crear distancia emocional	A veces baja la preferencia
Altura del techo [22]	Techo alto	Genera apertura y creatividad.	Mejora la preferencia de espacio
	Techo bajo	Promueve la concentración	Preferible para ciertas tareas
Color [14,15]	Tonos cálidos	Proporcionar consuelo psicológico	Aumentar la preferencia en general
	Tonos fríos	Transmitir una sensación de distancia	La preferencia depende del contexto
Materiales [14]	Materiales naturales	Impartir calidez y estabilidad	Produce una mayor preferencia
	materiales artificiales	Crear distancia emocional	Tienden a disminuir la preferencia
Sonido [14,22]	Acústica adecuada diseño	Ofrece un ambiente cómodo y estable.	Mejora la experiencia del usuario
	ruido excesivo	Genera sentimientos desagradables	Disminuye la preferencia

Estos estudios se han basado en encuestas subjetivas para evaluar emociones o preferencias. Con respecto al espacio. El enfoque de autoinforme puede verse limitado debido a sesgos cognitivos. o distorsión de la memoria, lo que subraya la necesidad de un enfoque más objetivo y cuantificable para Comprender cómo los entornos arquitectónicos se relacionan con las emociones del usuario.

Para abordar esta limitación, este estudio propone aprovechar el análisis de bioseñales basado en EEG . El EEG captura respuestas neuronales en tiempo real a estímulos arquitectónicos específicos, como Imágenes de espacios o entornos de realidad virtual (RV), cuantificando así las reacciones neurofisiológicas del usuario. Al examinar los componentes de la ERP, se pueden derivar diferencias significativas en las respuestas emocionales. Este enfoque supera algunas de las deficiencias de los métodos tradicionales de evaluación subjetiva y puede ayudar a interpretar sistemáticamente la relación causal entre las respuestas emocionales y las propiedades físicas de los espacios arquitectónicos.

Este estudio pretende contribuir al diseño arquitectónico centrado en el usuario midiendo respuestas emocionales y cognitivas de forma objetiva y cuantitativa a través del EEG, empleándolo para Clasificación de preferencias en contextos arquitectónicos. Un enfoque como este puede integrar eficazmente factores emocionales, a menudo ignorados en los procesos de diseño tradicionales, y, en última instancia, mejorar la satisfacción del usuario y el éxito potencial de un espacio.

2.2. Fundamento teórico del análisis de emociones basado en EEG

“EEG” es un método no invasivo para medir la actividad eléctrica del cerebro en tiempo real. tiempo a través de electrodos colocados en el cuero cabelludo [23]. Ofrece una alta resolución temporal en La escala de milisegundos, capturando procesos emocionales y cognitivos momentáneos. EEG Las señales abarcan múltiples bandas de frecuencia, desde delta (0,5–4 Hz) hasta gamma (30–100 Hz o superior), cada uno reflejando diversos estados cognitivos [24,25]. Debido a estas características, el EEG Se aplica ampliamente en campos como el aprendizaje, la toma de decisiones y el reconocimiento de emociones. Entre los métodos basados en EEG, el análisis ERP se centra en el bloqueo temporal de la señal EEG a la aparición de estímulos específicos, aislando y cuantificando así las respuestas rápidas del cerebro a esos estímulos [26]. Al observar los componentes ERP como N100, N200, P300 y LPP Siguiendo los estímulos espaciales, se puede inferir cuantitativamente cómo los usuarios perciben y evalúan esos estímulos [27].

Los datos de EEG se pueden analizar desde diferentes perspectivas: temporal, frecuencial o espacial. dominio, como se resume en la Tabla 2. Por ejemplo, un análisis del dominio del tiempo es muy adecuado para

Las evaluaciones ERP, mientras que un análisis del dominio de frecuencia utiliza bandas específicas (por ejemplo, alfa y beta) para medir la carga cognitiva o el estado emocional [28–36].

Tabla 2. Principales métodos de análisis de electroencefalografía.

Método Categoría	Descripción	Punto fuerte clave	Aplicaciones típicas
Dominio del tiempo [28–30]	Examen directo de la amplitud de la señal, picos de potenciales relacionados con eventos (ERP) o características estadísticas	Permite una detección intuitiva de cambios en tiempo real (por ejemplo, inicio de ERP)	Análisis ERP, capturando el tiempo de respuesta al estímulo
Dominio de frecuencia [31–36]	Descompone la señal en bandas delta, theta, alfa, beta y gamma.	Facilita la vinculación de bandas de frecuencia específicas a estados cognitivos/emocionales	Monitoreo de la carga de trabajo, la atención, la relajación y la fatiga mental
Dominio del tiempo-frecuencia [37,38]	Combina análisis de tiempo y frecuencia simultáneamente	Identifica la evolución temporal de señales o eventos anormales (por ejemplo, convulsiones)	Seguimiento detallado de las oscilaciones cerebrales en tareas o eventos
Dominio espacial [39,40]	Examina la distribución espacial a través de múltiples electrodos (por ejemplo, frontal y parietal).	Identifica qué regiones del cerebro responden fuertemente a estímulos o tareas específicas	Generación de mapas topográficos, localización de la activación específica de la tarea
Dinámica no lineal [41,42]	Evalúa la complejidad de la señal (por ejemplo, entropía y dimensión fractal)	Útil para descubrir patrones emocionales o cognitivos impredecibles/ sutiles.	Detección avanzada del estrés o estado afectivo
Conectividad funcional [43–45]	Investiga las interacciones interregionales mediante la teoría de grafos o correlaciones.	Aclara cómo múltiples áreas corticales cooperan en condiciones específicas	Comprender la activación de redes a gran escala en las tareas

En el ámbito arquitectónico, el análisis ERP se ha consolidado como una técnica eficaz para cuantificar las respuestas psicológicas a elementos espaciales específicos. Por ejemplo, N100 y N200 reflejan el reconocimiento de estímulos o el grado de cambio atencional, P300 se asocia con emociones positivas y la toma de decisiones, y LPP representa el procesamiento emocional sostenido a lo largo del tiempo. La Tabla 3 resume los principales componentes del ERP, sus rangos temporales típicos , las principales funciones cognitivas y su relevancia para el diseño arquitectónico [46–51].

Tabla 3. Principales componentes potenciales relacionados con eventos.

Componente	Tiempo típico Ventana (ms)	Función cognitiva principal	Relevancia del diseño arquitectónico
N100	~100	Atención inicial, detección de estímulos	Evalúa si los elementos de diseño captan eficazmente la atención [46]
200 nairas	~200	Emoción negativa, detección de conflictos	Ayuda a refinar los diseños para evitar estímulos visuales excesivos o conflictivos [47]
P300	~300	Emoción positiva, toma de decisiones	Evalúa la satisfacción del usuario y la valoración positiva de los aspectos de diseño [48]
Potencial positivo tardío	>400	Respuesta emocional positiva sostenida	Identifica elementos de diseño que mejoran el bienestar/ comodidad prolongados [49]
Onda lenta positiva	>500	Compromiso emocional prolongado	Determina si los elementos emocionalmente significativos mantienen el interés [50]

Dado que la EEG proporciona análisis emocional en tiempo real y datos más objetivos que las mediciones autoinformadas, su potencial se ha reconocido en diversas aplicaciones, como las interacciones persona-computadora y las interfaces cerebro-computadora [52,53]. Por ejemplo, la EEG en entornos de juegos o realidad virtual (RV) puede detectar cambios en tiempo real en el estado del usuario, ajustando las interfaces

o contenido dinámicamente [54–56]. El amplio rango de información de frecuencia (delta a gamma) también permite la interpretación simultánea de diversos estados como estrés, relajación o concentración [24,27,57,58].

Sin embargo, el EEG es sensible al ruido de los parpadeos, las señales electromiográficas y la interferencia eléctrica, y su resolución espacial relativamente baja complica la localización de activaciones localizadas en el cerebro [52,53]. Además, incluso cuando se exponen a estímulos idénticos, los patrones del EEG pueden variar en gran medida entre individuos, lo que dificulta la construcción de modelos generalizados [59]. Para superar estos problemas, se necesitan métodos sofisticados de preprocesamiento como el análisis de componentes independientes o la descomposición de modos empíricos, posiblemente en conjunto con enfoques multimodales (EEG más imágenes por resonancia magnética funcional) y entrenamiento de datos a gran escala utilizando aprendizaje profundo [60,61]. La Tabla 4 resume las principales ventajas y limitaciones del análisis de emociones basado en EEG.

Tabla 4. Ventajas y desventajas del análisis emocional basado en electroencefalografía.

Aspecto	Ventaja	Limitación
Resolución temporal	Medición de la actividad neuronal a nivel de milisegundos	Altamente sensible a artefactos causados por parpadeos, movimientos musculares e interferencias eléctricas.
Resolución espacial	Los electrodos no invasivos para el cuero cabelludo son relativamente fáciles de instalar.	Es difícil localizar con precisión regiones cerebrales más
Objetividad	Menos propensos a sesgos de autoinforme ya que utilizan señales cerebrales directas	profundas. La variabilidad intersujeto puede reducir la generalización.
Aplicación práctica	Monitoreo factible de emociones en tiempo real (por ejemplo, interacción humano-computadora y realidad virtual)	Requiere un preprocesamiento complejo (por ejemplo, análisis de componentes independientes) para garantizar señales limpias.

Recientemente, un número creciente de estudios empíricos en el ámbito arquitectónico han aplicado la EEG. La Tabla 5 presenta ejemplos representativos de esta investigación y sus principales hallazgos.

Tabla 5. Estudios empíricos basados en EEG en el contexto arquitectónico.

Estudio (año)	Tema principal	Configuración de EEG	Conclusión primaria
Li y otros (2020) [62]	Elementos naturales y percepción/satisfacción del usuario	Relación beta en F7, CP2, FC6 y P3	La relación beta está relacionada con el rendimiento en las tareas; los entornos naturales mejoraron la comodidad
Banaei y otros (2017) [19]	Efectos emocionales de los interiores curvos	Corteza cingulada anterior, theta y 128 canales	El diseño curvo provocó una respuesta emocional positiva, aunque relativamente efímera.
Erkan (2018) [63]	La altura del techo y su efecto sobre la cognición y la orientación	F3/F4, Fz (alfa, beta, delta y theta)	Los techos más altos se correlacionaron con una mejor cognición y una actividad beta reducida
Marín-Morales et al. (2019) [64]	Comparación de las respuestas emocionales en entornos virtuales y reales	Nueve canales (alfa, beta, gamma y theta)	La realidad virtual provocó emociones similares a las de entornos reales; se utilizó SVM para la clasificación
Zou y otros (2019) [65]	Elementos de diseño de oficinas y motivación	14 canales	Red neuronal artificial logró una precisión de aproximadamente el 85 % en la clasificación de la experiencia personal
Vaquero-Blasco et al. (2020) [66]	Cromoterapia VR y alivio del estrés	Ocho canales (gamma/alfa y theta)	La realidad virtual produjo un alivio del estrés similar a la terapia real; las ondas gamma sirvieron como biomarcador clave

Tabla 5. Cont.

Estudio (año)	Tema principal	Configuración de EEG	Conclusión primaria
Cruz-Garza et al. (2022) [67]	Tamaño de la habitación y ubicación de las ventanas para efectos cognitivos	Alfa, beta, delta y theta (57 canales)	Las salas más grandes aumentaron la potencia alfa; SVM predijo las respuestas del usuario
Yeom et al. (2021) [68]	Muros verdes interiores para reducir el estrés	Alfa, theta y beta relativos (O, P)	Los muros verdes mitigaron el estrés; los niveles de ondas alfa aumentaron con la relajación
Zou y Ergan (2021) [69]	Satisfacción estética, resiliencia, ansiedad.	Frontal/occipital (14 canales)	El EEG clasifica eficazmente los estados emocionales; el área frontal es fundamental para la evaluación
Kalantari y otros (2022) [70]	Respuestas cognitivas en VR versus espacios reales idénticos	Delta, theta, alfa, beta y gamma	La realidad virtual provocó patrones cognitivos similares a los de entornos reales
Liu et al. (2022) [71]	Influencia del color de la pared en la atención y la memoria	C3, Cz, F3 y Fz (beta, beta alta)	Las aulas de colores fríos aumentaron la excitación, la atención y la memoria.
Kalantari y otros (2021) [72]	Impacto de los elementos de diseño en la señalización vial	Delta-gamma	Las características mejoradas mejoraron la orientación espacial y la participación cognitiva.
Bower y otros (2023) [73]	El tamaño de la habitación y el color en la conectividad cerebral	Theta y gamma (frontal/temporal derecha)	Habitaciones más pequeñas y color azul, patrones de conectividad gamma/theta modificados

Como se muestra en la Tabla 5, la EEG puede medir cuantitativamente las reacciones emocionales y cognitivas de los usuarios en tiempo real, lo que proporciona una interpretación sistemática de cómo los factores de diseño en un entorno arquitectónico afectan la respuesta humana [74]. Cuando se combina con tecnologías de realidad virtual o aumentada, la EEG también facilita experimentos en escenarios de diseño durante las primeras fases de la construcción [64,72]. A pesar de que el campo de la neuroarquitectura se encuentra en una etapa relativamente temprana (lo que requiere tamaños de muestra más grandes y estudios en diversas condiciones ambientales), la integración de la EEG en todo el proceso de diseño puede incorporar eficazmente los factores emocionales del usuario. En última instancia, esto puede hacer avanzar los entornos arquitectónicos que mejoran la calidad de vida [58,75,76].

2.3. Análisis de datos de EEG basado en aprendizaje profundo

El aprendizaje profundo es una técnica de aprendizaje automático basada en redes neuronales artificiales multicapa, modeladas a partir de la estructura del cerebro humano. Destaca en el aprendizaje de patrones de datos complejos y no lineales, y es particularmente eficaz con datos no estructurados como imágenes, audio y series temporales [77]. Dado que el EEG es una señal biológica compleja, el aprendizaje profundo ha cobrado relevancia recientemente por su capacidad para extraer automáticamente características significativas de dichos datos. Los modelos de aprendizaje profundo constan de una capa de entrada, múltiples capas ocultas y una capa de salida, que generalmente se entrenan mediante algoritmos de retropropagación. Optimizadores como el descenso de gradiente estocástico, los momentos adaptativos de gradiente (Adam) y métodos de propagación y regularización de la raíz cuadrada media, como la deserción y la normalización por lotes, se utilizan para evitar el sobreajuste y mejorar la generalización [78,79].

Como se describe en la Tabla 6, las funciones de activación proporcionan transformaciones no lineales que facilitan el aprendizaje de los complejos patrones espaciotemporales en datos de EEG multicanal. La alta resolución temporal y la correlación espacial entre canales del EEG dificultan el análisis [80,81]. A través de su arquitectura en capas, el aprendizaje profundo puede aprender conjuntamente estas características espaciotemporales, posicionando al método como efectivo para el reconocimiento de emociones basado en EEG o la clasificación de estados cognitivos [61,82].

Tabla 6. Tipos y características de las funciones de activación.

Función	Ecuación	Rango de salida	Características	Uso común	Limitaciones
Sigmoideo	$\sigma(x) = \frac{1}{1+e^{-x}}$	(0, 1)	Bueno para clasificación binaria; puede saturar gradientes.	Capa de salida (binaria)	Altamente sensible a los artefactos de parpadeo, movimientos musculares y eléctricos interferencia
Sospechoso	$\tanh(x) = 2\sigma(2x) - 1$	(-1, 1)	Centrado en cero; convergencia más rápida que sigmoide	Capas ocultas	Es difícil localizar con precisión las regiones cerebrales más profundas
Lineal rectificado unidad	$\text{ReLU}(x) = \max(0, x)$	$[0, \infty)$	Cálculo simple, convergencia rápida; puede producir resultados 'muertos' neuronas	Capas ocultas	La variabilidad intersujeto puede reducir la generalización
Máximo suave	$\text{entonces } f \text{ tmax}(x_i) = \frac{y(x_i)}{\sum e^{-x_j}}$	(0, 1) con suma = 1	Normaliza salidas en probabilidades multiclase	Capa de salida (multiclase)	Requiere un preprocesamiento complejo (por ejemplo, análisis de componentes independientes) para garantizar señal

Se aplican diferentes modelos de aprendizaje profundo según las características de los datos y los objetivos analíticos. Las CNN son excelentes para extraer características espaciales en datos de EEG multicanal, pero pueden presentar limitaciones para modelar dependencias temporales. Por el contrario, las redes neuronales recurrentes y variantes como las LSTM son más eficaces para gestionar la continuidad de series temporales, pero pueden resultar computacionalmente costosas [77,83–85]. Las unidades recurrentes con compuertas ofrecen una estructura más simple que las LSTM, lo que reduce la carga computacional, mientras que el modelo de transformador aprovecha el procesamiento paralelo y los mecanismos de atención para el aprendizaje de datos a gran escala, pero exige recursos computacionales considerables [78,86].

Originalmente elogiadas por su rendimiento en el procesamiento de imágenes, las CNN han demostrado un éxito notable en la detección de patrones espaciales en múltiples canales de EEG [87–89]. Las capas convolucionales de una CNN capturan características locales en datos de EEG multicanal, mientras que las capas de agrupamiento reducen las dimensiones espaciales para mitigar el ruido y mejorar la eficiencia computacional [77,88]. Por otro lado, LSTM, una arquitectura especializada de red neuronal recurrente, aborda el desafío de las dependencias a largo plazo en datos de EEG secuenciales [85,90,91]. LSTM mitiga los gradientes de desaparición o explosión mediante la incorporación de puertas de entrada, olvido y salida, lo que la hace especialmente eficaz para el análisis de intervalos ERP o la detección de patrones de EEG irregulares [92–95].

Recientemente, los enfoques híbridos CNN-LSTM, que combinan la capacidad de las CNN para extraer características espaciales con la capacidad de las LSTM para capturar dependencias temporales, han demostrado una precisión y una generalización superiores a las alternativas de un solo modelo [96]. La Tabla 7 compara brevemente los modelos CNN, LSTM y CNN-LSTM, mientras que la Figura 1 visualiza un ejemplo de arquitectura CNN-LSTM [96,97].

Estudios empíricos muestran que los modelos de aprendizaje profundo basados en EEG sobresalen en varias tareas, incluyendo reconocimiento de emociones, clasificación de imágenes motoras, detección de convulsiones y clasificación de etapas del sueño, entre otras [92,99–102]. La Tabla 8 resume estudios clave que lograron una precisión de alrededor del 85–90% o más en estas tareas [91,93,99,103–106]. Los modelos híbridos CNN-LSTM han registrado más del 90% de precisión en reconocimiento de emociones, expandiendo significativamente el potencial de aplicaciones de interfaz cerebro-computadora basadas en EEG [102,107].



Modelo		Característica clave	Ventaja	Limitación
PARES	Neuronal convolucional red (CNN)	Patrón espacial reconocimiento	Eficiente para el espacio datos electroencefalográficos	Temporal limitado aprendizaje de patrones
	Largo corto plazo memoria (LSTM)	Secuencia temporal modelado	Captura a largo plazo dependencias en señales	Computacionalmente caro
	CNN-LSTM	Conjunto espacio-temporal aprendiendo	Alta precisión y generalización	Arquitectura compleja



Estudios empíricos demuestran que los modelos de aprendizaje profundo basados en EEG destacan en diversas tareas,

### 3. Materiales y métodos



3. Materiales y métodos

3.1. Configuración experimental

Se utilizaron datos de EEG para analizar cuantitativamente las preferencias de los usuarios y sus respuestas emocionales a los estímulos arquitectónicos. Se empleó un Enobio 32 (Neuroelectrics, Barcelona, España), un sistema EEG inalámbrico de 32 canales, y el software NIC (NIC v2.1.3.11) para una medición precisa y una recopilación de datos reproducible. La figura 2 muestra el dispositivo de EEG con las posiciones de los canales y la plataforma de software NIC.




Figura 2. Hardware y software: (a) Enobio 32 (dispositivo de electroencefalografía certificado médicamente); (b) la posición del electrodo; y (c) el escritorio NIC.

El Enobio 32 mide de forma no invasiva señales neuronales de alta densidad con una resolución de 24 bits [ 112,113 ]. Admite una frecuencia de muestreo de 500 Hz y cubre bandas de frecuencia de EEG clave.

Admite una frecuencia de muestreo de 500 Hz y cubre bandas de frecuencia de EEG clave (delta, theta, alfa, beta y gamma) [113,114]. La colocación de sus electrodos sigue el estándar internacional 10-20, que incluye las regiones frontal (Fz, F3 y F4), parietal (Pz, P3 y P4), y regiones occipitales, todas ellas estrechamente vinculadas a la emoción y la cognición [7,13,112,115].

El software NIC proporciona visualización de EEG en tiempo real, análisis de tiempo-frecuencia y mapeo de ondas cerebrales en 3D [112,114,116,117]. Los datos se almacenan en múltiples formatos (p. ej., CSV y EDF). Se aplicó un filtro de línea de 60 Hz y un filtro de paso de banda visual de 1 a 50 Hz para minimizar el ruido, centrándose especialmente en las bandas alfa y beta, que son fuertemente emocionalmente asociadas [26,118–120]. Además, la configuración inalámbrica permite moverse con mayor naturalidad, lo que reduce la interferencia de señales externas y la ansiedad del usuario. La configuración permite que los participantes se muevan de forma más natural, lo que reduce la interferencia de señales externas y mejora así la confiabilidad de los datos [112,121].

Para los estímulos arquitectónicos, utilizamos Python 3.9 y la biblioteca de búsqueda de imágenes de Google ("https://ypi.org/project/Google-Images-Search/ (consultado el 25 de enero de 2025)") para recopilar imágenes de 25 estilos arquitectónicos (por ejemplo, donde una imagen arquitectónica [122]). Todas las imágenes tenían una resolución mínima de 1920x1080 píxeles y estaban en color y con un alto contraste para minimizar las discrepancias visuales [123,124].

Cada imagen se presentó en un monitor de aleatorio en un monitor. Durante el experimento, los participantes se sentaron cómodamente y se les indicó que miraran la imagen y que respondieran a la pregunta de preferencia de la imagen (ver Figura 1). Después de ver cada imagen, los participantes indicaron sus respuestas EEG (ERP) y sus respuestas de preferencia (1: me gusta, 2: neutral, 3: no me gusta) a través de una entrada de teclado, que estaba sincronizada con la señal EEG [126].

La sincronización de la respuesta del participante con la señal EEG [127,128]. Esto permite un mapeo preciso entre la sincronización de la respuesta y la señal EEG [127,128]. Esto permite un mapeo preciso entre cada clasificación de preferencia de cada imagen y el patrón de EEG correspondiente. Clasificación de preferencia de la imagen de datos de EEG y eventos y el patrón de EEG correspondiente. Los datos de EEG y eventos fueron almacenados en varios formatos de archivo (.eas, .edf y .nedf), lo que garantiza una amplia compatibilidad con diferentes herramientas analíticas. Los archivos de encabezado contienen los ID de los participantes, la fecha del experimento y... fecha y hora, información del canal e información del evento que coincida con el inicio del estímulo más inicios y respuestas. y respuestas.

3.2. Validación preliminar

del experimento piloto Antes de realizar el experimento principal, realizamos un experimento piloto con ocho estudiantes de arquitectura para verificar la idoneidad de los procedimientos de presentación de estímulos y análisis de datos.

3.2. Experimento piloto

Validación preliminar

Appl. Sci. 2025, 15, x PARA REVISIÓN POR

10 de 33

PARES Antes de realizar el experimento principal, realizamos un experimento piloto con Ocho estudiantes de arquitectura verificaron la idoneidad de los procedimientos de presentación de estímulos y análisis de datos. Los participantes observaron múltiples imágenes arquitectónicas mientras se realizaba el EEG, centrándose en particular en los componentes ERP (N100/N200, P300 y LPP) [129,130]. La figura 3 ilustra ejemplos de patrones de ERP en los canales parietal y occipital, lo que confirma la ex- El diseño experimental fue apropiado para medir las respuestas emocionales. El diseño experimental fue apropiado para medir las respuestas emocionales.




Figura 3. Gráficos de potenciales relacionados con eventos (PRE) para parietal (a) y occipital (b).

A partir del experimento piloto, los canales parietales mostraron amplitudes más negativas (rango N100/N200) y una amplitud positiva sostenida en el rango LPP para 'me gusta' (preferido), lo que indica un procesamiento emocional inicial rápido. Los estímulos desagradables (no preferidos) generaron una mayor amplitud positiva en el rango P300, lo que sugiere un procesamiento cognitivo más lento de los estímulos negativos. Se observaron tendencias similares en los canales occipitales, donde los estímulos preferidos mostraron amplitudes positivas. La amplitud positiva aumentó alrededor de P300. Estas diferencias en el ERP reflejan variaciones en el procesamiento visual y cognitivo desencadenado por el valor emocional de los estímulos. La Tabla 9 resume los resultados observados.

Mariza las características e interpretaciones observadas del ERP para cada tipo de estímulo (agradable, neutral y desagradable). Características e interpretaciones del ERP para cada tipo de estímulo (agradable, neutral y desagradable).

Tabla 9. Respuestas de potenciales relacionados con eventos (PRE) por tipo de estímulo y región cerebral.  
Tabla 9. Respuestas de potenciales relacionados con eventos (PRE) por tipo de estímulo y región cerebral.

Estímulo		Ventana ERP		Amplitud	
Tipo	Estímulo	Ventana ERP	región	Interpretación de la región cerebral	
				Amplitud	Tendencia Interpretación
Como	Positivo temprano	N100/N200	Parietal	Fuente amplitud negativa al estímulo	Refleja una amplitud de reacción neuronal rápida y robusta. Reacción al estímulo inicial. Fuerte amplitud negativa al estímulo inicial.
			Occipital	Estímulo preferido de amplitud negativa fuerte	Denota un procesamiento visual intenso para un estímulo preferido.
			Parietal	Indica mínimo recurso cognitivo	Indica un deterioro cognitivo mínimo.
		P300	Parietal	Baja amplitud positiva	Allo-Baja amplitud positiva asignación de recursos.
			Occipital	Baja amplitud positiva	Sugiere para reducir la carga cognitiva para estímulos positivos.
			Parietal	Amplitud positiva sostenida en: demuestran un mantenimiento prolongado de una respuesta emocional positiva.	Estímulos positivos sostenidos. Demuestra un mantenimiento prolongado de una respuesta emocional positiva.
Como	Positivo tardío	(LPP)	Parietal	Amplitud positiva sostenida en: demuestran un mantenimiento prolongado de una respuesta emocional positiva.	Positiva sostenida. Muestra un refuerzo duradero de un estado emocional favorable.
			Occipital	Amplitud positiva sostenida en: demuestran un mantenimiento prolongado de una respuesta emocional positiva.	Positiva sostenida. Muestra un refuerzo duradero de un estado emocional voraz.
			Parietal	Amplitud negativa débil	Sugiere sólo una respuesta inicial modesta al estímulo sensorial.
Como	Neutro	N100/N200	Occipital	Amplitud negativa débil	Indica una respuesta de nivel inferior en el procesamiento visual temprano.

Tabla 9. Cont.

Tipo de estímulo	Ventana ERP	Región del cerebro	Amplitud Tendencia	Interpretación
Neutral	N100/N200	Parietal	Negativo débil amplitud	Sugiere sólo un modesto inicio respuesta al estímulo sensorial
		Occipital	Negativo débil amplitud	Indica una respuesta de nivel inferior en procesamiento visual temprano
	P300	Parietal	Positivo moderado amplitud	Refleja un compromiso cognitivo limitado
		Occipital	Positivo moderado la amplitud aumenta	Indica moderado procesamiento cognitivo
	LPP	Parietal	Positivo moderado la amplitud aumenta	Representa un nivel moderado de mantenimiento emocional
		Occipital	Positivo moderado la amplitud aumenta	Sugiere un grado moderado de arrastre emocional
Aversión	N100/N200	Parietal	Negativo bajo amplitud	Implica una prioridad reducida en la fase inicial. manejo de estímulos
		Occipital	Negativo bajo amplitud	Sugiere un uso mínimo de recursos en las primeras etapas. procesamiento visual para estímulos desagradables
	P300	Parietal	Alto positivo amplitud	Indica un esfuerzo cognitivo elevado y asignación de recursos para estímulos negativos
		Occipital	Alto positivo la amplitud aumenta	Apunta a una intensificación cognitiva procesamiento de estímulos desfavorables
	LPP	Parietal	amplitud negativa	Muestra una rápida disminución de a reacción emocional negativa
		Occipital	amplitud negativa	Demuestra una reducción o desaparición de un efecto adverso respuesta emocional

Los resultados piloto indican que este protocolo de investigación es realmente adecuado para explorar respuestas emocionales; se obtuvieron patrones de EEG estables [131–134]. Basándose en estos En este estudio, investigamos más a fondo el potencial de predecir las preferencias del usuario y analizamos los elementos arquitectónicos que inducen respuestas afectivas en el experimento principal.

3.3. Diseño y procedimiento del experimento

3.3.1. Participantes

El experimento principal involucró a 40 participantes (20 hombres y 20 mujeres, promedio) Edad: 23,98 años), incluyendo estudiantes y profesionales de arquitectura. Análisis de AG\*Power indicó un tamaño de muestra óptimo de alrededor de 32 a 34, pero se reclutaron 40 participantes para acomodar a los posibles desertores [135–143]. La Tabla 10 resume la distribución por edad de Los participantes. Los criterios de selección tuvieron en cuenta la influencia de los conocimientos arquitectónicos. en la evaluación de la emoción espacial, y los participantes no informaron ningún problema neurológico o psiquiátrico. Condiciones. Todos los participantes tenían una visión normal o corregida a la normalidad y factores de estilo de vida. que podrían afectar las señales del EEG (por ejemplo, consumo excesivo de alcohol/cafeína y tabaquismo) También se controlaron [26,135–139]. Este estudio fue aprobado por la Revisión Institucional. Junta de Revisión Institucional (IRB) de la Universidad de Hanyang (HYUIRB-202504-006), y todos los participantes proporcionaron consentimiento informado por escrito [144].

Tabla 10. Distribución por edad de los participantes.

Rango de edad (años)	Número de participantes
18–20	8
21–30	30
31–35	1
≥36	1
Total	40

3.3.2. Selección y categorización de estímulos

PARA Para evaluar las respuestas neuronales a varios estilos arquitectónicos, inicialmente nos referimos a 25 estilos de diseño distintos propuestos en investigaciones previas [145]. Estos estilos fueron elegidos basado en (1) diversidad (que abarca variaciones culturales, regionales y temporales), (2) comparabilidad (características visualmente distintivas que permiten un análisis comparativo) y (3) popularidad (características visualmente distintivas que permiten el análisis comparativo) y (3) popularidad y reconocimiento. Para cada uno de los 25 estilos, utilizamos la API de Google Imágenes (SerpApi) para rastrear aproximadamente 10 imágenes candidatas por estilo, lo que resultó en un conjunto inicial de 250 imágenes. Para garantizar la consistencia visual y la confiabilidad de los datos EEG, aplicamos lo siguiente:

- Solo se seleccionaron imágenes de alta resolución de al menos 2 megapíxeles para mantener la claridad visual.
- Se estandarizaron el brillo, la luminancia y el contraste para eliminar las imágenes innecesarias.
- Las imágenes se presentaron en un orden aleatorio para mitigar los efectos del aprendizaje.
- Se excluyeron las imágenes duplicadas o de baja calidad para mejorar la confiabilidad de los datos.

Además, cada imagen fue verificada por dos expertos en arquitectura para garantizar que representara con precisión su categoría prevista (por ejemplo, elementos ecológicos visibles para Sostenibilidad, fachadas deterioradas para Estado urbano). Cualquier imagen que no exhibiera claramente los atributos específicos de la categoría o que mostrara contenido irrelevante. Como resultado, finalizamos 100 imágenes (cuatro imágenes por estilo en promedio) para el experimento de EEG. Sin embargo, para mayor claridad, la Figura 4 muestra ocho imágenes representativas de los estilos: Sostenibilidad, Condición urbana, Lujo, Minimalista, Materialidad, Estilo histórico, Decrepito y Moderno y contemporáneo, junto con las características típicas de cada uno. Al cubrir un amplio espectro de atributos estéticos y funcionales, estos estilos pueden servir como una guía de referencia para los usuarios, lo que nos permite hacer EEG de modo para el análisis de EEG basado en EEG.

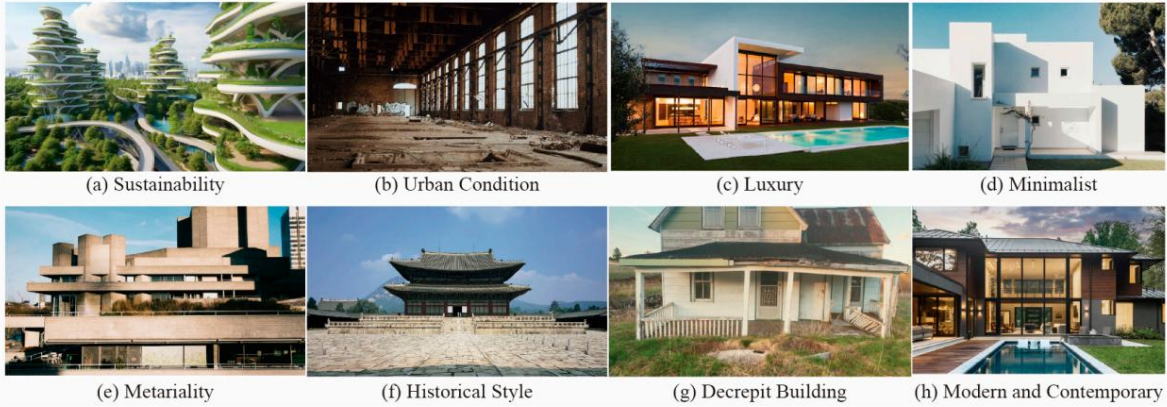


Figura 4. Ejemplos representativos de las ocho categorías de estilos arquitectónicos utilizados como estímulos en el experimento: (a) Sostenibilidad, (b) Condición urbana, (c) Lujo, (d) Minimalista, (e) Materialidad, (f) Estilo histórico, (g) Decrepito, y (h) Moderno y Contemporáneo.

3.3.3. Configuración y entorno experimental

Los experimentos se llevaron a cabo en la Sala 410 del Laboratorio de Diseño Informático del edificio de Ciencia y Tecnología de la Universidad de Hanyang. El espacio del laboratorio mide aproximadamente 7620 × 10430 × 2640 mm. En el centro se colocó una cabina de 800 × 1200 × 2000 mm, con



### 3.3.3. Configuración y entorno experimental

Los experimentos se llevaron a cabo en la Sala 410 del Laboratorio de Diseño Informático en Hanyang.

Edificio de Ciencia y Tecnología de la Universidad. El espacio del laboratorio mide aproximadamente

**7620 × 10.430 × 2640 mm. Se colocó un stand de 800 × 1200 × 2000 mm en el**

centro, con superficies interiores acabadas en película recubierta de aluminio para proporcionar una iluminación uniforme

PARES y bloquear la interferencia electromagnética externa [53,146,147]. El monitor (1920 × 1080 píxeles)

resolución) se colocó a 60 cm de los participantes (Figura 5).




Figura 5. Disposición del espacio experimental: (A) Escritorio de pie; (B) Teclado; (C) Monitor.  
Figura 5. Disposición del espacio experimental: (A) Escritorio de pie; (B) Teclado; (C) Monitor.

### 3.3.4. Procedimiento experimental

#### 3.3.4. Procedimiento experimental

Los participantes se sentaron en un ambiente con control de ruido. Antes del experimento,

A los participantes se les instruyó en el siguiente ambiente con ruido controlado. Antes del experimento,

A los participantes se les indicó los siguientes efectos del EEG.

- Evite el movimiento excesivo para minimizar los artefactos EEG.
- Mantenga una fijación visual en la pantalla durante la presentación del estímulo.
- Mantenga la mirada fija en la pantalla durante la presentación del estímulo.
- Califique cada imagen según su respuesta emocional intuitiva.

Para establecer la actividad cerebral basal en estado de reposo, los participantes primero miraron fijamente un objeto negro.

Para establecer la actividad cerebral basal en estado de reposo, los participantes primero observaron una pantalla negra durante 60 segundos mientras se registraban las señales de EEG. Posteriormente, se obtuvieron imágenes arquitectónicas. La pantalla se mantuvo durante 60 s mientras se registraban las señales de EEG. Posteriormente, se presentaron secuencialmente imágenes arquitectónicas y se registraron continuamente las respuestas del EEG. Cada prueba...

Se presentaron secuencialmente y las respuestas del EEG se registraron continuamente. Cada ensayo se desarrolló de la siguiente manera (véase la Figura 6):

Se procedió de la siguiente manera (ver

Figura 6): 1. Presentación del estímulo (t = 0): se presentó una imagen arquitectónica durante 5 s.

1. Presentación de estímulo (t = 0): se presentó una imagen arquitectónica durante 5 s.

2. Los participantes calificaron la imagen usando un teclado, seleccionando una de tres opciones (1: me gusta; 2: neutral; 3: no me gusta).

2: neutral; 3: no me gusta).

3. Se introdujo un intervalo de 2 s entre cada estímulo para evitar efectos de arrastre neuronal.

3. Se introdujo un intervalo de 2 s entre cada estímulo para evitar la transferencia neuronal. 4. La secuencia de prueba se

repetió 100 veces durante una duración total de aproximadamente 12 min.

Los datos del EEG se almacenaron en varios formatos (.easy, .edf, .nedf e .info). Archivos de eventos.

4. La secuencia de prueba se repetió 100 veces durante una duración total de aproximadamente 12. Se registro

la marca de tiempo para la presentación de la imagen, las entradas de respuesta y el código de preferencia.

(es decir, 1: me gusta, 2: neutral y 3: no me gusta).

Los datos del EEG se almacenaron en varios formatos (.easy, .edf, .nedf e .info). Los archivos de eventos

registraron la marca de tiempo de la presentación de la imagen, las entradas de respuesta y el código de

preferencia (es decir, 1: me gusta, 2: neutral y 3: no me gusta).

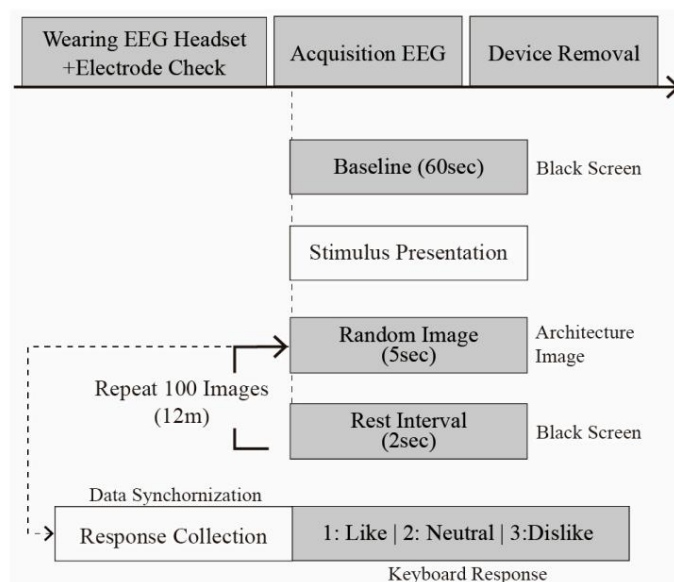


Figura 6. Procedimiento experimental y estructura del ensayo.

Figura 6. Procedimiento experimental y estructura del ensayo.

Figura 6. Procedimiento experimental y estructura del ensayo.

#### 4. Análisis de datos y desarrollo de modelos 4. Análisis de

## datos y desarrollo de modelos

#### 4. Análisis de datos y desarrollo de modelos 4.1

#### EEG 4.1. Preprocesamiento de datos de EEG

4.1. Preprocesamiento de datos de EEG. Para mejorar la calidad de la señal y garantizar un análisis preciso, realizamos un preprocesamiento de datos de EEG de varios pasos. Para mejorar la calidad de la señal y garantizar un análisis preciso, realizamos un preprocesamiento de datos de EEG de varios pasos.

preprocesamiento de varios pasos en los datos de EEG [148, 149]. Esto incluye (1) filtrado y eliminación de artefactos. del conjunto de datos de eliminación. (2) clasificación de canales y re-espaciado y (3) normalización de la potencia. (2) construcción de canal y re-referenciación, y (3) construcción del conjunto de datos final, como

Figura 7. eliminación de redundancia y re-referenciación, y (3) construcción del conjunto de datos final, como se muestra en la Figura 7.

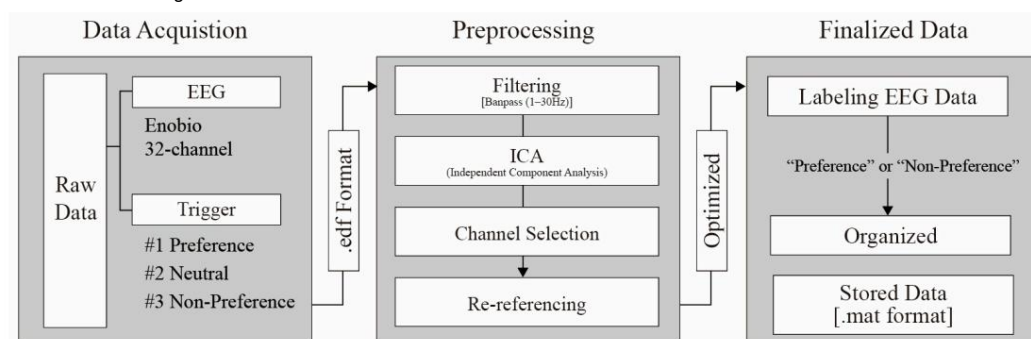


Figura 7. Proceso de preprocesamiento de datos de electroencefalografía (EEG).

Figura 7. Proceso de preprocesamiento de datos de electroencefalografía (EEG).

Figura 7. Proceso de preprocesamiento de datos de electroencefalografía (EEG)

El conjunto de datos inicial comprendía 4000 ensayos de EEG recopilados de 40 participantes, cada uno de los cuales realizó 100 imágenes arquitectónicas. Las señales de EEG se registraron en un muestreo

El conjunto de veintidós imágenes de 100 ms de duración de las EEGs se colocó en 40 registradores, y se reprodujo a 500 Hz utilizando el sistema de 10-20 electrodos, con un enfoque en el parietal (Pz, P3 y P4). Cada participante escuchó 100 imágenes de 500 Hz colocadas en silencio a 55 dB GS20 en los audífonos, con especial atención a las regiones parietal (P4) y occipital (Oz, O1 y O2). Cada prueba incluyó una línea base de 1 s (~200 mV). Frecuencia de pulso: 100 Hz (1 ms) y sistema de 10-20 electrodos en la cabeza (en las regiones parietal (Pz, P3 y P4) de estímulo: frecuencia de 5 s (0-5 s).

regiones occipitales ( $0.05 \leq p \leq 0.02$ ). Cada una ventana de respuesta a estímulo de 200 ms. En primer lugar, aplicamos un filtro de paso de banda de 1-30 Hz para preservar las bandas de frecuencia en particular, a 0 ms) seguido de una ventana de respuesta al estímulo de 50 ms. En primer lugar, aplicamos un filtro de paso de banda de 1-30 Hz para preservar las bandas de frecuencia particularmente relevantes para el procesamiento emocional y cognitivo (en particular, alfa [8-12 Hz] y beta).

[illegible]

H<sub>z</sub>), mientras se elimina el Primer orden de impulsos de impulsos finitos (orden = 2048, ventana de Hamming) para pasar la banda de las señales de EEG dentro del rango de 1 a 30 Hz. Esto tenía como objetivo preservar la

Primero se aplicó el filtro de paso bajo de 30 Hz a 300 Hz, para eliminar el ruido de baja frecuencia más relevantes para el procesamiento emocional y cognitivo, es decir, la alfa. En las señales de EEG de la banda de 30 Hz a 300 Hz, el ruido cognitivo, objetivo, las bandas  $\beta$  ( $\beta$  de 12 a 30 Hz), mientras se atenúa el ruido de baja frecuencia.

bandas de frecuencia (2-38 Hz) y en las que se aplicó un filtro de muesca Butterworth de cuarto orden en (8-12 Hz) y bandas beta (12-30 Hz), al tiempo que atenúa el ruido de baja y alta frecuencia.

A continuación, realizamos un análisis de componentes independiente para identificar y eliminar Artefactos fisiológicos como parpadeos, movimientos musculares y señales cardíacas. A continuación, Se utilizó la función 'pop\_runica' en la caja de herramientas EEGLAB para aplicar el infomax extendido algoritmo ('extendido', 1), con parámetros EEGLAB predeterminados que incluyen una iteración máxima recuento de 512 y una tasa de aprendizaje inicial de 0,001 [116,152].

Tras la descomposición del análisis de componentes independientes, el complemento ICLabel Se utilizó para clasificar automáticamente cada componente independiente en categorías como «Cerebro», «Ojo» y «Músculo». Componentes con una probabilidad de 0,9 o superior en el «ojo». o las categorías "musculares" se marcaron para su eliminación. Este criterio se implementó utilizando la función 'pop\_icflag', con el umbral establecido como [NaN NaN; 0.9 1; 0.9 1; NaN NaN; ... ], asegurando la preservación de las señales neuronales mientras se eliminan selectivamente los artefactos relacionados. componentes.

En nuestro análisis, nos centramos en el parietal (Pz, P3 y P4) y el occipital (por ejemplo, Oz y O2). Los canales parietales están estrechamente vinculados con la cognición espacial, la atención y la emoción. procesamiento, particularmente útil para examinar P300, mientras que los canales occipitales son fundamentales para procesamiento de información visual [26,153–155].

Luego aplicamos una referencia promedio común en todos los canales para reducir la varianza y Mejorar la consistencia del conjunto de datos [156–158]. Esto resultó en una mejor interpretabilidad en ERP. análisis [158–160].

Realizamos una referencia promedio común restando la señal promedio en Todos los canales de cada canal individual. Este método reduce el modo común. el ruido se comparte entre los electrodos y mitiga el sesgo de referencia entre canales [161,162]. En concreto, la referencia promedio común suprime fluctuaciones globales innecesarias (por ejemplo, ruido no neuronal distribuido uniformemente entre los electrodos), mejorando así las diferencias relativas entre canales y la interpretabilidad del ERP y otros análisis de señales.

Los datos de EEG se registran originalmente con un electrodo de referencia inicial (normalmente representado como un canal lleno de ceros). Al incluir este canal de referencia inicial en el promedio proceso y posteriormente eliminarlo después de volver a referenciarlo, el estado de rango completo de los datos Se puede conservar. Este procedimiento es coherente con las recomendaciones del proceso de preprocesamiento de Makoto y el tutorial de EEGLAB, y es crucial para prevenir la deficiencia de rango. cuestiones como la generación de componentes independientes fantasma [156,163,164].

Después del preprocesamiento, se pueden detectar artefactos como el ruido inducido por el movimiento y la visión excesiva Se eliminaron los parpadeos, lo que resultó en 3200 pruebas utilizables (tasa de retención del 80%). Luego segmentamos las señales de EEG en épocas de 5 segundos correspondientes a cada estímulo y las etiquetaron como “preferencia” (preferido), “neutral” o “no preferencia” (no me gusta) antes de guardar los datos en el formato MATLAB (.mat).

Dado que nuestro enfoque principal era diferenciar respuestas de preferencia claras, los ensayos Los datos etiquetados como "neutrales" se excluyeron del conjunto de datos final, lo que garantiza una clasificación equilibrada entre las categorías de preferencia y no preferencia. La Tabla 11 resume los datos finales. configuración del conjunto de datos.

Tabla 11. El conjunto de datos final.

Tipo de datos	No. Canales Intervalo de tiempo		No. Estímulos
Ensayos de electroencefalografía en bruto	10	5 segundos	4000
Eliminación posterior de artefactos	10	5 segundos	3200
Datos de preferencia	10	5 segundos	1121
Datos sin preferencia	10	5 segundos	814





4.2.2. Componentes ERP (N100, N200, P300, LPP)

Utilizamos EEGLAB y FastICA de MATLAB R2024b para el preprocesamiento, analizando ventanas desde  $-0,2$  s antes del inicio del estímulo hasta  $1,0$  s después [26,169]. Este intervalo abarca Respuestas sensoriales tempranas (N100 y N200), asignación de recursos (P300) y procesamiento emocional sostenido (LPP). Para reducir el ruido, aplicamos un filtro de media móvil de 40 puntos. En la Tabla 13 se describe el rango de tiempo típico de cada componente de ERP.

Tabla 13. Ventanas de análisis de componentes potenciales relacionados con eventos.

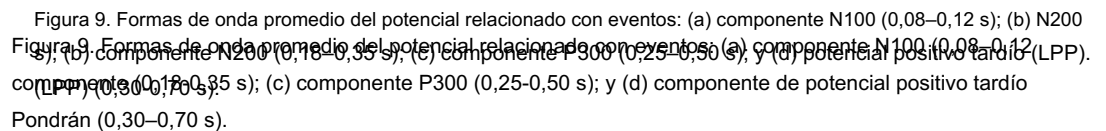
Componente	Ventana(s) de tiempo	Dominio clave	Significado
N100	0,08–0,12	Etapa sensorial temprana	Perceptual inmediato
			respuesta
200 nairas	0,18–0,35	Atención cambio/desajuste detección	La reasignación de recursos para estímulos inesperados
P300	0,25–0,50	Evaluación cognitiva	Asignación importancia para los estímulos
Positivo tardío potencial	0,30–0,70	Emocional mantenimiento	Emocional sostenido procesamiento o valencia

La figura 9 muestra las formas de onda promedio para cada componente ERP, derivadas de la Señales EEG registradas por el parietal (Pz, P3 y P4) y el occipital (Oz, O1 y O2) Electrodo. Estas formas de onda ilustran las respuestas neuronales en condiciones de preferencia y de no preferencia. En concreto, los siguientes puntos resumen las características principales. y las implicaciones de la forma de onda de cada componente ERP:

- N100 (80–120 ms): después del inicio del estímulo, los estímulos preferidos muestran una respuesta negativa inicial. deflexión (N100) seguida de un rebote positivo, lo que indica una mayor sensibilidad atención, mientras que los estímulos no preferidos muestran una amplitud negativa más estable (ver Figura 9a).
- N200 (180–350 ms): los estímulos preferidos muestran una transición aguda de positivo a negativo, lo que sugiere un fuerte reconocimiento de los estímulos relevantes, mientras que los estímulos no preferidos muestran una amplitud negativa retardada, que indica detección de desajuste (ver Figura 9b).
- P300 (250–500 ms): para estímulos preferidos, un pico positivo robusto alrededor de 300 ms refleja el procesamiento de estímulos significativos, mientras que los estímulos no preferidos muestran una desviación positiva seguida de un desplazamiento negativo (ver Figura 9c).
- LPP (300–700 ms): los estímulos preferidos mantienen una amplitud positiva continua, lo que significa un alto compromiso emocional, mientras que los estímulos no preferidos permanecen en una amplitud negativa. nivel, lo que indica un procesamiento emocional más débil (ver Figura 9d).

En conjunto, estos resultados muestran que los estímulos preferidos provocan respuestas más fuertes en todos los grupos. procesamiento sensorial temprano, asignación de recursos y evaluación emocional, mientras que los estímulos no preferidos provocan respuestas relativamente más débiles y, a veces, tardías. Esto confirma que las imágenes arquitectónicas pueden diferenciar de manera confiable las emociones del usuario a nivel neuronal, ofreciendo Perspectivas cruciales para el entrenamiento de modelos futuros y el diseño afectivo.

Para examinar si los ERP se generaron en respuesta a estímulos arquitectónicos, se emparejaron Se realizaron pruebas t con datos recopilados de 40 participantes, centrándose en los componentes del ERP: N100, N200, P300 y LPP. Los resultados revelaron diferencias estadísticamente significativas. entre condiciones preferidas y no preferidas en los primeros componentes del ERP (N100 y N200). Estos hallazgos sugieren que las respuestas atencionales tempranas y la detección de aversividad Los estímulos pueden variar dependiendo del tipo de espacio arquitectónico presentado.



Por el contrario, no se observaron diferencias significativas en los componentes ERP posteriores. (P300 y LRP) posiblemente debido a diferencias relativamente leve en la dosis de los compuestos en la calidad (P300 y LRP). Es posible también debido que la duración relativamente corta del estímulo tal que puede reducir la habilidad. Estos resultados indican la necesidad de experimentales. Estudios futuros que pueden prolongar la exposición a estímulos que los factores ambientales radicales. Estudios futuros que pueden mejorar las respuestas ERP tales hallazgos indican que los estímulos arquitectónicos pueden evocar diferencias significativas en de la respuesta ERP tempranos del ERP, lo que sugiere su utilidad potencial como indicadores neuronales

En resumen, los hallazgos indican que los estímulos arquitectónicos pueden evocar diferencias significativas en el procesamiento temprano ERP, tanto de los aspectos visuales como emocionales del entorno arquitectónico. El procesamiento cognitivo inicial de los aspectos visuales y emocionales del entorno arquitectónico.

Para predecir las respuestas emocionales a las imágenes arquitectónicas, construimos un híbrido CNN-LSTM. El modelo CNN extrae características espaciales mediante capas convolucionales 2D y aprende dependencias temporales mediante capas LSTM. La Tabla 14 describe los hiperparámetros y sus funciones. El modelo LSTM extrae características espaciales a través de capas convolucionales 2D y el resultado final de la capa LSTM tenía una dimensión de estado oculto de 40, que era a través de una capa completamente conectada, lo que conduce a la etapa final de clasificación. La capa de clasificación y las funciones de los componentes CNN y LSTM constaban de dos neuronas de salida con una función de activación Softmax, diseñadas.

Tabla 14. Configuración de la memoria a largo plazo de la red neuronal convolucional.

Para abordar la cuestión del desequilibrio de clases, se empleó la pérdida focal ( $\alpha = 0,25$ ,  $\gamma = 2,0$ ) como medida de pérdida. Descripción del valor Función del parámetro y se utilizó el Adam con una tasa de aprendizaje de 0,000203.

Modelo	optimizador	Descripción del valor	Función del parámetro y se utilizó el
Convolucional	Filtros de convolución	50 (Conv1), 100 (Conv2)	50 filtros en la primera capa convolucional y 100 filtros en la segunda capa para la extracción de características espaciales
red neuronal	(CNN)	Tamaño del kernel	Define el tamaño del campo receptivo de cada filtro.
		3 × 3	Los tamaños más pequeños permiten un aprendizaje más preciso de las características espaciales.

Tabla 14. Configuración de la memoria a largo plazo de la red neuronal convolucional.

Modelo	Parámetro	Valor	Descripción
Neuronal convolucional red (CNN)	Filtros de convolución	50 (Conv1), 100 (Conv2)	50 filtros en la primera capa convolucional y 100 filtros en la segunda capa para extracción de características espaciales
	Tamaño del kernel	3 × 3	Define el tamaño del campo receptivo de cada uno. Los tamaños más pequeños permiten un filtrado espacial más preciso.
	Función de activación	Unidad lineal rectificada	Añade no linealidad al modelo, lo que permite aprender funciones complejas de manera efectiva
	Unidad lineal rectificada	Normaliza la salida de cada capa efectiva Normalización por lotes aplicada para mejorar la estabilidad y velocidad del entrenamiento	Agrega no linealidad al modelo, lo que le permite Función de activación
	Normalización por lotes	Aplicado	Normaliza la salida de cada capa para im- Especifica el tamaño del filtro para la agrupación máxima, reduciendo la pérdida de información crítica.
	Tamaño de la agrupación	2 × 2	Demstrar estabilidad y velocidad de entrenamiento reduciendo las dimensiones espaciales mientras se conserva la crítica. Establece el tamaño del paso del filtro de agrupación, reduce la carga computacional
	Tamaño de la agrupación	2 × 2	ing dimensiones espaciales mientras se conserva la crítica. Establece el tamaño del paso del filtro de agrupación, reduce la carga computacional
	Pasos	2	Establece el tamaño de la salida del filtro de agrupación en el LSTM
	Unidades	40	El número de neuronas en la capa LSTM, que define la dimensionalidad de la salida
	Unidades	40	Mantiene la secuencia de salidas para pasar (por ejemplo, atención)
Memoria a corto plazo a largo plazo (LSTM)	Secuencias de retorno	Verdadero	Mantiene la secuencia de salidas para pasar (por ejemplo, atención)
Memoria a largo plazo (MLPA)	Activación	Activación	Funciones de compuerta integradas (sig-Funciones internas en el LSTM para la gestión y actualización de estados de celda
	Forma de entrada	(input_shape[0] // 4, (en- Dimensiones de los datos secuenciales (forma_de_entrada[1] // 4) × conv_fil- conv_filters × 2)	Funciones internas en el LSTM para gestión y actualización de estados de celda
	Forma de entrada	put_shape[1] // 4) × conv_fil- conv_filters × 2)	Funciones internas en el LSTM para gestión y actualización de estados de celda
	Optimizador	Momentos adaptativos de Momentos adaptativos de gradiente Algoritmo de optimización para entrenamiento; ajusta los pesos para minimizar la pérdida (tasa de aprendizaje = 0,000203) pesos para minimizar la tasa de pérdida = 0,000203)	Algoritmo de optimización para entrenamiento; ajusta los pesos para minimizar la pérdida

La figura 10 representa visualmente la arquitectura del modelo CNN-LSTM. La figura 10 representa visualmente la arquitectura del modelo CNN-LSTM.

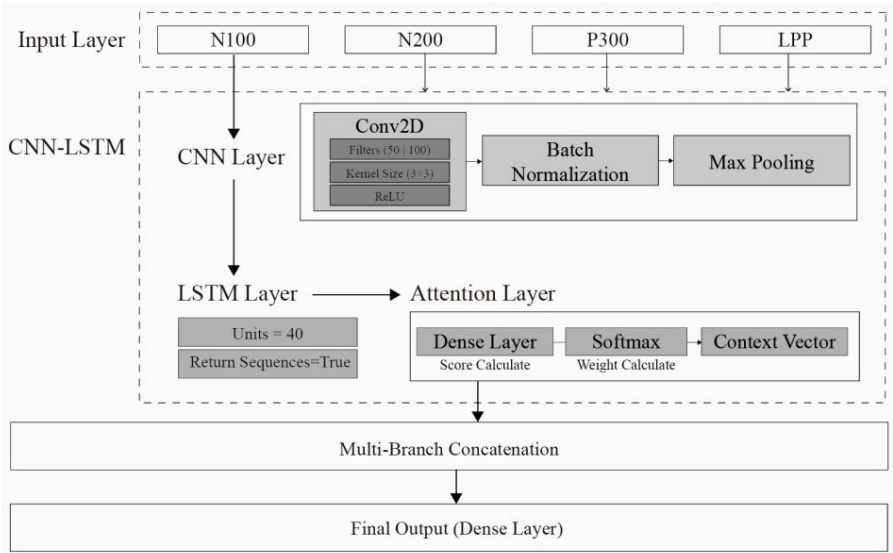


Figura 10. Diagrama de estructura del modelo de memoria a largo plazo de una red neuronal convolucional (CNN-LSTM). Figura 10. Diagrama de estructura del modelo de memoria a largo plazo de una red neuronal convolucional (CNN-LSTM).

La salida final de la capa LSTM tenía una dimensión de estado oculto de 40, que se pasó a través de una capa completamente conectada, lo que condujo a la etapa final de clasificación. La capa de clasificación consistió en dos neuronas de salida con una función de activación Softmax, diseñada para calcular las probabilidades de las dos clases objetivo: preferencial y no preferencial.

Utilizamos Optuna para optimizar hiperparámetros clave como el número de unidades LSTM, el número de filtros CNN, la tasa de abandono, la tasa de aprendizaje y el tamaño del lote. Tras 50 ensayos, la combinación óptima se muestra en la Tabla 15.

Tabla 15. La mejor configuración de hiperparámetros de prueba.

Largo Corto plazo Unidades de memoria	Filtros Conv1	Filtros Conv2	Aprendiendo Tasa	Validación Pérdida	Puntuación de F1
40	50	100	0,000203692	0,849423917	0,849423917

Al incorporar la pérdida focal, el modelo enfatizó la contribución de muestras difíciles de clasificar (p. ej., estímulos no preferidos) al asignarles mayores valores de pérdida . El entrenamiento se realizó con un tamaño de minilote de 16 en un total de 30 épocas. Se aplicó una detención temprana para finalizar el entrenamiento cuando la pérdida de validación no mejoraba en un número predefinido de iteraciones, evitando así el sobreajuste y mejorando la generalización.

Para abordar el desequilibrio de datos entre las clases con preferencia (positiva) y sin preferencia (negativa) , aplicamos la pérdida focal, que prioriza las muestras complejas. Utilizamos  $\alpha = 0,25$  y  $\gamma = 2,0$ . Tras 30 épocas de entrenamiento, las métricas de rendimiento del modelo fueron las siguientes:

- Recordatorio: 98,76 % (muy alto, rara vez se omiten casos positivos o de preferencia);
- Precisión: 72,11 % (relativamente baja; algunos casos sin preferencia se clasifican erróneamente como preferencia);
- Puntuación F1: 83,36 %;
- Precisión: 77,09 %.

Aunque la precisión fue algo modesta, la recuperación excepcionalmente alta del modelo podría ser ventajosa para aplicaciones de monitoreo de emociones en tiempo real.

4.4. Modelo 2: CNN-LSTM con características significativas (prueba t)

El segundo modelo se centra en extraer únicamente las características de los intervalos ERP (p. ej., N100, N200, P300 y LPP) que muestran diferencias estadísticamente significativas entre los estímulos preferenciales y no preferenciales. Al eliminar el ruido y la información superflua, alimentamos únicamente las variables clave (p. ej., amplitud media, pico, área bajo la curva y latencia máxima) que contribuyen directamente a distinguir las respuestas emocionales, con el objetivo de mejorar el rendimiento y la eficiencia del aprendizaje.

En primer lugar, realizamos pruebas t en cada intervalo ERP para determinar qué variables exhibieron diferencias significativas entre los estímulos preferidos y no preferidos ( $p < 0,05$ ) (Tabla 16). La Tabla 17 resume los resultados de la prueba t por electrodo, y la Tabla 18 enumera las combinaciones finales de canal y característica elegidas en función de la significancia estadística y la relevancia neurocientífica.

Estas características seleccionadas fueron procesadas por una capa CNN (Conv1D) para capturar imágenes parciales. patrones espaciales, seguidos de una capa LSTM para la dependencia temporal (Tabla 19).

También empleamos SMOTEENN para abordar el desequilibrio entre las clases minoritarias (no preferidas muestras) combinando un sobremuestreo de casos desafiantes con filtrado de ruido.

La capa de clasificación final, consistente con el Modelo 1, consistió en dos neuronas de salida con una función de activación Softmax para la clasificación binaria entre preferencia y no preferencia. El modelo se entrenó utilizando pérdida focal y el optimizador Adam.

Tabla 16. Definiciones de características de potencial relacionado con eventos (ERP) fusionadas e importancia específica del segmento.

Segmento ERP	Característica	Definición e importancia
N100	Significar	El valor promedio de la señal en el segmento ERP, que refleja la intensidad de respuesta de referencia a un estímulo. Los valores medios más altos indican estímulos emocionales más fuertes, lo que ayuda a evaluación de las respuestas sensoriales iniciales
	Cima	La mayor amplitud en el segmento ERP, reflejando la situación emocional o Intensidad atencional. Los valores máximos más altos para N100 indican respuestas iniciales más fuertes. útil para evaluar la intensidad de la respuesta
	Área bajo la curva (AUC)	Intensidad acumulada de la respuesta a lo largo del tiempo dentro de la ventana ERP. En N100, evalúa la duración de las respuestas neuronales tempranas, capturando las reacciones iniciales a estímulos emocionales
200 nairas	Significar	La amplitud promedio del ERP refleja la intensidad de la respuesta basal. En N200, indica un cambio de atención o detección de desajuste, clave para identificar estímulos que causan conflicto cognitivo
	AUC	Representa el procesamiento cognitivo sostenido a lo largo del tiempo. Para N200, evalúa la fuerza. y la duración de la respuesta de un individuo a estímulos en conflicto o que requieren mayor atención
P300	Latencia máxima	El tiempo desde el inicio del estímulo hasta la amplitud máxima. Para P300, las latencias más cortas implican una mayor relevancia emocional y una evaluación cognitiva más sólida de la importancia del estímulo
	AUC	La amplitud total en la ventana P300. Refleja la cantidad de recursos cognitivos disponibles. asignado, destacando el compromiso sostenido con un estímulo importante
Positivo tardío potencial (LPP)	Latencia máxima	El tiempo que tarda en alcanzar la amplitud máxima dentro de la ventana LPP. Se utiliza para medir la Velocidad de respuesta emocional, lo que ayuda a aclarar las evaluaciones emocionales tempranas.
	AUC	Amplitud acumulada desde el inicio del estímulo hasta el período LPP, que indica cómo cuánto tiempo y con qué intensidad se mantiene el procesamiento emocional a lo largo del tiempo

Tabla 17. Canales y características significativos de los resultados de la prueba t.

Canal	Relacionado con el evento Segmento potencial	Característica	estadística t	valor p
FP1	N100	Significar	−2.468	0.0137
FP1	N100	Cima	−2.487	0.0130
FP1	N100	Área bajo la curva (AUC)	−2.470	0.0136
FP1	200 nairas	Significar	−2.444	0.0146
FP1	200 nairas	AUC	−2.444	0.0146
F3	P300	Latencia máxima	−2.275	0.0230
F3	LPP	Latencia máxima	−2.334	0.0197
F8	N100	Diferencia	−2.051	0.0404
Fz	P300	Diferencia	−2.238	0.0253
Onz	N100	Significar	2.163	0.0307
Onz	N100	Cima	2.136	0.0328
Onz	N100	AUC	2.165	0.0305
Onz	200 nairas	Latencia máxima	−2.656	0.0080
O2	P300	Significar	−2.422	0.0155
O2	P300	AUC	−2.423	0.0155
O2	LPP	Significar	−2.713	0.0067
O2	LPP	Cima	−2.288	0.0222
O2	LPP	AUC	−2.712	0.0067

Tabla 18. Canales y características seleccionados por segmentos potenciales relacionados con eventos.

Canal	Canal Nombre	Segmento ERP	Características
0	FP1	N100	Media, pico, área bajo la curva (AUC)
0	FP1	200 nairas	Media, pico, AUC
1	FP2	N100	Media, pico, AUC
1	FP2	200 nairas	Media, pico, AUC
2	F3	P300	Latencia máxima, AUC
2	F3	Potencial positivo tardío (LPP)	Latencia máxima, AUC
3	F4	P300	Latencia máxima, AUC
3	F4	LPP	Latencia máxima, AUC
6	Fz	P300	Latencia máxima, AUC
6	Fz	LPP	Latencia máxima, AUC
9	O2	P300	Latencia máxima, AUC
9	O2	LPP	Latencia máxima, AUC

Tabla 19. Configuraciones de red neuronal convolucional integrada (CNN) y memoria a corto plazo (LSTM).

Modelo	Parámetro	Valor	Descripción
CNN	Filtros	64	Número de filtros para espacio extracción de características
	Tamaño del kernel	3 × 3	Define el tamaño de la ventana de convolución
	Función de activación	Unidad lineal rectificada	Permite el aprendizaje de características espaciales complejas
	Relleno	Mismo	Conserva el tamaño de entrada
	Tamaño de la agrupación	2 × 2	Reduce la dimensionalidad de el mapa de características de entrada
LSTM	Unidades	50	El número de neuronas en cada uno Capa LSTM
	Secuencias de retorno	Verdadero	Mantiene salidas secuenciales para el mecanismo de atención
	Tasa de abandono escolar	0.3	Reduce el sobreajuste mediante deshabilitando neuronas aleatoriamente durante el entrenamiento

Usando una división de validación de trenes de 80-20 y una parada temprana (parada dentro de 50 épocas), El modelo final logró lo siguiente:

- Precisión: 81,90%;
- Precisión: 85,00%;
- Recordatorio: 70,00%;
- Puntuación F1: 73,00%.

Al centrarse en características de ERP estadísticamente significativas, el Modelo 2 logró una mejora Exactitud y precisión. Sin embargo, su recuperación fue algo menor, lo que indica un sutil efecto positivo. Es posible que se hayan pasado por alto algunas respuestas. Aun así, estos resultados proporcionan una sólida base neurocientífica. Fundación para el diseño de espacios arquitectónicos afectivos.



4.5. Evaluación y comparación de modelos

A continuación, comparamos el rendimiento del Modelo 1 (Segmento ERP CNN-LSTM) y el Modelo 2 (CNN-LSTM basado en la prueba t). El Modelo 1, que aprende características espaciotemporales completas del ERP, logró una alta tasa de recuperación (98,76%), con una baja tasa de omisión de casos positivos o preferidos. Sin embargo, su precisión (72,11%) fue relativamente baja, lo que generó más falsos positivos. Mientras tanto, el Modelo 2, utilizando sólo características ERP estadísticamente significativas, mejoró la exactitud (81,90%) y la precisión (85,00%), pero tuvo una recuperación menor (70,00%).

La Tabla 20 resume las fortalezas y debilidades de cada modelo. En resumen, la amplia cobertura de segmentos de ERP del Modelo 1 genera una mayor recuperación, mientras que las características específicas del Modelo 2 se traducen en mayor precisión y exactitud.

Tabla 20. Comparación de ventajas y desventajas entre el Modelo 1 y el Modelo 2.

Modelo	Ventajas	Desventajas
Modelo 1: Segmento ERP CNN-LSTM	<ul style="list-style-type: none"><li>• Captura características espaciotemporales integrales de señales EEG en todos los segmentos ERP •</li><li>La alta recuperación (98,76 %) garantiza la sensibilidad a los estímulos emocionales, minimizando las respuestas positivas perdidas • Adecuado para monitoreo de emociones en tiempo real o aplicaciones de cambio de atención</li></ul>	<ul style="list-style-type: none"><li>• Menor precisión (72,11 %) debido a un posible sobreajuste en patrones irrelevantes • Mayor complejidad computacional debido al procesamiento de todas las características del segmento ERP</li></ul>
Modelo 2: basado en la prueba t CNN-LSTM	<ul style="list-style-type: none"><li>• Utiliza características estadísticamente significativas (media, pico, área bajo la curva y latencia máxima), lo que reduce el ruido y mejora la eficiencia • Alta precisión (81,90 %) y exactitud (85,00 %) que garantizan predicciones positivas confiables</li><li>• Eficiente para escenarios que requieren predicciones emocionales confiables, como sistemas de gestión de riesgos</li></ul>	<ul style="list-style-type: none"><li>• Menor capacidad de recuperación (70,00 %) que el Modelo 1, lo que genera una mayor probabilidad de perder respuestas positivas sutiles. • Puede perderse información valiosa. Patrones espaciotemporales excluidos durante la selección de características</li></ul>

Para evaluar con mayor detalle el rendimiento de generalización de los Modelos 1 y 2, se realizó una validación cruzada quíntuple. Dado el conjunto de datos relativamente limitado y la variabilidad intersujeto en las señales ERP, se observó cierta variación en la precisión entre los pliegues. Sin embargo, el Modelo 2 superó consistentemente al Modelo 1 en cuanto a precisión de clasificación. Este resultado respalda la idea de que extraer características ERP significativas e incorporarlas a la arquitectura CNN-LSTM puede resultar en un rendimiento de clasificación más estable y mejorado.

Además, se realizó una prueba *t* pareada para comparar estadísticamente la precisión de la validación cruzada de los Modelos 1 y 2. Los resultados revelaron una diferencia significativa ( $t = -10,4913$ ,  $p = 0,0005$ ), lo que indica que el enfoque ERP basado en características del Modelo 2 es más eficaz para la clasificación afectiva basada en EEG. Estos hallazgos sugieren que la recopilación adicional de datos y una mayor optimización de las características podrían mejorar aún más el rendimiento del modelo.

Estos hallazgos validan la viabilidad del análisis de emociones basado en EEG para distinguir entre preferencia y no preferencia en respuesta a estímulos arquitectónicos. En la práctica, los diseñadores pueden elegir o combinar estos modelos en función de si priorizan la sensibilidad (alta capacidad de recuerdo) o la precisión al capturar las preferencias del usuario. La siguiente sección analiza las posibles aplicaciones prácticas de estos modelos y su importancia para la arquitectura afectiva personalizada.

## 5. Discusión

Este estudio confirma que las respuestas emocionales de los usuarios hacia los estímulos arquitectónicos y sus preferencias por ellos pueden evaluarse cuantitativamente mediante EEG. Propusimos una metodología basada en modelos de aprendizaje profundo para clasificar objetivamente estas respuestas. Reclutamos un total de 40 participantes y recopilamos sus respuestas neuronales a imágenes arquitectónicas utilizando un dispositivo de EEG de 32 canales. El preprocesamiento exhaustivo de los datos (filtrado, eliminación de ruido, selección de canal y re-referenciación) garantizó datos de EEG de alta calidad. Posteriormente, se analizaron los componentes ERP (N100, N200, P300 y LPP) para identificar diferencias espaciotemporales en las respuestas cerebrales entre los estímulos preferidos y no preferidos. Los resultados revelaron diferencias significativas en los intervalos P300 y LPP, lo que demuestra que una evaluación basada en ERP de las preferencias arquitectónicas es válida y respalda la Hipótesis 1.

Los dos modelos de aprendizaje profundo CNN-LSTM propuestos en esta investigación tuvieron un rendimiento diferente según las características ERP utilizadas. El modelo 1 (CNN-LSTM utilizando todo el ERP) alcanzó una alta tasa de recuperación de alrededor del 98,76%, minimizando las detecciones fallidas de respuestas emocionales, pero su precisión fue relativamente menor (72,11%). El modelo 2 (CNN-LSTM utilizando características ERP seleccionadas mediante la prueba *t*) tuvo una precisión mejorada (81,90%) y precisión (85,00%), pero exhibió una recuperación menor (70,00%). Esto indica que todo el conjunto de datos ERP puede proporcionar una gama más amplia de información emocional, pero puede ser sensible al ruido, mientras que el uso selectivo de características ERP estadísticamente significativas mejora la precisión, pero puede pasar por alto cambios neurológicos sutiles. Por lo tanto, la selección de características ERP juega un papel crucial en la determinación del rendimiento del modelo, lo que respalda parcialmente la hipótesis 2.

Para validar aún más el rendimiento y la generalización del modelo, se realizó una validación cruzada quíntuple. Si bien ambos modelos mostraron cierta variabilidad entre los pliegues, el Modelo 2 demostró consistentemente un rendimiento superior y más estable. Además, una prueba *t* pareada reveló una diferencia estadísticamente significativa en la precisión entre el Modelo 1 y el Modelo 2 ( $t = -10,4913$ ,  $p = 0,0005$ ), lo que confirma que la selección de características basada en ERP puede ser más eficaz para la clasificación de emociones basada en EEG, y que el rendimiento del modelo puede variar según la construcción de los datos de entrada.

Se deben tener en cuenta varias limitaciones importantes. En primer lugar, el tamaño de la muestra ( $n = 40$ ) es relativamente pequeño, lo que justifica cautela al generalizar los resultados. Se necesitan estudios de seguimiento a mayor escala para mejorar la confiabilidad. Además, debido a que los datos de EEG pueden no ajustarse completamente a una distribución normal, adoptamos una prueba *t* para el análisis exploratorio. Las investigaciones futuras deben considerar enfoques no paramétricos (p. ej., prueba *U* de Mann-Whitney) o correcciones de comparación múltiple (p. ej., tasa de descubrimiento falso) para mejorar la robustez de los análisis estadísticos. Finalmente, este estudio empleó estímulos basados en imágenes. Por lo tanto, se justifican las mediciones a largo plazo en espacios del mundo real o de realidad virtual y la integración de otras señales fisiológicas (p. ej., frecuencia cardíaca y respuesta galvánica de la piel) para asegurar la validez ecológica.

Sin embargo, el valor de la metodología propuesta aquí es que ofrece un enfoque objetivo para incorporar las respuestas afectivas de los usuarios durante las primeras etapas del diseño arquitectónico. Por consiguiente, los hallazgos de este estudio deben considerarse en relación con la investigación reciente basada en EEG en el campo de la neuroarquitectura. Si bien este estudio destaca la viabilidad de aplicar el análisis de emociones basado en EEG en el diseño arquitectónico, se deben abordar varios desafíos antes de que pueda aplicarse en la práctica, como se indica a continuación: • Recopilación de datos del mundo real:

para mejorar la validez ecológica, los futuros investigadores deben realizar mediciones a más largo plazo en entornos de la vida real, como hospitales, parques, complejos comerciales e instalaciones de transporte, donde entran en juego diversos factores contextuales [1,5].

- Integración de bioseñales multimodales: el acoplamiento del EEG con otras señales fisiológicas (por ejemplo, la respuesta galvánica de la piel o la variabilidad de la frecuencia cardíaca) podría mejorar la precisión y la capacidad de reconocimiento de emociones en tiempo real [13,170].

Optimización y distribución de modelos: Los modelos CNN-LSTM pueden requerir un alto volumen computacional. Técnicas como la implementación de matrices de puertas programables en campo (PGA), la aceleración de unidades móviles de procesamiento gráfico (GPU), los sistemas multiagente y los métodos de conjunto pueden utilizarse para reducir la carga computacional y mejorar la aplicabilidad en campo [88,171,172].

Utilizando gemelos digitales y realidad virtual (RV)/realidad aumentada (RA): la creación de una plataforma de evaluación que integre datos de EEG en entornos virtuales podría incorporar la retroalimentación de los usuarios en las primeras fases de diseño, lo que aumentaría significativamente la satisfacción y la eficiencia.

## 6. Conclusiones

Con base en el análisis de EEG y ERP, los hallazgos de esta investigación demuestran que las preferencias emocionales de los usuarios por estímulos arquitectónicos pueden cuantificarse. En particular, se identificaron variaciones distintivas entre estímulos preferidos y no preferidos en los componentes P300 y LPP, lo que sugiere que la clasificación de emociones basada en EEG es neurofisiológicamente válida. Al evaluar los modelos de aprendizaje profundo CNN-LSTM, el Modelo 1, que utilizó todo el conjunto de datos ERP, logró una alta recuperación pero una precisión relativamente menor. Por el contrario, el Modelo 2, que incorporó selectivamente solo características ERP estadísticamente significativas, demostró una alta precisión y exactitud pero una recuperación menor. Los resultados de la validación cruzada quíntuple confirmaron aún más el rendimiento más consistente y superior del Modelo 2. Una prueba t pareada indicó una diferencia estadísticamente significativa en la precisión entre los dos modelos, lo que respalda la efectividad de la extracción selectiva de características ERP. Estos hallazgos subrayan el potencial de la clasificación de emociones basada en EEG como una herramienta de evaluación objetiva y neurofisiológicamente válida, al tiempo que enfatizan la importancia de identificar los componentes ERP relevantes.

Sin embargo, el estudio presenta limitaciones debido al pequeño tamaño de la muestra, las suposiciones sobre la normalidad de los datos y las dudas sobre la validez ecológica. Las investigaciones futuras deberían abordar estas limitaciones ampliando el grupo de participantes, recopilando datos en entornos reales e integrando múltiples señales fisiológicas.

Además, este trabajo destaca un enfoque prometedor para integrar las emociones y preferencias del usuario en el proceso de diseño arquitectónico. A medida que se amplía la validación en el mundo real, aumenta la diversidad de usuarios y se perfeccionan las metodologías técnicas, estas estrategias neurofisiológicas pueden contribuir significativamente al desarrollo de entornos arquitectónicos verdaderamente afectivos y centrados en el ser humano.

Contribuciones de los autores: Conceptualización, JEC y HJJ; Metodología, JEC y SYK; Software, JEC, SYK y YYH; Validación, JEC; Análisis formal, JEC y YYH; Curación de datos, JEC, SYK y YYH; Redacción del borrador original, JEC; Redacción de la revisión y edición, JEC, SYK y YYH;

Supervisión, JEC y SYK; Administración del proyecto, HJJ; Adquisición de fondos, HJJ Todos los autores han leído y aceptado la versión publicada del manuscrito.

Financiación: Esta investigación fue apoyada por una subvención de la Fundación Nacional de Investigación de Corea (NRF) financiada por el gobierno coreano (MSIT) (No. NRF-2022R1A2C3011796).

Declaración del Comité de Revisión Institucional: El estudio se llevó a cabo de acuerdo con la Declaración de Helsinki y fue aprobado por el Comité de Ética de la Universidad de Hanyang (HYUIRB-202504-006, aprobado el 22 de marzo de 2025).

Declaración de consentimiento informado: Se obtuvo el consentimiento informado de todos los sujetos involucrados en el estudio.

Declaración de disponibilidad de datos: Los conjuntos de datos presentados en este artículo no están disponibles de inmediato debido a que forman parte de un estudio en curso. Las solicitudes de acceso a los conjuntos de datos deben dirigirse al autor correspondiente.

Conflictos de intereses: Los autores declaran que no tienen ningún interés financiero en competencia conocido ni relaciones personales que pudieran parecer haber influenciado el trabajo presentado en este artículo.

### Abreviaturas

En este manuscrito se utilizan las siguientes abreviaturas:

Adán	Momentos adaptativos de gradiente
CNN	Redes neuronales convolucionales
Red neuronal convolucional CNN-LSTM de memoria a largo plazo y corto plazo	
EEG	Electroencefalografía
-----	Potencial relacionado con eventos
LPP	Potencial positivo tardío
LSTM	Memoria a corto plazo a largo plazo
-----	Realidad virtual

### Referencias

- Ergan, S.; Radwan, A.; Zou, Z.; Tseng, H.-a.; Han, X. Cuantificación de la experiencia humana en espacios arquitectónicos con realidad virtual integrada y redes de sensores corporales. *J. Comput. Civ. Eng.* 2018, 33, 04018062. [\[CrossRef\]](#)
- Nanda, U.; Pati, D.; Ghamari, H.; Bajema, R. Lecciones de la neurociencia: La forma sigue a la función, las emociones siguen a la forma. *Intell. Build. Int.* 2013, 5, 61–78. [\[Referencia cruzada\]](#)
- Eberhard, JP Paisaje cerebral: la coexistencia de la neurociencia y la arquitectura; Oxford University Press: Oxford, Reino Unido, 2009; págs. 1–280.
- Bower, I.; Tucker, R.; Enticott, PG. Impacto del diseño del entorno construido en la emoción, medido mediante correlatos neurofisiológicos e indicadores subjetivos: Una revisión sistemática. *J. Environ. Psychol.* 2019, 66, 101344. [\[CrossRef\]](#)
- Evans, GW; McCoy, JM Cuando los edificios no funcionan: El papel de la arquitectura en la salud humana. *J. Environ. Psychol.* 1998, 18, 85–94. [\[Referencia cruzada\]](#)
- Eastman, C.; Newstetter, W.; McCracken, M. Diseño: Conocimiento y aprendizaje: Cognición en la educación en diseño; Elsevier: Ámsterdam, Países Bajos, 2001; págs. 79–103.
- Kim, N.; Chung, S.; Kim, DI. Explorando los estudios de diseño basados en EEG: Una revisión sistemática. *Arch. Des. Res.* 2022, 35, 91–113. [\[Referencia cruzada\]](#)
- Hu, L.; Shepley, MM El diseño se encuentra con la neurociencia: una revisión preliminar de la investigación de diseño utilizando herramientas de neurociencia. *J. Inter. Des.* 2022, 47, 31–50. [\[Referencia cruzada\]](#)
- Ball, LJ; Christensen, BT Avanzando en la comprensión de la cognición del diseño y la metacognición del diseño: avances y perspectivas. *Des. Stud.* 2019, 65, 35–59. [\[CrossRef\]](#)
- Gero, JS; Milovanovic, J. Un marco para estudiar el pensamiento de diseño a través de la medición de las mentes, los cuerpos y los cerebros de los diseñadores. *Des. Sci.* 2020, 6, e19. [\[Referencia cruzada\]](#)
- Vieira, S.; Gero, JS; DELMORO, J.; GATOL, V.; FERNÁNDES, C.; Parente, M.; Fernández, A.A. Las activaciones neurofisiológicas de Ingenieros mecánicos y diseñadores industriales en el diseño y la resolución de problemas. *Des. Sci.* 2020, 6, e26. [\[CrossRef\]](#)
- Kim, J.; Kim, N. Cuantificación de emociones en entornos arquitectónicos mediante biometría. *Appl. Sci.* 2022, 12, 9998. [\[CrossRef\]](#)
- Koelstra, S.; Muhl, C.; Soleymani, M.; Lee, J.-S.; Yazdani, A.; Ebrahimi, T.; Pun, T.; Nijholt, A.; Patras, I. DEAP: Una base de datos para Análisis de emociones; uso de señales fisiológicas. *IEEE Trans. Affect. Comput.* 2012, 3, 18–31. [\[CrossRef\]](#)

14. Ricci, N. El impacto psicológico del diseño arquitectónico. Tesis de licenciatura, Claremont McKenna College, Claremont, CA. Estados Unidos, 2018.
15. Heydarian, A.; Pantazis, E.; Wang, A.; Gerber, D.; Becerik-Gerber, B. Hacia un diseño de edificios centrado en el usuario: Identificación del usuario final Preferencias de iluminación mediante entornos virtuales inmersivos. *Autom. Constr.* 2017, 81, 56–66. [\[CrossRef\]](#)
16. Bar, M.; Neta, M. Los humanos prefieren objetos visuales curvos. *Psychol. Sci.* 2006, 17, 645–648. [\[CrossRef\]](#) [\[PubMed\]](#)
17. Madani Nejad, K. Curvilinealidad en la arquitectura: Efecto emocional de las formas curvilíneas en el diseño de interiores. Tesis doctoral, Texas Universidad A&M, College Station, TX, EE. UU., 2007.
18. Vartanian, O.; Navarrete, G.; Chatterjee, A.; Fich, LB; Leder, H.; Modroño, C.; Nadal, M.; Rostrup, N.; Skov, M. Impacto del contorno en los juicios estéticos y las decisiones de aproximación-evitación en arquitectura. *Proc. Natl. Acad. Sci. USA* 2013, 110, 10446–10453. [\[Referencia cruzada\]](#)
19. Banaei, M.; Hatami, J.; Yazdanfar, A.; Gramann, K. Caminar por espacios arquitectónicos: el impacto de las formas interiores en Dinámica del Cerebro Humano. *Portada. Hum. Neurosci.* 2017, 11, 477. [\[CrossRef\]](#)
20. Roelfsema, PR; Scholte, HS; Spekreijse, H. Restricciones temporales en la agrupación de segmentos de contorno en segmentos espacialmente extendidos. *Objetos. Vis. Res.* 1999, 39, 1509–1529. [\[CrossRef\]](#)
21. Zadeh, RS; Shepley, MM; Williams, G.; Chung, SSE El impacto de las ventanas y la luz natural en la fisiología de las enfermeras de cuidados agudos Salud psicológica y conductual. *HERD Health Environ. Res. Des. J.* 2014, 7, 35–61. [\[CrossRef\]](#)
22. Meyers-Levy, J.; Zhu, R. La influencia de la altura del techo: el efecto de la preparación en el tipo de procesamiento que utilizan las personas. *J. Consum. Res.* 2007, 34, 174–186. [\[Referencia cruzada\]](#)
23. Teplan, M. Fundamentos de la medición del EEG. *Meas. Sci. Rev.* 2002, 2, 1–11.
24. Aldayel, MS; Ykhlef, M.; Al-Nafjan, AN Predicción de preferencias basada en electroencefalogramas utilizando aprendizaje por transferencia profunda. *IEEE Access* 2020, 8, 176818–176829. [\[Referencia cruzada\]](#)
25. Zhu, L.; Lv, J. Revisión de estudios sobre investigación de usuarios basada en EEG y seguimiento ocular. *Appl. Sci.* 2023, 13, 6502. [\[CrossRef\]](#)
26. Luck, SJ Introducción a la técnica del potencial relacionado con eventos; MIT Press: Cambridge, MA, EE. UU., 2014.
27. Siuly, S.; Li, Y.; Zhang, Y. Análisis y clasificación de señales EEG. *IEEE Trans. Neural Syst. Rehabil. Eng.* 2016, 11, 141–144. [\[Referencia cruzada\]](#)
28. Dehais, F.; Duprès, A.; Blum, S.; Drougard, N.; Scannella, S.; Roy, RN; Lotte, F.; Dehais, F.; Duprès, A.; Blum, S.; et al. Monitorización de la carga mental del piloto mediante ERP y potencia espectral con un sistema de EEG de seis electrodos secos en condiciones reales de vuelo. *Sensors* 2019, 19, 1324. [\[CrossRef\]](#)
29. Zhang, L.; Wade, J.; Bian, D.; Fan, J.; Swanson, A.; Weitlauf, A.; Warren, Z.; Sarkar, N. Medición de la carga cognitiva en un sistema de conducción basado en realidad virtual para la intervención del autismo. *IEEE Trans. Affect. Comput.* 2017, 8, 176–189. [\[CrossRef\]](#) [\[PubMed\]](#)
30. KOK, A. Sobre la utilidad de la amplitud de P3 como medida de la capacidad de procesamiento. *Psicofisiología* 2001, 38, 557. [\[CrossRef\]](#) [\[PubMed\]](#)
31. Brouwer, A.-M.; Hogervorst, MA; Van Erp, JB; Heffelaar, T.; Zimmerman, PH; Oostenveld, R. Estimación de la carga de trabajo mediante EEG Potencia espectral y ERP en la tarea n-back. *J. Neural Eng.* 2012, 9, 045008. [\[CrossRef\]](#)
32. Kabbara, A. Estimación de la red cerebral a partir de señales EEG densas: Aplicación a trastornos neurológicos. Tesis doctoral, Universidad de Rennes; Universidad Libanesa, Rennes, Francia, 2018.
33. Wilson, GF; Russell, CA Mejora del rendimiento en una tarea de vehículo aéreo deshabitado utilizando determinaciones psicofisiológicas Ayuda adaptativa extraída. *Hum. Factors* 2007, 49, 1005–1018. [\[CrossRef\]](#)
34. Mühl, C.; Jeunet, C.; Lotte, F. Estimación de la carga de trabajo basada en EEG en contextos afectivos. *Front. Neurosci.* 2014, 8, 114.
35. Zarjam, P.; Epps, J.; Chen, F. Caracterización de la carga de la memoria de trabajo mediante la actividad delta del EEG. En las Actas de la 19.ª edición de 2011. Conferencia Europea de Procesamiento de Señales, Barcelona, España, 29 de agosto–2 de septiembre de 2011; págs. 1554–1558.
36. Dijksterhuis, J.; De Ward, D.; Brookhuis, CA; Mulder, BL; de Jong, R. Clasificación de la carga visomotora en un simulador de conducción mediante patrones cerebrales espaciales específicos del sujeto. *Portada. Neurosci.* 2013, 7, 149. [\[CrossRef\]](#)
37. Zarjam, P.; Epps, J.; Chen, F.; Lovell, NH Estimación de la carga de trabajo cognitiva utilizando características basadas en la entropía de wavelets durante un Tarea aritmética. *Comput. Biol. Med.* 2013, 43, 2186–2195. [\[CrossRef\]](#)
38. Walter, C.; Schmidt, S.; Rosenstiel, W.; Gerjets, P.; Bogdan, M. Uso de la clasificación entre tareas para clasificar los niveles de carga de trabajo en tareas complejas de aprendizaje. En las Actas de la Conferencia de la Asociación Humana de 2013 sobre Computación Afectiva e Interacción Inteligente, Ginebra, Suiza, del 2 al 5 de septiembre de 2013. [\[CrossRef\]](#)
39. Tian, Y.; Zhang, H.; Jiang, Y.; Li, P.; Li, Y. Una función de fusión para mejorar el rendimiento de la clasificación en la memoria de trabajo Carga con detección de un solo ensayo. *IEEE Trans. Neural Syst. Rehabil. Eng.* 2019, 27, 1985–1993. [\[CrossRef\]](#)
40. Roy, RN; Bonnet, S.; Charbonnier, S.; Campagne, A. Estimación de la fatiga mental y la carga de la memoria de trabajo: Interacción e implicaciones para la BCI pasiva basada en EEG. En las Actas de la 35.ª Conferencia Internacional Anual de 2013 de la Sociedad de Ingeniería en Medicina y Biología del IEEE (EMBC), Osaka, Japón, del 3 al 7 de julio de 2013. [\[CrossRef\]](#)
41. Subha, DP; Joseph, PK; Acharya, UR; Lim, CM. Análisis de la señal EEG: Un estudio. *J. Med. Syst.* 2008, 34, 195–212. [\[CrossRef\]](#) [\[PubMed\]](#)

42. Ma, Y.; Shi, W.; Peng, C.-K.; Yang, AC Análisis dinámico no lineal de la electroencefalografía del sueño utilizando fractales y entropía Enfoques. *Sleep Med. Rev.* 2018, 37, 85–93. [\[CrossRef\]](#) [\[PubMed\]](#)
43. Dimitrakopoulos, GN; Kakkos, I.; Dai, Z.; Lim, J.; deSouza, JJ; Bezerianos, A.; Sun, Y. Clasificación de la carga de trabajo mental independiente de la tarea basada en la conectividad cortical común del EEG multibanda. *IEEE Trans. Neural Syst. Rehabil. Eng.* 2017, 25, 1940–1949. [\[CrossRef\]](#)
44. Sakkalis, V. Revisión de técnicas avanzadas para la estimación de la conectividad cerebral medida con EEG/MEG. *Comput. Biol. Med.* 2011, 41, 1110–1117. [\[Referencia cruzada\]](#)
45. Kakkos, I.; Dimitrakopoulos, GN; Gao, L.; Zhang, Y.; Qi, P.; Matsopoulos, GK; Thakor, N.; Bezerianos, A.; Sun, Y. La carga de trabajo mental impulsa diferentes reorganizaciones de la conectividad cortical funcional entre experimentos de vuelo simulado en 2D y 3D. *IEEE Trans. Sistemas Neurales, Rehabilitación, Ingeniería*, 2019, 27, 1704–1713. [\[CrossRef\]](#) [\[PubMed\]](#)
46. Romeo, Z.; Spironelli, C. El componente P1 revela asimetrías hemisféricas relacionadas con el género durante el procesamiento IAPS. *Simetría*. 2023, 15, 610. [\[Referencia cruzada\]](#)
47. Patel, SH; Azzam, PN. Caracterización de N200 y P300: Estudios Selectos del Potencial Relacionado con Eventos. *Int. J. Med. Sci.* 2005, 2, 147–154. [\[Referencia cruzada\]](#)
48. Goto, N.; Lim, XL; Shee, D.; Hatano, A.; Khong, KW; Buratto, LG; Watabe, M.; Schaefer, A. ¿Pueden las ondas cerebrales realmente determinar si un producto será comprado? Infiriendo las preferencias del consumidor a partir de los potenciales cerebrales de un solo producto. *Front. Integr. Neurosci.* 2019, 13, 19. [\[CrossRef\]](#)
49. Cacioppo, JT Sentimientos y emociones: Función de los marcadores electrofisiológicos. *Biol. Psychol.* 2004, 67, 235–243. [\[CrossRef\]](#)
50. Chen, J.; He, B.; Zhu, H.; Wu, J. La evaluación de la preferencia implícita por las baldosas cerámicas con diferentes características visuales: Evidencia de un estudio de potencial relacionado con eventos. *Front. Psychol.* 2023, 14, 1139687. [\[CrossRef\]](#)
51. Almeida, R.; Prata, C.; Pereira, MR; Barbosa, F.; Ferreira-Santos, F. Correlatos neuronales de la empatía: una revisión sistemática de Estudios de Potenciales Relacionados con Eventos en Tareas Perceptuales. *Brain Sci.* 2024, 14, 504. [\[CrossRef\]](#) [\[PubMed\]](#)
52. Johal, PK; Jain, N. Eliminación de artefactos del EEG: Comparación de técnicas. En las Actas de la Conferencia Internacional sobre Técnicas Eléctricas, Electrónicas y de Optimización (ICEEOT) de 2016, Chennai, India, del 3 al 5 de marzo de 2016. [\[CrossRef\]](#)
53. Henry, JC Electroencefalografía: Principios básicos, aplicaciones clínicas y campos relacionados. *Neurología* 2006, 67, 2092–2092–a. [\[Referencia cruzada\]](#)
54. Liu, Y.; Sourina, O.; Nguyen, MK. Reconocimiento y visualización de emociones humanas basado en EEG en tiempo real. En Actas de la Conferencia Internacional sobre Cibernundos 2010, Singapur, 20-22 de octubre de 2010. [\[CrossRef\]](#)
55. Li, Y.; Li, X.; Ratcliffe, M.; Liu, L.; Qi, Y.; Liu, Q. Un sistema BCI basado en EEG en tiempo real para el reconocimiento de la atención en un entorno ubicuo. En Actas del Taller Internacional de 2011 sobre Conciencia Afectiva Ubicua e Interacción Inteligente, Pekín, China, 18 de septiembre de 2011; págs. 33-40. [\[CrossRef\]](#)
56. Cincotti, F.; Mattia, D.; Aloïse, F.; Bufalari, S.; Astolfi, L.; Fallani, FDV; Tocci, A.; Bianchi, L.; Mariani, MG; Gao, S.; et al. Técnicas de EEG de alta resolución para aplicaciones de interfaz cerebro-computadora. *J. Neurosci. Methods* 2008, 167, 31–42. [\[CrossRef\]](#) [\[PubMed\]](#)
57. Hart, S. Desarrollo de NASA-TLX (Índice de Carga de Trabajo): Resultados de la investigación empírica y teórica. En *Carga Mental Humana*; Elsevier: Ámsterdam, Países Bajos, 1988.
58. Ramachandran, V. S.; Hirstein, W. La ciencia del arte: Una teoría neurológica de la experiencia estética. *J. Conscious. Stud.* 1999, 6, 15–51.
59. Gao, Z.; Wang, X.; Yang, Y.; Mu, C.; Cai, Q.; Dang, W.; Zuo, S. Red neuronal convolucional espacio-temporal basada en EEG para la evaluación de la fatiga del conductor. *IEEE Trans. Neural Netw. Learn. Syst.* 2019, 30, 2755–2763. [\[CrossRef\]](#)
60. Ismail, LE; Karwowski, W. Un modelo basado en la teoría de grafos de la conectividad cerebral funcional basado en EEG: un estudio sistemático Revisión en el contexto de la neuroergonomía. *IEEE Access* 2020, 8, 155103–155135. [\[CrossRef\]](#)
61. Craik, A.; He, Y.; Contreras-Vidal, JL Aprendizaje profundo para tareas de clasificación de electroencefalogramas (EEG): una revisión. *J. Neural Eng.* 2019, 16, 031001. [\[CrossRef\]](#)
62. Li, J.; Jin, Y.; Lu, S.; Wu, W.; Wang, P. Información del entorno del edificio y retroalimentación perceptiva humana recopilada mediante un método combinado de realidad virtual (RV) y electroencefalograma (EEG). *Energy Build.* 2020, 224, 110259. [\[CrossRef\]](#)
63. Erkan, 'I. Examen de comportamientos de orientación en espacios arquitectónicos utilizando imágenes cerebrales con electroencefalografía (EEG). *Archit. Sci. Rev.* 2018, 61, 410–428. [\[Referencia cruzada\]](#)
64. Marín Morales, J.; Higuera-Trujillo, JL; Greco, A.; Guixères, J.; Llinares, C.; Gentili, C.; Scilingo, EP; Alcañiz, M.; Valenza, G. Experiencia emocional real vs. inmersión-virtual: Análisis de patrones psicofisiológicos en una exploración libre de un museo de arte. *PLoS ONE* 2019, 14, e0223881. [\[Referencia cruzada\]](#)
65. Zou, Z.; Yu, X.; Ergun, S. Integración de sensores biométricos, RV y aprendizaje automático para clasificar señales de EEG en diseños de arquitectura alternativos. En Actas de la Conferencia Internacional de la ASCE sobre Computación en Ingeniería Civil, Nueva Orleans, LO, EE. UU., 11-14 de mayo de 2019; págs. 169-176.

66. Vaquero-Blasco, MA; Pérez-Valero, E.; López-Gordo, MA; Morillas, C. La realidad virtual como alternativa portátil a la cromoterapia. Salas de relajación para el alivio del estrés: Un estudio preliminar. *Sensors* 2020, 20, 6211. [\[CrossRef\]](#)
67. Cruz-Garza, JG; Darfler, M.; Rounds, JD; Gao, E.; Kalantari, S. Investigación basada en EEG del impacto del tamaño de la habitación y la ventana Colocación en el rendimiento cognitivo. *J. Build. Eng.* 2022, 53, 104540. [\[CrossRef\]](#)
68. Yeom, S.; Kim, H.; Hong, T. Efectos psicológicos y fisiológicos de un muro verde en los ocupantes: un estudio cruzado en entornos virtuales. *Realidad. Construcción. Medio ambiente.* 2021, 204, 108134. [\[CrossRef\]](#)
69. Zou, Z.; Ergon, S. Evaluación de la eficacia de los sensores biométricos y sus características de señal para clasificar la experiencia humana en Entornos virtuales. *Informe de Ingeniería Avanzada*, 2021, 49, 101358. [\[CrossRef\]](#)
70. Kalantari, S.; Tripathi, V.; Kan, J.; Rounds, J. D.; Mostafavi, A.; Snell, R.; Cruz-Garza, J. G. Evaluación del impacto del color, los gráficos y las características arquitectónicas en la señalización en entornos sanitarios mediante datos de EEG y pruebas de respuesta virtual. *J. Environ. Psychol.* 2022, 79, 101744. [\[Referencia cruzada\]](#)
71. Liu, C.; Zhang, Y.; Sun, L.; Gao, W.; Zang, Q.; Li, J. El efecto del color de las paredes del aula en el rendimiento académico: Un experimento de realidad virtual. *Build. Simul.* 2022, 15, 2019-2030. [\[CrossRef\]](#)
72. Kalantari, S.; Rounds, JD; Kan, J.; Tripathi, V.; Cruz-Garza, JG Comparación de respuestas fisiológicas durante pruebas cognitivas en Entornos virtuales vs. entornos reales idénticos. *Sci. Rep.* 2021, 11, 10227. [\[CrossRef\]](#)
73. Bower, IS; Hill, AT; Enticott, PG Conectividad cerebral funcional durante la exposición a la escala y el color de interiores construidos Entornos. *Hum. Brain Mapp.* 2023, 44, 447–457. [\[CrossRef\]](#)
74. Taherysayah, F.; Malathouni, C.; Liang, H.-N.; Westermann, C. Realidad virtual (RV) y electroencefalografía (EEG) en el diseño arquitectónico: Una revisión sistemática de estudios empíricos. *J. Build. Eng.* 2024, 85, 108611.
75. Lau-Zhu, A.; Lau, MPH; McLoughlin, G. Electroencefalografía móvil en la investigación de trastornos del neurodesarrollo: Oportunidades y desafíos. *Dev. Cogn. Neurosci.* 2019, 36, 100635. [\[CrossRef\]](#)
76. Rad, PN; Behzadi, F.; Yazdanfar, SA; Ghamari, H.; Zabe, E.; Lashgari, R. Explorando enfoques metodológicos de estudios experimentales en el campo de la neuroarquitectura: Una revisión sistemática. *HERD Health Environ. Res. Des. J.* 2023, 16, 284–309. [\[CrossRef\]](#)
77. LeCun, Y.; Bengio, Y.; Hinton, G. Aprendizaje profundo. *Nature* 2015, 521, 436–444. [\[CrossRef\]](#) [\[PubMed\]](#)
78. Vaswani, A. La atención es todo lo que necesitas. En *Avances en Sistemas de Procesamiento de Información Neural*; MIT Press: Cambridge, MA, EE. UU., 2017.
79. Sabour, S.; Frosst, N.; Hinton, G. E. Enrutamiento dinámico entre cápsulas. En *Avances en Sistemas de Procesamiento de Información Neural*; MIT Prensa: Cambridge, MA, EE.UU., 2017.
80. Grech, R.; Cassar, T.; Muscat, J.; Jamillery, K.P.; Fabry, S.G.; Zervakis, M.; Xanthopoulos, P.; Sakkalis, V.; Vanrumste, B. Revisión sobre la resolución del problema inverso en el análisis de fuentes de EEG. *J. Neuroeng. Rehabil.* 2008, 5, 25. [\[CrossRef\]](#) [\[PubMed\]](#)
81. He, B.; Ding, L. Mapeo electrofisiológico y neuroimagen. En *Ingeniería Neural*; Springer: Nueva York, NY, EE. UU., 2012; págs. 499–543.
82. Roy, Y.; Banville, H.; Albuquerque, I.; Gramfort, A.; Falk, TH; Faubert, J. Análisis electroencefalográfico basado en aprendizaje profundo: Una revisión sistemática. *J. Neural Eng.* 2019, 16, 051001.
83. Yang, J.; Ma, Z.; Wang, J.; Fu, Y. Un nuevo esquema de aprendizaje profundo para la decodificación de imágenes motoras en EEG basado en la fusión de representaciones espaciales. *IEEE Access* 2020, 8, 202100–202110. [\[CrossRef\]](#)
84. Rumelhart, DE; Hinton, GE; Williams, RJ. Aprendizaje de representaciones mediante retropropagación de errores. *Nature* 1986, 323, 6088. [\[Referencia cruzada\]](#)
85. Graves, A. Memoria a largo plazo; Springer: Singapur, 2012. [\[CrossRef\]](#)
86. Cho, K. Aprendizaje de representaciones de frases mediante el codificador-decodificador RNN para la traducción automática estadística. *arXiv* 2014, arXiv:1406.1078.
87. Krizhevsky, A.; Sutskever, I.; Hinton, G. E. Clasificación Imagenet con redes neuronales convolucionales profundas. *Adv. Neural Inf. Proceso. Sistema.* 2012, 25, 84–90. [\[CrossRef\]](#)
88. Lawhern, VJ; Solon, AJ; Waytowich, NR; Gordon, SM; Hung, CP; Lance, BJ EEGNet: Una red neuronal convolucional compacta para interfaces cerebro-computadora basadas en EEG. *J. Neural Eng.* 2018, 15, 056013. [\[CrossRef\]](#)
89. Schirrneister, RT; Springenberg, JT; Fiederer, LDJ; Glasstetter, M.; Eggensperger, K.; Tangemann, M.; Hutter, F.; Burgard, W.; Ball, T. Aprendizaje profundo con redes neuronales convolucionales para la decodificación y visualización de EEG. *Hum. Brain Mapp.* 2017, 38, 5391–5420. [\[CrossRef\]](#) [\[PubMed\]](#)
90. Li, G.; Lee, CH; Jung, JJ; Youn, YC; Camacho, D. Aprendizaje profundo para análisis de datos de EEG: Una encuesta. *Concurrencia. Computación. Práctica. Exp.* 2020, 32, e5199. [\[Referencia cruzada\]](#)
91. Yang, Y.; Wu, QJ; Zheng, WL; Lu, B.-L. Reconocimiento de emociones basado en EEG utilizando una red jerárquica con nodos de subred. *IEEE Trans. Cogn. Dev. Syst.* 2017, 10, 408–419. [\[Referencia cruzada\]](#)
92. Yin, Y.; Zheng, X.; Hu, B.; Zhang, Y.; Cui, X. Reconocimiento de emociones mediante EEG mediante un modelo de fusión de redes neuronales convolucionales de grafos. y LSTM. *Appl. Soft Comput.* 2021, 100, 106954. [\[CrossRef\]](#)
93. Zhang, T.; Zheng, W.; Cui, Z.; Zong, Y.; Li, Y. Red neuronal recurrente espacio-temporal para el reconocimiento de emociones. *Traducción IEEE. Cybern.* 2018, 49, 839–847. [\[Referencia cruzada\]](#)



94. Wang, P.; Jiang, A.; Liu, X.; Shang, J.; Zhang, L. Clasificación EEG basada en LSTM en tareas de imaginaria motora. IEEE Trans. Neural Syst. Rehabil. Ingeniería. 2018, 26, 2086–2095. [\[CrossRef\]](#) [\[PubMed\]](#)
95. Kumar, S.; Sharma, A.; Tsunoda, T. Clasificación de ondas cerebrales utilizando un predictor ÓPTICO basado en una red de memoria a corto y largo plazo. Sci. Rep. 2019, 9, 9153. [\[Referencia cruzada\]](#)
96. Liu, T.; Yang, D.; Liu, T.; Yang, D. Una red neuronal convolucional tridimensional multirrama densamente conectada para imágenes motoras EEG Descodificación. Brain Sci. 2021, 11, 197. [\[CrossRef\]](#)
97. Chambon, S.; Galtier, M.N.; Arnal, P.J.; Wainrib, G.; Gramfort, A. Una arquitectura de aprendizaje profundo para la clasificación temporal de las etapas del sueño mediante series temporales multivariadas y multimodales. IEEE Trans. Neural Syst. Rehabil. Eng. 2018, 26, 758–769. [\[CrossRef\]](#)
98. Abdallah, M.; An Le Khac, N.; Jahromi, H.; Delia Jurcut, A. Un enfoque híbrido basado en CNN-LSTM para sistemas de detección de anomalías en SDN. En las Actas de la 16.<sup>a</sup> Conferencia Internacional sobre Disponibilidad, Fiabilidad y Seguridad, Viena, Austria, 17-20 de agosto de 2021; págs. 1-7.
99. Chao, H.; Zhi, H.; Dong, L.; Liu, Y. Reconocimiento de emociones utilizando datos de EEG multicanal y un conjunto profundo basado en DBN-GC Marco de aprendizaje. Comput. Intell. Neurosci. 2018, 2018, 750904. [\[CrossRef\]](#)
100. Tayeb, Z.; Fedjaev, J.; Ghaboosi, N.; Richter, C.; Everding, L.; Qu, X.; Wu, Y.; Cheng, G.; Conradt, J. Validación de redes neuronales profundas para la decodificación en línea de movimientos de imágenes motoras a partir de señales de EEG. Sensors 2019, 19, 210. [\[CrossRef\]](#)
101. Dose, H.; Möller, JS; Iversen, HK; Puthusserypady, S. Un enfoque integral de aprendizaje profundo para la clasificación de señales MI-EEG para BCI. Expert Syst. Appl. 2018, 114, 532–542. [\[CrossRef\]](#)
102. Zhang, R.; Zong, Q.; Dou, L.; Zhao, X. Un nuevo esquema híbrido de aprendizaje profundo para la clasificación de imágenes motoras de cuatro clases. J. Neural Ing. 2019, 16, 066004. [\[Referencia cruzada\]](#)
103. Li, J.; Zhang, Z.; He, H. Redes neuronales convolucionales jerárquicas para el reconocimiento de emociones basado en EEG. Cogn. Comput. 2018, 10, 368–380.
104. Zeng, H.; Wu, Z.; Zhang, J.; Yang, C.; Zhang, H.; Dai, G.; Kong, W. Clasificación de emociones mediante EEG mediante un modelo mejorado de aprendizaje profundo basado en SincNet. Brain Sci. 2019, 9, 326. [\[CrossRef\]](#)
105. Li, X.; Song, D.; Zhang, P.; Hou, Y.; Hu, B. Fusión profunda de señales neurofisiológicas multicanal para el reconocimiento de emociones y Monitoreo. Int. J. Data Min. Bioinform. 2017, 18, 1–27. [\[CrossRef\]](#)
106. Topic, A.; Russo, M. Reconocimiento de emociones basado en mapas de características de EEG mediante una red de aprendizaje profundo. Eng. Sci. Technol. Int. J. 2021, 24, 1442–1454.
107. Xu, B.; Zhang, L.; Song, A.; Wu, C.; Li, W.; Zhang, D.; Xu, G.; Li, H.; Zeng, H. Clasificación de EEG de imágenes motoras mediante imágenes tiempo-frecuencia por transformada wavelet y redes convolucionales. IEEE Access 2018, 7, 6084–6093. [\[CrossRef\]](#)
108. Alhagry, S.; Fahmy, AA; El-Khoribi, RA. Reconocimiento de emociones basado en EEG mediante red neuronal recurrente LSTM. Int. J. Adv. Aplicaciones de Ciencias Computacionales 2017, 8, 355–358. [\[CrossRef\]](#)
109. Acharya, UR; Oh, SL; Hagiwara, Y.; Tan, JH; Adeli, H. Red neuronal convolucional profunda para la detección y el análisis automatizados Diagnóstico de convulsiones mediante señales de EEG. Comput. Biol. Med. 2018, 100, 270–278. [\[CrossRef\]](#)
110. Affes, A.; Mdhaftar, A.; Triki, C.; Jmaiel, M.; Freisleben, B. Una red neuronal recurrente convolucional y compuertada para la predicción de crisis epilépticas. En Actas de la 17.<sup>a</sup> Conferencia Internacional «Cómo la IA impacta la vida urbana y la salud pública», ICOST 2019, Nueva York, EE. UU., 14-16 de octubre de 2019; págs. 85-96.
111. Supratak, A.; Dong, H.; Wu, C.; Guo, Y. DeepSleepNet: Un modelo para la puntuación automática de la etapa del sueño basado en datos brutos de un solo canal. EEG. IEEE Trans. Sistema Neural. Rehabilitación. Ingeniería. 2017, 25, 1998-2008. [\[CrossRef\]](#) [\[PubMed\]](#)
112. Enobio. Instrucciones de uso de Enobio; Neuroelectrics: Barcelona, España, 2022.
113. He, C.; Chen, Y.-Y.; Phang, C.-R.; Stevenson, C.; Chen, I.-P.; Jung, T.-P.; Ko, L.-W. Revisión de la Diversidad e Idoneidad de los Sistemas de EEG Portátiles e Inalámbricos de Última Generación. IEEE J. Biomed. Health Inform. 2023, 27, 3830–3843. [\[CrossRef\]](#) [\[PubMed\]](#)
114. Rocha, P.; Dagnino, PC; O'Sullivan, R.; Soria-Frisch, A.; Paúl, C. BRAINCODE para el diagnóstico del deterioro cognitivo en personas mayores Adultos: Diseño de un estudio piloto de casos y controles. Int. J. Environ. Res. Salud Pública 2022, 19, 5768. [\[CrossRef\]](#)
115. Vidyarani, K.; Dhananjaya, B.; Tejaswini, S. Detección de somnolencia en el conductor mediante LabVIEW. IAETSD J. Adv. Res. Aplica. Ciencia. 2018, 5, 23–32.
116. Delorme, A.; Makeig, S. EEGLAB: Una caja de herramientas de código abierto para el análisis de la dinámica del EEG de un solo ensayo, que incluye Análisis de componentes; PubMed. J. Neurosci. Methods 2004, 134, 9–21. [\[CrossRef\]](#)
117. Ostenveld, R.; Papas fritas, P.; Maris, E.; Schoffelen, J.-M. FieldTrip: software de código abierto para análisis avanzado de MEG, EEG y Datos electrofisiológicos invasivos. Comput. Intell. Neurosci. 2011, 2011, 156869. [\[CrossRef\]](#)
118. Cohen, M. Análisis de datos neuronales de series temporales: teoría y práctica; MIT Press: Cambridge, MA, EE. UU., 2014.
119. Balconi, M.; Mazza, G. Oscilaciones cerebrales y efectos del BIS/BAS (sistema de inhibición/activación conductual) en el procesamiento de neuronas enmascaradas. Señales emocionales: ERS/ERD y medidas de coherencia de la banda alfa. Int. J. Psychophysiol. 2009, 74, 158-165. [\[CrossRef\]](#)
120. Davidson, RJ. ¿Qué hace la corteza prefrontal en el afecto? Perspectivas sobre la investigación de la asimetría del EEG frontal. Biol. Psychol. 2004, 67, 219–234. [\[Referencia cruzada\]](#)

121. Collado-Mateo, D.; Adsuar, JC; Olivares, PR; Cano-Plasencia, R.; Gusi, N. Uso de un dispositivo EEG de electrodo seco durante el equilibrio Tareas en varones jóvenes sanos: Análisis de fiabilidad test-retest. *Somatosens. Mot. Res.* 2015, 32, 219–226. [\[CrossRef\]](#)
122. Biblioteca de búsqueda de imágenes de Google. Disponible en línea: <https://pypi.org/project/Google-Images-Search/> (consultado el 25 de enero de 2025).
123. Soleymani, M.; Asghari-Esfeden, S.; Fu, Y.; Pantic, M. Análisis de señales de EEG y expresiones faciales para la emoción continua Detección. *IEEE Trans. Af. Comput.* 2016, 7, 17–28. [\[CrossRef\]](#)
124. Herzog, TR; Bryce, AG: Misterio y preferencia en entornos forestales. *Environ. Behav.* 2007, 39, 779–796. [\[CrossRef\]](#)
125. Ekman, P.; Davidson, RJ. La sonrisa voluntaria altera la actividad cerebral regional. *Psychol. Sci.* 1993, 4, 342–345. [\[CrossRef\]](#)
126. Lang, P.; Bradley, MM El Sistema Internacional de Imágenes Afectivas (IAPS) en el estudio de la emoción y la atención. En *Manual de Elicitación y evaluación de emociones*; Oxford University Press: Oxford, Reino Unido, 2007; Volumen 29, págs. 70–73.
127. Jarcho, JM; Berkman, ET; Lieberman, MD La base neuronal de la racionalización: reducción de la disonancia cognitiva durante Toma de decisiones. *Soc. Cogn. Afecto. Neurociencia.* 2011, 6, 460–467. [\[CrossRef\]](#)
128. Greco, A.; Valenza, G.; Scilingo, EP Avances en el procesamiento de la actividad electrodérmica con aplicaciones para la salud mental; Springer: Singapur, 2016. [\[CrossRef\]](#)
129. Olofsson, J. K.; Nordin, S.; Sequeira, H.; Polich, J. Procesamiento afectivo de imágenes: Una revisión integradora de los hallazgos del ERP. *Biol. Psychol.* 2008, 77, 247–265. [\[Referencia cruzada\]](#) [\[PubMed\]](#)
130. Schupp, HT; Markus, J.; Weihe, AI; Hamm, AO Facilitación emocional del procesamiento sensorial en la corteza visual. *Psychol. Sci.* 2003, 14, 7–13. [\[Referencia cruzada\]](#)
131. Delplanque, S.; Lavoie, ME; Hot, P.; Silvert, L.; Sequeira, H. Estudio de la modulación del procesamiento cognitivo mediante la valencia emocional. A través de potenciales relacionados con eventos en humanos. *Neurosci. Lett.* 2004, 356, 1–4. [\[CrossRef\]](#) [\[PubMed\]](#)
132. Keil, A.; Bradley, MM; Hauk, O.; Rockstroh, B.; Elbert, T.; Lang, PJ Correlatos neuronales a gran escala del procesamiento de imágenes afectivas. *Psicofisiología* 2002, 39, 641–649. [\[CrossRef\]](#)
133. Hajcak, G.; Weinberg, A.; MacNamara, A.; Foti, D. ERPs y el estudio de la emoción. En *el Manual Oxford de Evolución Relacionada con Eventos. Componentes potenciales*; Oxford University Press: Oxford, Reino Unido, 2012; Volumen 441, 474p.
134. Cuthbert, BN; Schupp, HT; Bradley, MM; Birbaumer, N.; Lang, PJ Potenciales cerebrales en el procesamiento afectivo de imágenes: covariación Con activación autonómica e informe afectivo. *Biol. Psychol.* 2000, 52, 95–111. [\[CrossRef\]](#)
135. Franz, G.; Wiener, J.M. De la sintaxis espacial a la semántica espacial: Una metodología orientada al comportamiento y la percepción para la descripción eficiente de la geometría y la topología de entornos. *Environ. Plan. B. Plan. Des.* 2008, 35, 574–592. [\[CrossRef\]](#)
136. Nasar, J. L. Estética del Diseño Urbano. *Environ. Behav.* 1994, 26, 377–401. [\[CrossRef\]](#)
137. Chu, SK; Cha, SH: Experiencia humana mediante realidad virtual para un diseño arquitectónico óptimo. *KIBIM Mag.* 2024, 14, 1–10. [\[Referencia cruzada\]](#)
138. Banaei, M.; Ahmadi, A.; Gramann, K.; Hatami, J. Evaluación emocional de las formas arquitectónicas interiores basada en la personalidad. Diferencias mediante realidad virtual. *Front. Archit. Res.* 2020, 9, 138–147.
139. Razoumnikova, OM. Organización funcional de diferentes áreas cerebrales durante el pensamiento convergente y divergente: Una investigación EEG. *Cogn. Brain Res.* 2000, 10, 11–18. [\[CrossRef\]](#)
140. Cohen, J. A Power Primer. En *Cuestiones metodológicas y estrategias en la investigación clínica*; Asociación Americana de Psicología: Washington, D. C., EE. UU., 2016.
141. Faul, F.; Erdfelder, E.; Lang, A.-G.; Buchner, A. G\*Power 3: Un programa flexible de análisis de potencia estadística para las áreas sociales, conductuales, y ciencias biomédicas. *Behav. Res. Methods* 2007, 39, 175–191. [\[CrossRef\]](#) [\[PubMed\]](#)
142. Al-Samarraie, H.; Eldenfra, A.; Price, ML; Zaout, F.; Fauzy, WM Efectos de las características del diseño de mapas en las búsquedas de los usuarios Rendimiento y carga cognitiva: Un estudio empírico. *Electron. Lib.* 2019, 37, 667–679. [\[CrossRef\]](#)
143. Hu, W.-L.; Reid, T. Los efectos de la experiencia contextual de los diseñadores en el proceso de ideación y los resultados del diseño. *J. Mech. Des.* 2018, 140, 101101. [\[Referencia cruzada\]](#)
144. Emanuel, EJ; Wendler, D.; Grady, C. ¿Qué hace que la investigación clínica sea ética? *JAMA* 2000, 283, 2701–2711. [\[CrossRef\]](#)
145. Lee, J.-K.; Jeong, H.; Kim, Y.; Cha, SH Creación de visualizaciones espaciales utilizando modelos de estilo de diseño de interiores perfeccionados e informados por Preferencias del usuario. *Adv. Eng. Inform.* 2024, 62, 102686. [\[CrossRef\]](#)
146. Galloway, NR Electrofisiología del cerebro humano: Potenciales evocados y campos magnéticos evocados en la ciencia y la medicina. *Br. J. Otolmol.* 1990, 74, 255. [\[CrossRef\]](#)
147. Makeig, S.; Bell, A.; Jung, T.-P.; Sejnowski, T.J. Análisis de componentes independientes de datos electroencefalográficos. En *Avances en Sistemas de procesamiento de información neuronal 8*; MIT Press: Cambridge, MA, EE.UU., 1995.
148. Widmann, A.; Schröger, E.; Maess, B. Diseño de filtros digitales para datos electrofisiológicos: un enfoque práctico. *J. Neurosci. Methods* 2015, 250, 34–46. [\[CrossRef\]](#)
149. Mäkinen, V.; Tiitinen, H.; May, P. Las respuestas auditivas relacionadas con eventos se generan independientemente de la actividad cerebral en curso. *NeuroImage* 2005, 24, 961–968. [\[Referencia cruzada\]](#) [\[PubMed\]](#)
150. Viola, FC; Debener, S.; Thorne, J.; Schneider, TR. Uso de ICA para el análisis de datos de EEG multicanal. En *EEG simultáneo y fMRI: registro, análisis y aplicación*; Oxford University Press: Oxford, Reino Unido, 2010; págs. 121–133.

151. Kappenman, ES; Luck, SJ Los efectos de la impedancia de los electrodos en la calidad de los datos y la significación estadística en los registros de ERP. *Psicofisiología* 2010, 47, 888–904. [\[CrossRef\]](#)
152. AJ, B.; TJ, S. Un enfoque de maximización de la información para la separación y deconvolución ciegas. *Neural Comput.* 1995, 7, 1129–1159. [\[Referencia cruzada\]](#)
153. Polich, J. Actualización de P300: Una teoría integrativa de P3a y P3b. *Clin. Neurophysiol.* 2007, 118, 2128–2148. [\[CrossRef\]](#) [\[PubMed\]](#)
154. Bentin, S.; Allison, T.; Puce, A.; Pérez, E.; McCarthy, G. Estudios electrofisiológicos de la percepción facial en humanos. *J. Cogn. Neurosci.* 1996, 8, 551–565. [\[Referencia cruzada\]](#)
155. Joyce, C.; Rossion, B. Los componentes N170 y VPP sensibles a la cara manifiestan los mismos procesos cerebrales: El efecto de la referencia Sitio del electrodo. *Clin. Neurophysiol.* 2005, 116, 2613–2631. [\[CrossRef\]](#)
156. Dien, J. Problemas en la aplicación de la referencia promedio: Revisión, críticas y recomendaciones. *Behav. Res. Methods Instrum. Comput.* 1998, 30, 34–43. [\[Referencia cruzada\]](#)
157. Yao, D. Un método para estandarizar una referencia de registros de EEG del cuero cabelludo hasta un punto en el infinito. *Physiol. Meas.* 2001, 22, 693–711. [\[Referencia cruzada\]](#) [\[PubMed\]](#)
158. Kayser, J.; Tenke, CE. Sobre los beneficios del uso de la metodología laplaciana de superficie (densidad de fuente de corriente) en electrofisiología. *Int. J. Psychophysiol. Off. J. Int. Organ. Psychophysiol.* 2015, 97, 171–173. [\[CrossRef\]](#)
159. Michel, CM; Murray, MM; Lantz, G.; Gonzalez, S.; Spinelli, L.; Peralta, RGd Imágenes de fuente EEG. *Clin. Neurophysiol.* 2004, 115, 2195–2222. [\[Referencia cruzada\]](#)
160. Pascual-Marqui, RD; Michel, CM; Lehmann, D. Tomografía electromagnética de baja resolución: Un nuevo método para localizar Actividad eléctrica cerebral. *Int. J. Psychophysiol.* 1994, 18, 49–65. [\[CrossRef\]](#) [\[PubMed\]](#)
161. Bertrand, O.; Perrin, F.; Pernier, J. Una justificación teórica de la referencia promedio en estudios de potenciales evocados topográficos. *Electroencefalograma. Neurofisiología Clínica. Sección de Potenciales Evocados*, 1985, 62, 462–464. [\[CrossRef.\]](#) [\[PubMed\]](#)
162. Nunez, PL; Srinivasan, R. Campos eléctricos del cerebro: la neurofísica del EEG; Oxford University Press: Oxford, Reino Unido, 2006. [\[Referencia cruzada\]](#)
163. Tutorial de EEGLAB. Disponible en línea: <https://eeglab.org/tutorials/> (consultado el 30 de septiembre de 2024).
164. Kim, H.; Luo, J.; Chu, S.; Cannard, C.; Hoffmann, S.; Miyakoshi, M. Error de ICA: Cómo surgen circuitos integrados fantasma a partir de una deficiencia de rango efectivo causada por la interpolación de electrodos de EEG y una re-referenciación incorrecta. *Front. Signal Process.* 2023, 3, 1064138. [\[CrossRef\]](#)
165. Vecchiato, G.; Toppi, J.; Astolfi, L.; De Vico Fallani, F.; Cincotti, F.; Mattia, D.; Bez, F.; Babiloni, F. Las asimetrías frontales del EEG espectral se correlacionan con la satisfacción experimentada con los anuncios de televisión. *Med. Biol. Eng. Comput.* 2011, 49, 579–583. [\[Referencia cruzada\]](#)
166. Davidson, RJ; Irwin, W. Neuroanatomía funcional de la emoción y el estilo afectivo. *Trends Cogn. Sci.* 1999, 3, 11-21. [\[CrossRef\]](#)
167. Harmon-Jones, E.; Gable, PA Sobre el papel de la actividad cortical frontal asimétrica en la motivación de aproximación y retirada: un Revisión actualizada de la evidencia. *Psicofisiología* 2018, 55, e12879. [\[CrossRef\]](#)
168. Pourtois, G.; Schettino, A.; Vuilleumier, P. Mecanismos cerebrales de las influencias emocionales en la percepción y la atención: ¿Qué es la magia? y lo que no lo es. *Biol. Psychol.* 2013, 92, 492–512. [\[CrossRef\]](#)
169. Cohen, JD PsyScope: Un nuevo entorno gráfico interactivo para el diseño de experimentos de psicología. *Behav. Res. Methods Instrum. Comput.* 1993, 25, 257–271. [\[Referencia cruzada\]](#)
170. Mccraty, R.; Shaffer, F. Variabilidad de la frecuencia cardíaca: nuevas perspectivas sobre los mecanismos fisiológicos, evaluación de la autorregulación Capacidad y riesgo para la salud. *Glob. Adv. Health Med.* 2015, 4, 46–61. [\[CrossRef\]](#)
171. Huang, H.; Xie, Q.; Pan, J.; He, Y.; Wen, Z.; Yu, R.; Li, Y. Una interfaz cerebro-computadora basada en EEG para el reconocimiento de emociones y su aplicación en pacientes con trastorno de la conciencia. *IEEE Trans. Affect. Comput.* 2021, 12, 832–842. [\[CrossRef\]](#)
172. Bashivan, P.; Rish, I.; Yeasin, M.; Codella, N. Aprendizaje de representaciones a partir de EEG con redes neuronales convolucionales recurrentes profundas . *arXiv* 2015, arXiv:1406.1078.

Aviso legal/Nota del editor: Las declaraciones, opiniones y datos contenidos en todas las publicaciones son responsabilidad exclusiva de los autores y colaboradores, y no de MDPI ni de sus editores. MDPI y sus editores no se responsabilizan de ningún daño a personas o bienes que resulte de las ideas, métodos, instrucciones o productos mencionados en el contenido.